# 9 学习问题的数学表达

**先修知识、学习目标与本章位置**

本章使用第 4 章的数组形状、第 6 章的向量和第 8 章的期望、条件概率。目标是把实际预测任务写成输入、目标、模型集合、损失和数据分布；分清经验风险与期望风险、拟合与决策、模型误差与优化误差。第 9–14 章构成监督学习的共同基础，本章先规定后续算法要解决的问题。

假设在包裹揽收时预测最终配送时长。数据库中有揽收时间、重量、目的地，也有送达后才写入的签收时间。如果只把所有数值列送入一个算法，程序也许能得到很低的误差，但签收时间已包含答案。数学表达必须从预测发生的时刻开始：哪些信息当时存在，预测的是哪一个未来量，哪些包裹属于需要服务的人群。数据表只是观察结果的载体，不能代替问题定义。

## 9.1 从业务叙述到样本与空间

### 观测单位、预测时刻与目标窗口

**观测单位**是一个样本所代表的对象，可以是一件包裹、一次就诊、一个用户或一段时间窗口。一名用户产生一百条记录，不等于观察了一百名独立用户。建立数据集时应先明确“一行是什么”，再决定标签和划分方式。

配送例中，观测单位选为一次订单；预测时刻为完成揽收；目标为此后直到签收的小时数。尚未签收的订单没有完整时长，不能直接当作零小时，也不能在不解释的情况下全部删除。若长时延订单更容易尚未完成，删除会改变样本分布。本书后续基础实验使用完整标签；实际存在这类删失数据时，需要额外建模。

输入对象记为 $x \in \mathcal{X}$，其中 $\mathcal{X}$ 称为**输入空间**（input space）。表格输入通常写成向量 $\mathbf{x} \in \mathbb{R}^d$；原始图片、字符串也可以作为输入，但送入数值模型之前还要编码。目标 $y \in \mathcal{Y}$ 属于**目标空间**：回归常取 $\mathcal{Y} \subseteq \mathbb{R}$，二分类常取 $\{0,1\}$，$K$ 类分类常取 $\{1,\dots,K\}$。分类编号表示身份，不表示距离。

有时模型输出与目标不属于同一空间。二分类目标只有 0 或 1，而模型可以输出 $p \in [0,1]$；多分类输出可以是 $K$ 维概率向量，其分量非负且总和为 1。为了统一，记模型输出空间为 $\mathcal{A}$，预测函数为 $f : \mathcal{X} \to \mathcal{A}$。输出概率后还需要决策规则，不能直接把一个概率向量当作类别编号。

**例题 9.1：定义一个可执行的预测任务**

计划预测“用户是否会流失”。说明为何这句话不完整，并给出一种可检验的定义。

**解** 可规定：对每月 1 日仍活跃且有至少 30 天历史的用户，用此前 30 天行为预测未来 30 天是否没有任何登录。样本是一名用户在一个月初的快照；输入只包含月初前可用的字段；标签是随后 30 天是否无登录。若同一用户跨月出现，样本可能相关。若要服务新用户，还需解释不足 30 天历史的用户如何进入任务。

“流失”在这里是人为定义的可观察事件，不等于知道用户永久离开。修改为未来 90 天未购买，会改变标签、可用样本数和评价含义。正式实验应保存目标定义，不能在看到结果后悄悄更换。

### 数据矩阵与符号约定

训练集写为 $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n}$。本书将单个输入看作 $d$ 维列向量，把样本转置后按行排列：

$$X = \begin{bmatrix} \mathbf{x}_1^{\mathrm{T}} \\ \vdots \\ \mathbf{x}_n^{\mathrm{T}} \end{bmatrix} \in \mathbb{R}^{n \times d}, \qquad \mathbf{y} = (y_1, \dots, y_n)^{\mathrm{T}} \in \mathbb{R}^n.$$

数学上 $\mathbf{y}$ 是列向量，NumPy 中常存为形状 `(n,)` 的一维数组；不要把它与 `(n,1)` 混用，否则相减时可能广播出 $n \times n$ 的错误矩阵。线性回归的权重 $\mathbf{w} \in \mathbb{R}^d$，截距 $b \in \mathbb{R}$，批量预测为 $X\mathbf{w} + b\mathbf{1} \in \mathbb{R}^n$。

输入的每一列应同时记录名称、单位、可用时刻和缺失含义。把千克改成克会改变权重的数值；把未知年龄填成 0 会把“未知”误表示为“出生时”。这些改变不只是文件格式调整，还会改变模型见到的统计问题。

## 9.2 假设空间、参数与训练算法

**假设空间**（hypothesis space）$\mathcal{H}$ 是允许选择的预测函数集合。这里的“假设”指候选函数，不是统计检验中的零假设。若只允许直线，则

$$\mathcal{H} = \{x \mapsto wx + b : w, b \in \mathbb{R}\}.$$

若先构造 $\phi(x) = (x, x^2)$，再做线性组合，得到 $f_\theta(x) = b + w_1 x + w_2 x^2$。它对输入 $x$ 可以弯曲，但对参数 $\theta = (b, w_1, w_2)$ 仍是线性的。第 11 章将利用这一点建立多项式回归。

**参数化**（parameterization）是用参数 $\theta \in \Theta$ 表示候选函数 $f_\theta$。同一个函数不一定只有一组参数：若两列特征完全相同，将第一列权重增加 1、第二列减少 1，不改变任何预测。因而“参数唯一”与“拟合值唯一”是两个问题；第 6 章的零空间正是这种现象的代数表达。

**训练算法**（training algorithm）$A$ 把数据与预先确定的设置转换成预测器，记为 $\hat{f} = A(D)$。算法可以直接解线性方程，也可以逐步更新参数。随机初始化、数据顺序、停止条件都可能影响输出。模型给出可以表示哪些函数，算法决定如何从中寻找一个函数。

| 对象 | 配送回归中的例子 | 怎样确定 |
|---|---|---|
| 模型形式 | $b + \mathbf{w}^{\mathrm{T}}\mathbf{x}$ | 根据表达能力和任务选择 |
| 参数 | $b, \mathbf{w}$ | 利用训练数据拟合 |
| 超参数 | 正则强度、特征次数 | 依据验证方案选择 |
| 训练算法 | 直接求解或梯度下降 | 考虑目标性质与资源 |
| 决策规则 | 超过 48 小时则预警 | 依据成本及验证结果 |
| 评价指标 | MAE 或延误召回率 | 根据使用目标事先规定 |

学习率在算法中控制更新步幅，不能替代正则强度；决策阈值改变行动，不必改变已经拟合的概率函数。广义上阈值也可作为需验证的设置，但应把它与模型权重分开记录，以便重现整个系统。

## 9.3 损失与风险：从一个样本到一个分布

### 逐样本损失

**损失函数**（loss function）$\ell(a, y)$ 衡量输出 $a$ 与目标 $y$ 的不一致。平方损失为 $(a-y)^2$，绝对损失为 $|a-y|$；分类的 0–1 损失为 $\mathbf{1}\{a \neq y\}$，其中指示函数在条件成立时等于 1，否则为 0。

平方损失的单位是目标单位的平方，绝对损失与目标同单位。若把小时换成分钟，平方损失放大 3600 倍；这会影响与正则项的相对权重。单位转换以后仍沿用原数值的正则系数，并不一定保持同一个优化问题。

二分类概率 $p$ 可用对数损失

$$\ell(p, y) = -y \log p - (1 - y) \log(1 - p).$$

自然对数对应第 8 章的交叉熵。对真实标签赋予接近零的概率会受到很大惩罚；它衡量概率预测，不只衡量阈值后的分类是否正确。第 13 章再从伯努利似然推导参数梯度。

### 期望风险与经验风险

设随机输入与目标 $(\mathbf{X}, Y)$ 服从联合分布 $P$。大写表示随机变量，数据矩阵也记为 $X$，应根据上下文区分。对于固定函数 $f$，**期望风险**（expected risk，也称总体风险）为

$$R_P(f) = \mathbb{E}_{(\mathbf{X},Y)\sim P}[\ell(f(\mathbf{X}), Y)]. \tag{9.1}$$

它描述从目标总体抽到一个新样本时的平均损失。真实 $P$ 通常未知，故无法直接计算。训练数据上的**经验风险**（empirical risk）为

$$\widehat{R}_D(f) = \frac{1}{n} \sum_{i=1}^{n} \ell(f(\mathbf{x}_i), y_i). \tag{9.2}$$

经验风险对已有 $n$ 条数据求平均，期望风险对未知总体求平均；两者计算对象不同。验证集、测试集也可以计算经验平均，但其作用是评估由其他数据确定的函数。

若 $f$ 事先固定，样本同分布且损失期望存在，则 $\mathbb{E}_D \widehat{R}_D(f) = R_P(f)$。线性期望给出

$$\mathbb{E}_D\left[\frac{1}{n}\sum_i \ell(f(\mathbf{X}_i), Y_i)\right] = \frac{1}{n}\sum_i R_P(f) = R_P(f).$$

这里无偏性本身只用到各样本边缘分布相同；要控制平均值的波动，还必须研究独立性或依赖结构。更不能把固定 $f$ 的结论直接套给根据同一数据选出的 $\hat{f}$。

**例题 9.2：训练均值为何显得特别准确**

设 $Y_i$ 独立同分布，均值 $\mu$、方差 $\sigma^2$。只允许常数预测 $c$，平方损失下以训练均值 $\bar{Y}$ 拟合。比较平均训练误差与新样本误差。

**解** 最小化 $n^{-1}\sum_i (Y_i - c)^2$，对 $c$ 求导得 $2(c - \bar{Y}) = 0$，故 $\hat{c} = \bar{Y}$。由第 8 章样本离差恒等式，

$$\sum_i (Y_i - \bar{Y})^2 = \sum_i (Y_i - \mu)^2 - n(\bar{Y} - \mu)^2.$$

两边取期望并除以 $n$，利用 $\mathrm{Var}(\bar{Y}) = \sigma^2/n$，得到

$$\mathbb{E}_D \widehat{R}_D(\hat{c}) = \sigma^2(1 - 1/n).$$

对于与训练集独立的新 $Y'$，条件于已经得到的 $\bar{Y}$，

$$\mathbb{E}[(Y' - \bar{Y})^2 \mid D] = \sigma^2 + (\bar{Y} - \mu)^2.$$

再对训练集求平均，得到 $\sigma^2(1 + 1/n)$。训练误差平均比新样本误差小 $2\sigma^2/n$。这个差来自使用同一批数据既选常数又评价常数，即使只有一个参数也会出现。

### 风险最优预测不等于恢复每个标签

对平方损失，令 $m(\mathbf{x}) = \mathbb{E}[Y \mid \mathbf{X} = \mathbf{x}]$。把 $Y - a$ 拆成 $Y - m + m - a$，在条件期望中交叉项为零，得

$$\mathbb{E}[(Y - a)^2 \mid \mathbf{X} = \mathbf{x}] = \mathrm{Var}(Y \mid \mathbf{X} = \mathbf{x}) + (m(\mathbf{x}) - a)^2.$$

第一项不随 $a$ 改变，所以最佳平方损失预测为条件均值。即使知道真实分布，只要条件方差不为零，也不能让所有新样本误差都为零。绝对损失的最优预测为条件中位数；0–1 分类损失的最优预测为条件概率最大的类别。所谓“最优”必须同时指定分布与损失。

**例题 9.3：不同损失选择不同常数**

$Y$ 以概率 3/4 取 0，以概率 1/4 取 2。只输出常数，求平方损失与绝对损失下的最优输出。

**解** 平方风险为 $R(c) = \frac{3}{4}c^2 + \frac{1}{4}(2-c)^2 = c^2 - c + 1$。配方得 $(c-1/2)^2 + 3/4$，故 $c = 1/2$、最小风险 3/4。若强制输出 0，平方风险为 1。

绝对风险在 $0 \le c \le 2$ 时为 $\frac{3}{4}c + \frac{1}{4}(2-c) = \frac{1}{2} + \frac{1}{2}c$，随 $c$ 增大；在区间外也不会更小，故最优为 0，风险 1/2。数据完全相同，改变损失就改变了合理答案。

## 9.4 经验风险最小化与正则化

**经验风险最小化**（empirical risk minimization，ERM）求

$$\hat{f} \in \arg\min_{f \in \mathcal{H}} \widehat{R}_D(f).$$

arg min 返回使目标最小的参数或函数，不是最小值本身；若有多个解，必须说明算法如何选择。足够灵活的函数可能逐点记住标签，训练误差为零，却在新点上任意输出。因此需要限制候选函数或引入偏好。

**正则化**（regularization）的一种形式是在数据损失后增加惩罚：

$$J_D(\theta) = \frac{1}{n}\sum_i \ell(f_\theta(\mathbf{x}_i), y_i) + \lambda\Omega(\theta), \qquad \lambda \ge 0. \tag{9.3}$$

$\Omega$ 描述不希望出现的参数特性，如过大的欧氏范数或过多非零系数；$\lambda$ 控制权衡。正则项不是另一批真实样本的损失，$J_D$ 的下降不等价于测试误差下降。比较不同 $\lambda$ 时，应使用共同的验证指标，而非直接比较含有不同惩罚系数的目标值。

以一维 $J(w) = \frac{1}{2}(w-3)^2 + \frac{\lambda}{2}w^2$ 为例，导数为 $(1+\lambda)w - 3$，最优 $w = 3/(1+\lambda)$。增大 $\lambda$ 使权重缩小，也使原始拟合误差增大；如果未正则化估计受噪声影响较大，这种有偏估计可能降低新样本风险，具体情况仍需验证。

另一种写法是约束 $\Omega(\theta) \le t$ 后最小化经验风险。凸问题在适当条件下可通过拉格朗日乘子联系这两种形式，但不能预先假定任意 $t$ 都与唯一 $\lambda$ 一一对应。优化器的学习率也不是这个乘子：学习率决定怎么走，$\lambda$ 决定目标长什么样。

## 9.5 损失、指标与决策成本

训练时常用易计算或可微的损失，报告时用便于解释的指标。例如平方损失易求导，RMSE 回到小时单位；0–1 错误率直接对应分类错误，但对参数呈阶梯变化，难以用普通梯度下降优化。替代损失是否能改善任务指标，应在验证数据中检查，不能只因可微就视为符合全部业务目标。

设 $p = P(Y = 1 \mid \mathbf{x})$，误报成本为 $C_{\mathrm{FP}} > 0$，漏报成本为 $C_{\mathrm{FN}} > 0$，正确行动成本设为 0。选择正类的条件期望成本为 $C_{\mathrm{FP}}(1-p)$，选择负类为 $C_{\mathrm{FN}}p$。因此选择正类的条件为

$$C_{\mathrm{FP}}(1-p) \le C_{\mathrm{FN}}p \quad \Longleftrightarrow \quad p \ge \frac{C_{\mathrm{FP}}}{C_{\mathrm{FP}} + C_{\mathrm{FN}}}.$$

该阈值推导假设 $p$ 是适用分布下的真实后验或可靠估计、成本固定且没有资源容量限制。如果每天最多人工审核 100 件，则还需考虑排序与容量；概率失准时也不能直接依靠公式完成决策。

**例题 9.4：相同概率，不同决策**

四个样本的正类概率为 $(0.1, 0.3, 0.6, 0.9)$，实际标签为 $(0, 1, 0, 1)$。误报成本 1，漏报成本 5。比较阈值 0.5 与成本阈值。

**解** 阈值 0.5 得到 $(0, 0, 1, 1)$，有一次误报和一次漏报，总成本 6。成本阈值为 $1/(1+5) = 1/6$，得到 $(0, 1, 1, 1)$，仅一次误报，总成本 1。后一方案改变了决策规则，没有重新估计四个概率。四条记录只能核对计算，不能证明未来成本必然下降；真实阈值选择仍需独立验证。

## 9.6 独立同分布及其失效方式

**独立同分布**（independent and identically distributed，i.i.d.）假设包含两层：各记录的联合分布不通过依赖关系耦合，各记录又来自同一个总体。独立不等于输入各列相互独立；同分布不等于每条样本数值相同。即使记录由程序随机打乱，同一个用户的多条行为也不会因此变成独立观察。

若随机变量 $Z_i$ 是样本损失，则

$$\operatorname{Var}\left(\frac{1}{n}\sum_{i} Z_i\right) = \frac{1}{n^2}\left[\sum_{i} \operatorname{Var}(Z_i) + 2\sum_{i<j} \operatorname{Cov}(Z_i, Z_j)\right].$$

独立时协方差为零，得到常见的 $\sigma^2/n$。若样本正相关，第二项会使平均损失的波动更大。把同一图片复制一百份并不能提供一百份独立信息，也不应按独立样本计算置信区间。

**分布变化**（distribution shift）表示训练分布 $P$ 与使用分布 $Q$ 不同。可把联合分布分解为 $P(x, y) = P(y \mid x)P(x)$：若输入人群比例改变但条件关系近似不变，称协变量偏移；若条件关系本身改变，常称概念漂移。标签偏移则假设 $P(x \mid y)$ 不变而类别先验改变。这些是便于分析的特定假设，现实变化可能同时涉及多项。

配送模型在晴天训练、暴雨时使用，可能同时遇到区域比例和交通规律改变。新的数据中不含标签时，可以检查输入分布，却通常不能仅凭输入稳定证明 $P(y \mid x)$ 也稳定。若使用期标签获取滞后，评价也会滞后。

若 $Q$ 相对于 $P$ 绝对连续（即 $P$ 概率为零的区域，$Q$ 也不赋予正概率），且密度比与损失可积，重要性加权可写为

$$R_Q(f) = \mathbb{E}_P\left[\frac{q(X, Y)}{p(X, Y)}\ell(f(X), Y)\right].$$

但密度比通常未知，大权重会放大方差，训练没有覆盖的区域不能靠权重凭空恢复。本书不把它作为无标签漂移的通用修复方法。

## 9.7 误差来源与可采取的行动

### 总体风险的参照分解

令 $R^*$ 为所有可测预测函数能达到的最低风险，$f^*_{\mathcal{H}}$ 为所选假设空间中的总体最优函数，$\hat{f}$ 为理想经验风险最小化解，$\tilde{f}$ 为实际算法输出。假设这些最优解存在，可以写恒等式

$$\begin{aligned} R(\tilde{f}) - R^* = {} & [R(f^*_{\mathcal{H}}) - R^*] \\ & + [R(\hat{f}) - R(f^*_{\mathcal{H}})] + [R(\tilde{f}) - R(\hat{f})]. \end{aligned}$$

第一项是表达能力限制带来的**近似误差**，也称模型误差；第二项来自有限样本选择函数，体现**估计误差**或统计误差；第三项是实际算法与理想经验解在总体风险上的差。第三项不必非负：没有把训练目标完全最小化，有时反而改善泛化。严格非负的**优化误差**通常定义为经验目标差 $J_D(\tilde{\theta}) - \inf_\theta J_D(\theta)$，不要把它与第三项混为一谈。

这一区分解释了为什么“训练更久”只能针对某些问题。若模型只允许直线而真实条件均值为弯曲函数，优化到机器精度也不能消除表达限制；若样本数太少，训练更久不产生新信息；若训练分布与部署分布不同，即使原总体风险很小，也不保证部署风险小。

### 一个可证明的上界

考虑未正则化 ERM。若在某次数据抽样下，对所有 $f \in \mathcal{H}$ 都有 $|R(f) - \widehat{R}(f)| \le \varepsilon$，而实际输出满足 $\widehat{R}(\tilde{f}) \le \inf_{f\in\mathcal{H}} \widehat{R}(f) + \delta$，则

$$\begin{aligned} R(\tilde{f}) &\le \widehat{R}(\tilde{f}) + \varepsilon \\ &\le \widehat{R}(f^*_{\mathcal{H}}) + \delta + \varepsilon \\ &\le R(f^*_{\mathcal{H}}) + \delta + 2\varepsilon. \end{aligned}$$

所以超额风险至多为近似误差加 $2\varepsilon + \delta$。关键是“对所有候选函数同时成立”：只控制一个事先固定函数的误差，不能保证数据挑出的最佳函数也满足相同界。假设空间越复杂，建立这种统一控制通常越困难。这是第 14 章泛化与模型选择的理论入口，本章不预先给出没有假设的万能样本量。

**例题 9.5：判断错误应该在哪里处理**

某模型训练和验证误差都很高；另一模型训练误差极低但验证误差很高；第三个模型两者原本都低，上线后却明显变差。能否只凭这三种现象确定原因？

**解** 不能唯一确定。第一种应先检查实现、标签对齐和训练是否收敛，再考虑表达能力不足；第二种可检查模型复杂度、训练量和划分差异；第三种需要核对上线预处理与训练一致性、输入可用性、分布与标签定义变化。损失曲线提供线索，不能代替对照实验。把学习率调小并不能修复标签错位，把模型变大也不能修复泄漏。

## 9.8 实验 9.1：把风险与成本写成程序

实验入口为 ch09_risk.py，只使用 NumPy。数据均为前面例题中的教学数值；运行 python3 ch09_risk.py。程序分别计算有限分布的加权平方风险和固定标签上的决策成本。

```
import numpy as np
values = np.array([0., 2.])
probability = np.array([.75, .25])
for c in [0., .5, 1.]:
    loss = (values - c) ** 2
    population_risk = np.sum(probability * loss)
    print(c, population_risk)
```

预期总体风险依次为 1、0.75、1。这里概率分布完全已知，所以确实在计算总体风险；真实数据中把一批样本的频率当成真实概率，只得到经验近似。完整脚本拒绝空数组、预测与标签形状不一致、负权重和非有限值；不能用广播偷偷完成长度不一致的评价。

修改任务：将概率改成 $(0.9, 0.1)$，先求新的最优常数，再运行核对。应得到均值 0.2、最小平方风险 0.36。把漏报成本从 5 改成 2，则成本阈值为 $1/3$，本例与 0.5 阈值给出相同决策。阈值连续改变，有限数据上的决策和指标会呈阶梯式变化。

## 9.9 实验 9.2：反复抽样观察训练乐观偏差

入口 ch09_sampling.py 使用固定种子 902，对 $Y \sim N(2, 9)$ 重复生成 20000 份训练集，样本量分别为 5、20、100。每份数据都重新估计常数 $\bar{Y}$；随后用已知分布计算该常数的真实风险 $9 + (\bar{Y} - 2)^2$，无需另外制造一个有抽样噪声的测试集。

```
rng = np.random.default_rng(902)
y = rng.normal(2., 3., size=(20000, 5))
mean = y.mean(axis=1)
training = ((y - mean[:, None]) ** 2).mean(axis=1)
population = 9 + (mean - 2) ** 2
print(training.mean(), population.mean())
```

理论上训练风险均值分别为 7.2、8.55、8.91，总体风险均值分别为 10.8、9.45、9.09；模拟结果应接近而非逐字相同。脚本以 0.12 的绝对差检查固定种子的模拟均值，精确恒等式另在答案核对中验证。这个宽度是实验检查容差，不是置信区间。

程序存储 $20000 \times n$ 个浮点数，时间与内存均随重复次数和样本量的乘积增长。内存不足可按批生成再累计总和。修改任务是将总体均值改为 10 而方差保持 9：理论风险不变，因为常数模型可以吸收位置变化。若重复使用同一个训练均值而不重新拟合，就不再是在研究训练集随机性。

## 9.10 知识联系与自检

本章把第 8 章的期望转化为学习目标，把第 6、7 章的优化用于从假设空间选函数。第 10 章讨论实际数据如何满足评价问题，第 11 章求解一类具体经验风险，第 12 章研究迭代算法，第 14 章再系统讨论泛化和评价。阅读任何新算法时，可以先写出输入形状、函数族、逐样本损失、正则项、优化方法与评价分布；其中缺少一项，往往就无法准确比较结果。

计算与编程答案可运行 `ch09_solutions.py` 核对。该入口验证数值与实现边界；概念题仍需依据下列推理说明判断。

## 9.11 分层练习

9.1 预测“明天需求”的任务还缺哪些定义？至少列出四项。

9.2 $X \in \mathbb{R}^{40\times 6}$，有截距的线性回归有多少参数？批量预测形状是什么？

9.3 $Y$ 以概率 0.8 取 1、0.2 取 6，求平方损失最优常数及风险。

9.4 标签 $(1,3,4)$，常数预测 2，计算 MSE 与 MAE；哪个与标签单位相同？

9.5 证明平方损失下 $R(f)=\mathbb{E}[\mathrm{Var}(Y\mid X)]+\mathbb{E}[(m(X)-f(X))^2]$。

9.6 误报成本 3、漏报成本 7，推导概率决策阈值。若所有正类行动另需固定成本 1，正确负类成本仍为 0，阈值如何变化？

9.7 对 $J(w)=\frac{1}{2}(w-4)^2+\frac{\lambda}{2}w^2$ 求最优值对应的参数，分别代入 $\lambda=0,1,3$。

9.8 把每个测试样本复制 10 次，平均损失、独立信息量和朴素独立标准误各会怎样变化？

9.9 固定 $f$ 的经验风险无偏，为何不能证明挑选 1000 个模型中训练误差最小者的训练误差无偏？

9.10 若统一偏差界为 0.03，经验优化误差不超过 0.02，模型近似误差为 0.1，超额风险上界是多少？列出使用条件。

9.11 修改实验 9.2 为 $n=1$，说明训练误差和总体风险的理论均值，并用模拟核对。

9.12 给实验 9.1 增加非法权重测试与概率总和检查。一般样本加权平均与已知有限分布求期望，对权重归一化的接口约定应怎样区分？

## 9.12 参考答案与推理

9.1 应规定哪种商品或区域、预测发生的时间、明天的起止时区、需求计数口径、取消订单是否计入以及当时可用输入。没有这些定义，不同程序可能正确计算不同目标。

9.2 权重 6 个、截距 1 个，共 7 个。$X\mathbf{w}$ 为 40 维；NumPy 采用 `(40,)`，截距以标量广播。标签也保持该形状。

9.3 均值为 $0.8 + 1.2 = 2$。风险为 $0.8(1-2)^2 + 0.2(6-2)^2 = 4$；配方后为 $(c-2)^2 + 4$。

9.4 误差为 $(-1, 1, 2)$，平方和 6，故 MSE 为 2；绝对和 4，MAE 为 $4/3$，与标签同单位。

9.5 条件于 $X$ 展开平方，$\mathbb{E}[Y - m(X) \mid X] = 0$ 使交叉项消失，再用全期望公式对 $X$ 求平均。要求二阶矩存在。

9.6 原阈值 $3/(3+7) = 0.3$。加入行动成本后，正类成本为 $3(1-p)+1$，负类为 $7p$，比较得 $p \geq 0.4$。不能只把误报成本改成 4，因为真阳性也付出行动成本。

9.7 导数 $(1+\lambda)w - 4 = 0$，故 $w = 4/(1+\lambda)$，三种情况为 4、2、1。每种目标的二阶导数为 $1 + \lambda > 0$，所以是唯一全局最小值。

9.8 平均损失不变，独立信息量不增加；若误当作样本量扩大 10 倍，标准误约缩小为原来的 $1/\sqrt{10}$，从而夸大精度。应按原始独立单位重采样或汇总。

9.9 最佳模型依赖这些数据，选择过程偏向获得有利噪声的候选。固定函数无偏的等式不能在数据依赖的最小化以后原样保留；例题 9.2 已给出单参数反例。

9.10 $0.1 + 2 \times 0.03 + 0.02 = 0.18$。需对整个候选集合同时成立的风险偏差界、同一总体与损失，以及未正则化经验目标下的优化误差定义。

9.11 单个样本的均值等于该样本，训练误差恒为 0；新样本风险平均为 $9(1+1) = 18$。检查程序沿行计算均值，避免把 20000 份训练集合并拟合一个常数。

9.12 加权平均允许正权重总和任意，程序内部除以其总和；已声明为概率的数组则应非负且总和近似 1，否则应拒绝或显式报告归一化。负数、全零、形状错误和 NaN 均应拒绝；不能静默将非法概率改成另一个分布。

# 10 数据划分与特征工程

**先修知识、学习目标与本章位置**

先修为第 3 章的对象和方法、第 4 章数组、第 5 章数据表与第 9 章学习问题。本章学习按部署目标划分数据，正确拟合填补器、缩放器与编码器，识别时间、用户和标签泄漏，并把处理链封装为可重复执行的 Pipeline。第 11 章将给出线性回归的完整数学推导；本章先将库中的回归器作为具有 fit 和 predict 接口的预测部件。

一个预测器的输入不是原始数据库的自然产物。程序往往要填补缺失、转换单位、选择字段、编码类别，然后才能训练。若处理步骤偷偷使用了验证数据的统计量或标签，最终分数评价的就不再是“只靠过去资料预测新对象”的能力。数据处理应被视为模型的一部分，一起拟合、保存和评价。

## 10.1 先决定评价对象，再决定划分方式

### 训练、验证和测试的职责

训练集用于估计可学习状态，包括模型参数和预处理统计量。验证集用于比较预先规定的候选方案，例如特征次数、正则强度或停止时刻。测试集用于在方案确定后估计最终性能。数据量较小时，第 14 章会用交叉验证提高训练部分的利用率，但测试集仍不能成为不断试错的反馈面板。

划分比例没有通用答案。少数类样本只有十几个时，即便总体测试集占 20%，也可能无法稳定评价该类；时间相关任务还需让验证期和部署跨度接近。应同时报告总样本数、独立单位数、各类数量与日期范围。

**数据泄漏**（data leakage）指拟合或选择过程中使用了评价协议不允许获得的信息。信息可以是标签、未来字段、同一实体的副本，也可以是验证集参与计算的处理统计量。泄漏通常使分数偏乐观，但某一次泄漏也可能让分数变差；是否违规由信息使用规则判定，不由分数是否提高判定。

### 随机与分层划分

若样本可合理近似为独立同分布，随机划分可使各部分来自相似总体。固定随机种子让划分可以重现，但不能保证这一次划分具有代表性。分类中可采用**分层划分**（stratified split），使各子集类别比例接近整体比例。

```
from sklearn.model_selection import train_test_split
train_id, valid_id = train_test_split(
    ids, test_size=0.2, random_state=10, stratify=y
)
```

这里 `ids` 是样本下标，`y` 是等长标签。随后对所有字段使用同一组下标，不能分别打乱输入与标签。该片段以已经定义两个数组为前提。连续回归标签不应直接逐值分层，因为几乎每个值可能都只出现一次；若按区间分层，需明确分箱规则及样本量。

极少数类可能少到无法同时分配到训练与验证。此时应重新设计评价、收集数据或说明不足，不能通过把同一样本复制到两个集合来凑数。分层也不处理实体重复；两部分拥有相同比例，不代表它们彼此独立。

### 时间划分

若模型根据过去预测未来，通常按时间先后划分。训练截止日后的信息不能进入训练，包括事后补录且覆盖到过去日期的字段。要区分**事件时间**（事情发生的时间）与**可用时间**（系统实际能够取得字段的时间）。预测时必须以可用时间为准。

假设在第 $t$ 天用此前 7 天行为预测未来 7 天的销量。若训练样本的预测时刻到第 100 天，而验证从第 101 天开始，则第 100 天样本标签包含第 101–107 天结果。验证起点处训练标签尚未全部成熟，无法按该设定真正训练。可以提前训练截止日，使最后训练标签在部署时已可获得，并根据重叠窗口和依赖程度设置间隔。

**例题 10.1：标签窗口跨过了分界线**

每个样本在当天结束时预测未来 3 天总需求。计划在第 11 天开始前训练模型并部署。训练样本的预测日期最晚可以是哪一天?

**解** 第 7 天样本使用第 8、9、10 天标签，到了第 11 天开始前已经完整；第 8 天样本需要第 9、10、11 天结果，部署时尚不可得。因此最后训练预测日期是第 7 天，前提是第 10 天结果在部署前已完成入库。如果还需一天结算延迟，必须再提前。间隔应由窗口和可用性推导，不能固定认为空出一天就足够。

### 分组划分与组合约束

**分组划分**（group split）使同一用户、设备或原始文档的记录只出现在一个集合。若目标是服务新用户，按用户分组通常比逐行随机划分更贴近任务；若目标是给已有用户预测下一次行为，则同一用户跨集合可以合理，但必须保持时间与字段可用性。

分组与分层可能冲突：若一个医院几乎只有一种类别，留出医院可能明显改变类别比例。应优先忠实表达部署问题，再报告分布差异；不能为了分数更好看，把医院内记录随机混入训练。需要同时满足时间和组约束时，可先限定时间段，再明确哪些组允许出现，检查交集而不是仅依赖函数名。

| 使用场景 | 合适的主要约束 | 常见错误 |
|---|---|---|
| 独立表格样本 | 随机，分类可分层 | 分别打乱输入和标签 |
| 历史预测未来 | 按时间及信息可用性 | 使用未来窗口或结算值 |
| 预测未见用户 | 按用户分组 | 同一用户两边都有记录 |
| 新设备或新机构 | 留出设备或机构 | 把站点特征误当成普适规律 |
| 文本切片或图像增强 | 按原文或原图分组 | 原始对象的近重复跨集合 |

## 10.2 fit 与 transform：把状态和应用分开

拟合 `fit` 计算并保存训练数据决定的状态，例如均值、方差、词表、保留特征列表。变换 `transform` 使用已经保存的规则处理输入。`fit_transform` 先拟合再变换，通常用于训练部分；在普通验证或测试上调用它会重新学习规则，破坏协议。

以标准化为例，训练列均值 $\mu_j$、标准差 $s_j$ 构成状态。新输入转换为 $z_j = (x_j - \mu_j)/s_j$。即使新批次的均值不同，也应使用同一 $\mu_j, s_j$，否则同一个物理数值在不同批次会变成不同坐标。模型权重是在旧坐标中估计的，随意换坐标等于改变输入意义。

> **例题 10.2：验证集自己标准化会发生什么**
>
> 训练值为 $(1, 3)$，验证值为 $(5, 7)$。使用总体方差形式即除以样本数计算标准差，比较正确转换与分别拟合转换。

**解** 训练均值 2，标准差 1，训练转换为 $(-1, 1)$。正确的验证转换为 $(3, 5)$，反映它们高于训练中心。验证自身均值 6、标准差 1，重新拟合会得到 $(-1, 1)$，掩盖位置差异。若把四个数一起拟合，均值 4、标准差 $\sqrt{5}$，也已经用到验证输入。三种结果均可计算，但只有第一种符合本例训练后固定规则的评价协议。

有些变换没有从数据估计状态，如按已知换算关系将千克转克、按事先规则提取月份。这类确定操作与从全数据估计分位数不同。不过即使公式固定，计算时使用了预测时尚不存在的字段，仍属于泄漏。

## 10.3 数值特征：缺失、尺度与异常值

### 缺失不是一种普通数值

缺失可以来自设备故障、未填写、业务不适用或数据尚未入库。应先区分原因再决定处理。把缺失全部填为 0 会混淆真实零值；把有缺失的行全部删除可能改变服务人群。例如高负载时传感器容易丢失数据，删除恰好排除了困难条件。

**填补**（imputation）用训练数据学习替代值，例如数值列中位数。均值填补对极端值敏感，中位数对极端值较稳健，但两者都会缩小填补后列的变化范围，不能被解释为恢复了真实观测。有时增加缺失指示列 $m_j = \mathbf{1}\{x_j \text{缺失}\}$ 可让模型区分真实值与填补值；该指示的稳定性仍取决于数据采集方式。

若某一列在训练集全缺失，中位数无法定义。应事先决定删除该列、使用有明确意义的常数，或触发数据质量错误，并检查库版本的具体行为。训练中没有缺失、部署时突然出现大量缺失，也应被记录为输入状态变化。

### 标准化与其他缩放

标准化常按

$$\mu_j = \frac{1}{n}\sum_i x_{ij}, \qquad s_j^2 = \frac{1}{n}\sum_i (x_{ij} - \mu_j)^2, \qquad z_{ij} = \frac{x_{ij} - \mu_j}{s_j}$$

计算。这里分母是 $n$，用于定义转换尺度；它不声称是总体方差的无偏估计，因而不必与第 8 章的 $n-1$ 混同。常数列 $s_j = 0$ 时应单独处理，不能直接除零；常见实现把缩放因子设为 1。

**最小最大缩放**用训练最小值 $a_j$ 和最大值 $b_j$，计算 $(x - a_j)/(b_j - a_j)$。验证输入超出训练范围时，转换结果可以小于 0 或大于 1；自动裁剪会丢失超出程度，必须是显式选择。稳健缩放可用训练中位数及四分位距，但四分位距为零时也需保护。

尺度影响距离、惩罚和优化：距离中的大单位列容易占主导；岭回归惩罚权重，单位不同会改变惩罚意义；梯度下降在尺度差异很大的坐标上可能缓慢。标准化并不把非高斯分布变成高斯分布，也不保证消除异常值。

### 异常值与偏态变换

异常值应先区分录入错误与真实少见情况。年龄为负可按规则判为非法；极长配送时间可能正是任务关心的失败案例，删除会把评价变得过于容易。以训练分位数作截断属于需要拟合的变换，阈值不能由完整数据决定。

对非负长尾量，可考虑 $z = \log(1 + x)$，它压缩较大的差距，要求 $x > -1$。若变换的是目标，模型实际优化的损失也改变。对数空间预测均值后取指数，并不一般等于原空间条件均值，因为非线性函数与期望不能任意交换。采用对数目标时，应在原任务单位下另行评价，避免以较小对数误差代替真实金额或时长误差。

## 10.4 类别编码与文本特征

### 无序类别与独热编码

**独热编码**（one-hot encoding）将 $K$ 个无序类别表示为 $K$ 维指示向量。例如区域 A、B、C 分别编码为 $(1,0,0)$、$(0,1,0)$、$(0,0,1)$。直接编码为 0、1、2 会向线性模型暗示相邻类别存在相同的数值间隔，除非这确有意义，否则不适合无序类别。

完整独热列之和恒为 1。如果线性模型同时含截距，会出现线性依赖；可以删除一个基准类别，或者采用能够处理秩亏的求解器与正则化，并明确参数解释。删除基准类别后，其他类别系数表示相对于基准的差异，而非脱离截距的绝对水平。

> **例题 10.3：基准类别与未知类别**
>
> 以 A 为基准，仅保留 B、C 两列，模型为 $\hat{y} = 5 + 2z_B - z_C$。求 A、B、C 的预测；若新类别 D 也被编码为全零，能否说 D 与 A 相同？

**解** 三类预测依次为 5、7、4。D 若映射为全零，程序会得到 5，但这只是未知类别的处理约定，不构成 D 与 A 具有相同规律的证据。若需要区分未知，可显式设置未知类别并设计训练规则，或将其交给后备方案；还应统计未知类别频率。

类别词表由训练数据确定。`handle_unknown='ignore'` 让未见类别在该编码块中取全零，从而避免预测时报错，但不保证合理外推。使用全量数据预先列出所有类别，在普通归纳评价中也让处理器见到了留出输入；若任务明确允许预知完整候选词表，应在协议中说明这一额外信息。

### 有序编码与高基数问题

“小、中、大”有顺序，但编号 0、1、2 还额外假定线性模型中间距相等。有序编码只有在这种近似可接受时才直接用于线性项，否则可采用独热或其他适合的结构。**高基数**指不同类别很多，如用户 ID；独热维度可能接近样本数，容易记忆个体而难以处理新个体。

哈希编码把字符串映射到固定数量的桶，不必学习词表，但不同类别可能碰撞，同一桶的系数因此混合多个含义。它减少维度和词表管理成本，不自动解决泛化或泄漏问题。

### 词袋与 TF–IDF 的最小背景

文本不能直接参与矩阵乘法。**词袋**（bag of words）先把文本切成词项，再用每个词项出现次数作为特征；忽略词序，但能提供一个简单基线。**词频–逆文档频率**（term frequency–inverse document frequency，TF–IDF）降低在大量文档中普遍出现的词的权重。

一种平滑定义为

$$\mathrm{idf}(t) = \log \frac{1+n}{1+\mathrm{df}(t)} + 1, \qquad v_{it} = \mathrm{tf}(t,i)\,\mathrm{idf}(t),$$

其中 $n$ 是训练文档数，$\mathrm{df}(t)$ 是含词 $t$ 的训练文档数，tf 可取原始计数。实现还可能对每篇文档向量作 $L^2$ 归一化，或采用对数词频；使用时要说明约定。词表和 IDF 都必须只在训练部分拟合。

例如三篇训练文档中，“配送”出现于全部文档，IDF 为 1；“暴雨”仅出现于一篇，IDF 为 $1+\log 2$。少见不等于有用：拼写错误、订单号也可能获得高权重。中文文本还要明确按字、词还是子词切分，不能默认英文按空格分词的方法直接表达中文词义。第 29 章再系统讨论分词与嵌入。

## 10.5 特征构造、选择与目标编码

### 构造有意义的坐标

**特征工程**（feature engineering）把原始信息转换为适合模型的表示。例如总金额和件数可以产生平均单价，但件数为零时必须定义规则；日期可以产生星期，但月份编号的周期性不能由普通直线自动表达。

对于周期为 $T$ 的位置 $t$，可使用 $\sin(2\pi t/T)$ 和 $\cos(2\pi t/T)$，使周期末端与起点在二维表示中接近。两列共同表示位置，只用正弦会把周期中的不同位置映射为相同数值。交互项 $x_1x_2$ 则允许“重量的影响随距离变化”；它增加表达能力，也增加参数与方差，仍需验证。

构造特征时应重新检查可用时间。例如“本月总消费”用于月中预测时，必须截止预测日，不能从月底汇总表读取完整月值。数据库查询中的时间条件同样属于模型实现的一部分。

### 特征选择必须嵌入拟合过程

**特征选择**（feature selection）保留原有字段的子集，可基于方差、与标签的关系或模型系数。即使最终只用一个简单模型，若先利用所有标签挑选最相关字段，也已把验证标签泄漏到模型结构中。

设有上万列与标签无关的随机噪声，最大样本相关系数仍可能很大。若用全体样本找到这种偶然相关，再在同一批样本中划分评价，验证也继承了筛选所依赖的信息。正确流程是在每个训练子集内重新选择特征，留出部分只应用已选列。

### 目标编码与折外构造

**目标编码**（target encoding）用某类别在训练数据中的标签平均值表示类别。对类别 $c$，一种平滑形式为

$$z_c = \frac{\sum_{i:x_i=c} y_i + \alpha\,\mu}{n_c + \alpha}, \qquad \alpha > 0,$$

其中 $n_c$ 是训练中类别计数，$\mu$ 是训练标签总体均值。可写为 $\frac{n_c}{n_c+\alpha}\bar{y}_c + \frac{\alpha}{n_c+\alpha}\mu$：样本少时更接近总体均值。$\alpha$ 也要在训练与验证框架内选择。

如果每个类别只有一个样本且不平滑，那么该样本编码就等于自己的标签。这不是学到可迁移规律，而是在输入中放入答案。常见训练办法是**折外编码**（out-of-fold encoding）：把训练部分再分成若干折，对每折用其他折的标签建立映射，再转换这一折。训练模型用这些折外特征；对外部验证集使用全部训练数据拟合的映射。

> **例题 10.4：单例类别的泄漏**
>
> 训练记录类别为 A、B、C、D，标签为 0、1、0、1，每个类别只出现一次。无平滑的全训练目标编码是什么？若某一折包含 A、B，另一折包含 C、D，使用对折均值作为未知类别后备值，折外编码又是什么？

**解** 全训练编码为 $(0, 1, 0, 1)$，逐条复制标签。折外时，A、B 在另一折未见，后备均值为 $1/2$；C、D 同理，因此全部编码为 $1/2$。后者没有凭空制造区分能力，正符合四个独立新类别没有可迁移信息的设置。若内层划分也存在用户或时间约束，编码的折划分必须遵守同样约束；普通随机折不能解决所有目标泄漏。

平滑只能减弱直接复制，不能自动消除自身标签参与编码。折外编码也不能修复类别本身来自未来信息的问题。完整外层验证必须覆盖整个编码与建模过程，而不是只验证最终回归器。

## 10.6 Pipeline 与按列处理

**scikit-learn** 是提供常用机器学习模型、数据处理与评价接口的 Python 库，不是一个单独算法。它通常用估计器对象保存拟合状态，`fit` 返回拟合后的对象，回归器的 `predict` 生成预测。第 3 章的实例、属性与方法知识在这里直接应用。

**流水线**（Pipeline）把顺序步骤连接起来。训练时，前面的转换器逐个拟合并变换，最后拟合预测器；预测时，前面只变换，最后预测。**列转换器**（ColumnTransformer）让

数值列和类别列分别进入不同处理分支，再合并结果。

```
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler
numeric = Pipeline([
    ('fill', SimpleImputer(strategy='median')),
    ('scale', StandardScaler())
])
```

名称 `fill` 与 `scale` 用于查看状态和设置参数；它们不是随意排列的注释。先填补再标准化表示均值与尺度基于填补后的训练数组。若改为另一种顺序，状态定义可能改变，应重新验证。

对每次交叉验证，必须复制一个尚未拟合的完整流水线，并在该折训练数据上拟合所有步骤。Pipeline 帮助约束调用顺序，但不会替人判断组间重叠、未来字段或错误标签。把泄漏字段装入 Pipeline 仍然会泄漏。

## 10.7 实验 10.1：检查预处理状态是否固定

入口 `ch10_pipeline.py` 需要 NumPy、pandas 和 scikit-learn，可在独立环境安装 `pip install numpy pandas scikit-learn`。实验数据由程序构造，不下载资料。训练重量为 $(1, 2, \mathrm{NaN}, 4, 5, 6)$，区域为 A、A、B、B、A、B；标签是教学费用 $(3, 5, 8, 9, 11, 13)$。验证输入有未见区域 C 以及缺失重量。

数值分支先以训练中位数填补，再标准化；类别分支先以众数填补，再独热编码。两者合并后拟合岭回归。关键外层结构为：

```
from sklearn.compose import ColumnTransformer
from sklearn.linear_model import Ridge
prep = ColumnTransformer([
    ('num', numeric, ['weight']),
    ('cat', category, ['zone'])
])
model = Pipeline([('prep', prep), ('model', Ridge(alpha=1.))])
model.fit(train, y)
prediction = model.predict(valid)
```

片段中的 `category`、`train`、`valid` 在完整脚本中定义；阅读片段时应把注意力放在对象组合与数据流。岭回归的 `alpha` 是惩罚系数，第 11 章会与本书数学记号对应。

训练非缺失重量为 1、2、4、5、6，中位数 4；填补后均值为 $22/6$。实验断言这些状态正确，验证中区域 C 对应独热块全零，并额外预测一个重量很大的新样本，检查标准化均值仍不改变。程序同时打印转换矩阵和预测值，便于逐行追踪；三条验证输入未给真实标签，所以这些预测值不能被报告为准确率或真实业务效果。

修改任务：把验证重量 10 改为 100，确认训练状态不变而预测可变化；把训练重量 6 改为 60，重新拟合后状态应变化。再把类别策略改为遇到未知类别报错，观察预

测失败位置。这些对照直接检验“训练时学习规则，预测时应用规则”。

## 10.8 实验 10.2：用户记忆造成的高分

入口 `ch10_leakage.py` 为 200 名用户分别随机分配一个二分类标签，每名用户复制成 10 条记录。模型只记忆训练中用户 ID 对应的标签，未见用户采用训练多数类。这里标签没有跨用户规律，故对新用户不能从 ID 推知标签。

实验以相同数据比较逐行随机划分和按用户分组划分。逐行划分的验证用户大多已经在训练中出现，记忆器可得到极高准确率；分组划分中用户交集为零，表现接近随机标签的多数类水平。脚本实际打印交集大小与准确率，且断言分组交集为零。有限样本下分组分数不一定恰为 0.5。

这个例子不是证明随机划分总错误。若部署任务就是为已知用户读取一个固定标签，记忆有合理用途；若要宣称能预测新用户，逐行高分就回答了错误的问题。改变预测对象会改变何种信息允许使用。

修改任务：把每人重复次数改为 1，逐行划分也不再能记忆验证用户；把标签改成随时间变化的事件，单纯 ID 字典将失效。若采用真实用户资料，应避免把个人标识直接写入输出日志；本例只使用模拟编号。

## 10.9 从数据到评价的检查顺序

实际训练前，先保存不随算法改变的样本 ID 与划分清单，再检查标签对齐、日期范围和实体交集。接着仅在训练部分拟合转换器，输出转换后形状、缺失数、类别词表和特征名称。最后训练并评价；模型比较使用相同划分和指标，才能把差异归因于候选方案。

合并数据表后尤其需要检查行数与唯一键。一个一对多关联可能把某些标签复制多次，等价于改变它们的样本权重；即使没有训练测试混用，评价人群也已改变。第 5 章的数据审计与本章的泄漏审计应共同执行。

> **知识联系与自检**
>
> 标准化是第 6 章中的坐标变换，特征构造改变第 9 章的假设空间；目标编码把统计估计变为输入，因此必须遵守标签使用边界。能否指出每个处理步骤保存了什么状态、状态来自哪些行、部署时能否得到原字段，是判断流程是否可复现的直接标准。

计算与编程答案可运行 `ch10_solutions.py` 核对。该入口验证数值与实现边界；概念题仍需依据下列推理说明判断。

## 10.10 分层练习

10.1 新病人预测中，同一病人的检查记录应如何划分？若目标为预测老病人的下一次检查，答案是否相同？

10.2 训练列 $(2,4,6)$，验证值 8，按分母 $n$ 标准化，求训练均值、方差与验证变换值。

10.3 训练列 $(1, \mathrm{NaN}, 5, 9)$ 用中位数填补，求填补值及填补后的均值。

10.4 对训练最小值 10、最大值 20，求新值 25 的最小最大缩放结果。它是否必须落在 $[0, 1]$？

10.5 有四种类别，同时使用完整独热列和截距，设计矩阵为什么秩亏？给出一个不改变预测的参数改动。

10.6 100 篇训练文档中，某词出现于 9 篇，按本章平滑 IDF 计算其权重；为何不能用测试文档更新文档频率？

10.7 类别 A 有两条标签 1、0，全训练均值 0.2，$\alpha = 3$，求平滑目标编码。它是否自动避免自身标签泄漏？

10.8 在全体样本上挑选与标签相关性最高的 10 列，再交叉验证回归器，错在哪里？写出正确操作顺序。

10.9 用此前 14 天特征预测未来 7 天总量，计划第 31 天开始前部署且标签当天结束即可获得，最后可用训练样本的预测日是哪天？

10.10 为实验 10.1 增加断言：预测新批次前后训练中位数和编码词表完全相同。说明应比较哪些属性。

10.11 设计一个文本切片任务的无泄漏划分方案，并说明为什么按切片随机分层仍可能有问题。

10.12 数据中训练列全部缺失，而验证列非缺失。给出两种明确处理方案，说明为何不能直接用验证中位数填补训练。

## 10.11 参考答案与推理

10.1 新病人任务按病人分组，不能让同一人的记录跨集合。老病人未来预测可允许相同病人出现，但必须按时间、标签成熟期及可用字段划分；不能读取未来检查结果。

10.2 均值 4，方差 $[(2-4)^2+0+(6-4)^2]/3 = 8/3$。验证值转换为 $4/\sqrt{8/3} = \sqrt{6} \approx 2.44949$。不能用验证值重新估计均值。

10.3 非缺失数为 1、5、9，中位数 5，填补后为 1、5、5、9，均值 5。填补后的离差不代表恢复了原始未知值的真实变化。

10.4 $(25-10)/(20-10) = 1.5$。验证值超出训练范围允许越界；是否裁剪应事先规定并考虑信息损失。

10.5 四个独热列的和等于截距列。将截距加 $a$，四个类别权重都减 $a$，所有预测保持不变。删除一个类别列可以消除这一特定线性依赖。

10.6 $1 + \log(101/10) \approx 3.312535$。IDF 是模型输入变换的拟合状态；普通留出评价不允许测试数据参与学习。若采用明确的传导式协议，应另行说明，不能与归纳评价直接混报。

10.7 $(1 + 0 + 3 \times 0.2)/(2 + 3) = 0.32$。两条样本的标签仍参与自己的表示，平滑不等于折外构造。

10.8 特征列表已经依赖验证折的标签。每折应先划分，再在该折训练部分拟合选择器和其余变换，训练回归器，最后转换并评价该折验证部分。

10.9 第 23 天样本标签使用 24–30 天，在 31 天开始前完整；第 24 天样本需要第 31 天结果，因此不能使用。若还存在入库延迟需再提前。

10.10 保存数值分支 `fill.statistics_` 的副本，类别分支 `encode.categories_` 中各数组的副本，调用 predict 后逐项比较。不要仅比较对象身份，因为原数组可能被原地改动。

10.11 先按原始文档或同源文档簇分组，再切片；同一原文的相邻片段常共享内容，随机切片会让验证文本近似复制训练文本。词表和 IDF 也只在训练文档拟合。

10.12 可以删除该列并保存列清单，也可按业务定义以固定常数填补并增加缺失指示。两者都需解释部署时如何处理；验证中位数来自留出输入，会改变训练规则并掩盖训练期没有观测信息的事实。

# 11 线性回归、岭回归与 Lasso

**先修知识、学习目标与本章位置**

本章使用第 6 章的投影、秩与奇异值分解，第 7 章的梯度和凸性，第 9 章的风险以及第 10 章的预处理规则。目标是从手算直线拟合过渡到多元回归，推导普通最小二乘与岭回归，理解 Lasso 产生零系数的原因，并用残差和独立评价判断模型是否适用。所有公式明确区分截距与被惩罚的权重。

根据包裹重量估计费用，可以先用一条直线表示平均变化趋势。直线未必描述全部真实规律，但它便于手算、检查单位、理解误差，也为后续分类器与神经网络提供基础。线性模型的价值取决于任务是否能被所选特征的加权和近似，而不是名称中的“简单”二字。

## 11.1 从一元直线到设计矩阵

### 模型、误差与统计假设

一元线性回归写为 $\hat{y} = b + wx$，$w$ 是斜率，$b$ 是截距。若 $x$ 为千克、$y$ 为元，则 $w$ 的单位为元每千克，$b$ 的单位为元。斜率表示模型预测随输入增加一个单位的变化；它不自动具有因果含义。配送费用还可能与地区相关，遗漏地区会影响估计斜率。

多元模型为

$$\hat{y}_i = b + \sum_{j=1}^{d} x_{ij} w_j, \qquad \hat{\mathbf{y}} = X\mathbf{w} + b\mathbf{1}. \tag{11.1}$$

这里 $X \in \mathbb{R}^{n \times d}$，$\mathbf{w} \in \mathbb{R}^d$，预测为 $n$ 维。增加常数列可写成 $A = [\mathbf{1}\ X] \in \mathbb{R}^{n \times (d+1)}$，$\theta = (b, \mathbf{w}^{\mathrm{T}})^{\mathrm{T}}$，于是 $\hat{\mathbf{y}} = A\theta$。$A$ 称为**设计矩阵**（design matrix）。

要把求得的函数作为描述条件均值的统计模型，常写 $Y = b + \mathbf{X}^{\mathrm{T}}\mathbf{w} + \varepsilon$，并假设 $\mathbb{E}[\varepsilon \mid \mathbf{X}] = 0$。求解最小二乘本身不要求误差正态；讨论特定参数估计性质或区间时才需增加相应假设。同方差表示条件方差不随输入改变，独立误差表示不同记录的噪声没有相关性，二者也不是同一条件。

### 对参数线性，不要求对原输入线性

将原始 $x$ 映射为 $\phi(x) = (x, x^2, \dots, x^p)$，得到

$$f(x) = b + w_1 x + w_2 x^2 + \cdots + w_p x^p.$$

它对 $x$ 是多项式，对权重仍是线性组合，因此仍能用本章算法。也可以加入已知的正弦函数或交互项，只要系数线性出现。相反，$b + \exp(wx)$ 的参数 $w$ 在指数内部，不能直接套线性最小二乘。

增加次数扩大假设空间，使最小训练误差不增，但验证误差不必下降。高次幂还可能造成列尺度差异和病态矩阵；输入先中心化缩放可改善数值条件，但不能消除高次多项式在训练范围外急剧增长的风险。

## 11.2 一元最小二乘的完整手算

**普通最小二乘**（ordinary least squares，OLS）选择参数使残差平方和最小。本章采用便于求导的归一化目标

$$J(b,w)=\frac{1}{2n}\sum_{i=1}^{n}(b+wx_i-y_i)^2. \tag{11.2}$$

除以 $2n$ 不改变最小化解；它使梯度含 $1/n$。评价时的 MSE 仍是 $n^{-1}\sum r_i^2$，是本目标的两倍。所有正则化系数都必须与这个约定一起解释。

分别对 $b,w$ 求偏导并令其为零：

$$\sum_i (b+wx_i-y_i)=0, \qquad \sum_i x_i(b+wx_i-y_i)=0.$$

第一式给出 $b=\bar y-w\bar x$。将它代入第二式，并利用 $\sum_i(x_i-\bar x)=0$，得

$$w\sum_i (x_i-\bar x)^2=\sum_i (x_i-\bar x)(y_i-\bar y).$$

只要输入不全相同，就有

$$\hat w=\frac{\sum_i (x_i-\bar x)(y_i-\bar y)}{\sum_i (x_i-\bar x)^2}, \qquad \hat b=\bar y-\hat w\bar x. \tag{11.3}$$

若分母为零，数据没有提供区分斜率的信息；可以确定在这个固定输入处的最优预测，但无法唯一确定截距与斜率。

> **例题 11.1：三点拟合与逐项核对**
>
> 样本为 $(0,1),(1,2),(2,2)$，求最小二乘直线，并验证残差的正交条件。

**解** 均值 $\bar x=1$，$\bar y=5/3$。输入离差为 $(-1,0,1)$，目标离差为 $(-2/3,1/3,1/3)$，交叉乘积和为 $1$，输入离差平方和为 $2$。因此

$$\hat w=1/2, \qquad \hat b=5/3-1/2=7/6.$$

预测为 $(7/6,5/3,13/6)$。采用统计残差 $e_i=y_i-\hat y_i$，得到 $(-1/6,1/3,-1/6)$，其和为 $0$，且 $\sum_i x_i e_i=0$。残差平方和为 $1/6$，MSE 为 $1/18$，目标 $J=1/36$。残差采用相反符号时平方损失不变，但梯度中的符号必须相应调整。

拟合直线通过点 $(\bar x,\bar y)$，这是截距最优条件的结果。它不需要通过每个样本；相邻点之间的偏差恰好在平方损失意义下达到平衡。第 7 章的梯度下降实验曾使用相同数据，本章给出了直接解的来源。

## 11.3 矩阵梯度、正规方程与投影

### 从逐项导数到矩阵形式

写 $\mathbf r=A\theta-\mathbf y$，$J(\theta)=\frac{1}{2n}\mathbf r^{\mathsf T}\mathbf r$。对第 $j$ 个参数，链式法则给出

$$\frac{\partial J}{\partial \theta_j}=\frac{1}{n}\sum_i r_i\frac{\partial r_i}{\partial \theta_j}=\frac{1}{n}\sum_i a_{ij}r_i.$$

把所有分量排列起来：

$$\nabla_\theta J = \frac{1}{n} A^{\mathrm{T}}(A\theta - \mathbf{y}), \qquad H = \nabla_\theta^2 J = \frac{1}{n} A^{\mathrm{T}} A. \tag{11.4}$$

$A^{\mathrm{T}}$ 为 $(d+1)\times n$，乘以 $n$ 维残差得到 $d+1$ 维梯度，形状与参数一致。任意向量 $\mathbf{v}$ 满足 $\mathbf{v}^{\mathrm{T}} H \mathbf{v} = \|A\mathbf{v}\|^2/n \geq 0$，所以目标凸；若 $A$ 满列秩，Hessian 正定，解唯一。

令梯度为零得到**正规方程**（normal equations）

$$A^{\mathrm{T}} A\hat{\theta} = A^{\mathrm{T}}\mathbf{y}. \tag{11.5}$$

“正规”是方程的惯用名称，不表示误差服从正态分布。若满列秩，形式解为

$$\hat{\theta} = (A^{\mathrm{T}}A)^{-1}A^{\mathrm{T}}\mathbf{y},$$

但实际程序不应为了套公式显式求逆。

### 投影说明拟合值为何唯一

正规方程等价于 $A^{\mathrm{T}}(\mathbf{y} - A\hat{\theta}) = 0$，所以残差与 $A$ 的每一列都正交。拟合值 $A\hat{\theta}$ 是 $\mathbf{y}$ 在 $\mathrm{col}(A)$ 上的正交投影，即列空间中距离目标最近的向量。

若 $\theta_0$ 是一个解而 $A\mathbf{v} = 0$，则 $\theta_0 + \mathbf{v}$ 有相同拟合值，参数可以不唯一。但是一个向量到固定线性子空间的正交投影唯一，所以最小二乘拟合值仍唯一。对训练列空间外的新输入，等价训练参数可能给出不同预测；算法选择哪一个解因此有实际含义。

> **例题 11.2：重复列与最小范数解**
>
> 将例题 11.1 中的输入复制成两列，预测为 $b + w_1 x + w_2 x$。求全部最优参数，并给出最小欧氏范数权重。

**解** 所有最优参数满足 $b = 7/6$、$w_1 + w_2 = 1/2$。写 $w_1 = 1/4 + t, w_2 = 1/4 - t$，则 $w_1^2 + w_2^2 = 1/8 + 2t^2$，最小值在 $t = 0$，故最小范数权重为 $(1/4, 1/4)$。这不证明两个字段在现实中有完全相同的独立贡献；它只是重复输入下的一种对称解。

### 数值求解与复杂度

QR 分解和奇异值分解可以避免显式形成逆矩阵。对薄 SVD $A = U_r \Sigma_r V_r^{\mathrm{T}}$，正奇异值个数为秩 $r$，最小范数解为

$$\hat{\theta} = A^{+}\mathbf{y} = V_r \Sigma_r^{-1} U_r^{\mathrm{T}}\mathbf{y}.$$

$A^{+}$ 是伪逆。数值实现需用阈值决定极小奇异值是否视为零，故近秩亏时参数会受容差影响；这是数据条件不足的表现，不宜只报告许多位小数。

在 $n \gg d$ 的稠密情形，QR 最小二乘通常需要约 $O(nd^2)$ 运算，保存数据需要 $O(nd)$ 内存。直接构造正规方程虽常见，但满列秩时 $\kappa(A^{\mathrm{T}}A) = \kappa(A)^2$，会放大条件数。高维、稀疏或巨大数据可使用迭代方法，第 12 章讨论其计算权衡。

```
A = np.column_stack([np.ones(len(X)), X])
theta, residuals, rank, singular = np.linalg.lstsq(A, y, rcond=None)
prediction = A @ theta
```

`residuals` 可能因秩亏或样本数不足而是空数组，不能据此认定误差为零。需要报告误差时直接计算 `y - prediction`。`rank` 和 `singular` 用于检查识别性与数值条件。

## 11.4 统计解释及其适用条件

固定设计矩阵 $A$，假设 $\mathbf{y} = A\theta_* + \boldsymbol{\varepsilon}$，$\mathbb{E}[\boldsymbol{\varepsilon} \mid A] = 0$，且满列秩，则

$$\hat{\theta} = \theta_* + (A^{\mathrm{T}}A)^{-1}A^{\mathrm{T}}\boldsymbol{\varepsilon}, \qquad \mathbb{E}[\hat{\theta} \mid A] = \theta_*.$$

如果还满足 $\mathrm{Cov}(\boldsymbol{\varepsilon} \mid A) = \sigma^2 I$，有

$$\mathrm{Cov}(\hat{\theta} \mid A) = \sigma^2 (A^{\mathrm{T}}A)^{-1}.$$

推导是线性变换的协方差公式：令 $B = (A^{\mathrm{T}}A)^{-1}A^{\mathrm{T}}$，则 $B(\sigma^2 I)B^{\mathrm{T}} = \sigma^2(A^{\mathrm{T}}A)^{-1}$。小奇异值方向的方差大，因此输入列近共线时，预测可能相似而单个系数不稳定。

如果误差条件均值不为零，例如遗漏变量与现有输入相关，上述无偏性不成立。若异方差或相关误差存在，协方差应写成 $B\Sigma B^{\mathrm{T}}$，不能仍用 $\sigma^2(A^{\mathrm{T}}A)^{-1}$。本章不把回归系数直接当因果效应，也不在未核查假设时给出参数显著性结论。

若进一步假设独立高斯误差，负对数似然中与参数有关的部分为 $\frac{1}{2\sigma^2}\|A\theta - \mathbf{y}\|^2$，因此最小二乘也是最大似然估计。这是第 8 章似然思想的具体实例；即使不接受高斯假设，平方损失仍可作为人为规定的预测目标。

## 11.5 岭回归：用连续收缩稳定估计

### 目标与截距处理

**岭回归**（ridge regression）在平方目标中加入 $L^2$ 惩罚。本书定义

$$J_\lambda(b, \mathbf{w}) = \frac{1}{2n}\|X\mathbf{w} + b\mathbf{1} - \mathbf{y}\|^2 + \frac{\lambda}{2}\|\mathbf{w}\|^2, \qquad \lambda \ge 0. \tag{11.6}$$

截距不惩罚，使整体目标平移不必付出额外成本。若把常数列与其他列一起罚，目标均值会被拉向零；这可能是某些特定先验的选择，但不是本章默认约定。

对 $b$ 求导仍得 $b = \bar{y} - \bar{\mathbf{x}}^{\mathrm{T}}\mathbf{w}$。令 $X_c = X - \mathbf{1}\bar{\mathbf{x}}^{\mathrm{T}}$，$\mathbf{y}_c = \mathbf{y} - \bar{y}\mathbf{1}$，得到中心化目标

$$J_\lambda(\mathbf{w}) = \frac{1}{2n}\|X_c\mathbf{w} - \mathbf{y}_c\|^2 + \frac{\lambda}{2}\|\mathbf{w}\|^2.$$

梯度为 $X_c^{\mathrm{T}}(X_c\mathbf{w} - \mathbf{y}_c)/n + \lambda\mathbf{w}$，所以

$$(X_c^{\mathrm{T}}X_c + n\lambda I)\widehat{\mathbf{w}} = X_c^{\mathrm{T}}\mathbf{y}_c. \tag{11.7}$$

当 $\lambda > 0$，任意非零 $\mathbf{v}$ 对应二次型为 $\|X_c\mathbf{v}\|^2 + n\lambda\|\mathbf{v}\|^2 > 0$，故系数矩阵正定，即使原输入秩亏也有唯一权重解。

**例题 11.3：一元岭回归的手算**

沿用三点数据，取本章 $\lambda = 1$，求不惩罚截距的岭回归。

**解** 中心化后 $\sum x_{ci}^2 = 2$，$\sum x_{ci}y_{ci} = 1$，样本数 3，因此 $w = 1/(2+3) = 1/5$，$b = 5/3 - 1/5 = 22/15$。未正则化斜率为 1/2，现在收缩为 1/5；截距相应调整，使直线仍通过 $(1, 5/3)$。把分母写成 $2+1$ 就是忘记了目标中的 $1/n$。

### 奇异值方向上的收缩

设 $X_c = U_r \Sigma_r V_r^{\mathrm{T}}$，则

$$\widehat{\mathbf{w}}_\lambda = \sum_{j=1}^{r} \frac{\sigma_j}{\sigma_j^2 + n\lambda} (\mathbf{u}_j^{\mathrm{T}} \mathbf{y}_c) \mathbf{v}_j.$$

OLS 对应因子 $1/\sigma_j$，岭相当于再乘 $\sigma_j^2/(\sigma_j^2 + n\lambda)$。小奇异值方向收缩更明显，因为这些方向由数据提供的信息较弱。收缩可降低方差，同时引入偏差；选择强度需要在独立验证中比较风险。

若 $X_c$ 的列满足 $X_c^{\mathrm{T}} X_c / n = I$，岭解简化为 $\widehat{\mathbf{w}} = \mathbf{z}/(1+\lambda)$，其中 $\mathbf{z} = X_c^{\mathrm{T}} \mathbf{y}_c / n$。一般输入列相关时，不能直接逐坐标把 OLS 系数除以 $1+\lambda$，必须在正确的特征方向上考虑耦合。

### 尺度与先验解释

将一列 $x$ 改为 $100x$，同样预测只需把权重缩小 100 倍，其平方惩罚却缩小 10000 倍。因而未缩放特征上的岭回归偏好依赖单位。通常先用训练统计量标准化，再调 $\lambda$；有明确物理尺度或先验时也可采用不同坐标的惩罚权重。

第 8 章讨论过高斯先验。若噪声方差为 $\sigma^2$，权重独立先验 $N(0, \tau^2)$，负对数后验的参数相关部分为

$$\frac{1}{2\sigma^2} \lVert X_c \mathbf{w} - \mathbf{y}_c \rVert^2 + \frac{1}{2\tau^2} \lVert \mathbf{w} \rVert^2.$$

乘以 $\sigma^2/n$，本章 $\lambda = \sigma^2/(n\tau^2)$。这个关系依赖目标归一化和先验条件，并不是所有库中名为 alpha 或 weight_decay 的数值都具有相同含义。

## 11.6 Lasso：非光滑惩罚与稀疏性

### 为什么零点需要单独分析

**Lasso**（least absolute shrinkage and selection operator）采用 $L^1$ 惩罚：

$$J_\lambda(b, \mathbf{w}) = \frac{1}{2n} \lVert X\mathbf{w} + b\mathbf{1} - \mathbf{y} \rVert^2 + \lambda \sum_{j=1}^{d} |w_j|. \tag{11.8}$$

截距仍不惩罚，可先中心化。绝对值在零点不可导，直接写 $\operatorname{sign}(0) = 0$ 并令普通梯度为零，会漏掉一个区间的最优可能。

凸函数的**次梯度**（subgradient）$g$ 满足 $h(v) \geq h(w) + g(v - w)$，即以斜率 $g$ 画出的直线不超过函数。对 $|w|$，正点的次梯度为 1，负点为 $-1$，零点所有 $[-1, 1]$ 都满足条

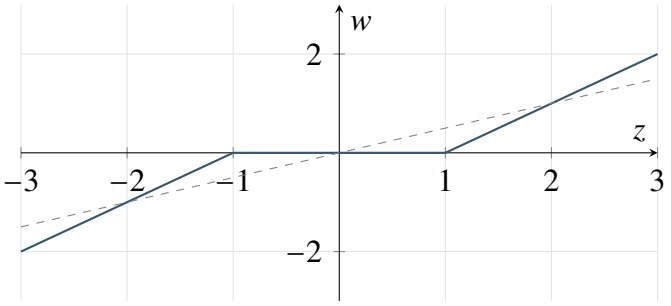
件。凸目标在某点最小化的条件是其次梯度集合包含 0。

### 一维软阈值的分段推导

考虑 $q(w)=\tfrac12(w-z)^2+\lambda|w|$。若 $w>0$，导数 $w-z+\lambda=0$，解 $w=z-\lambda$，只有 $z>\lambda$ 才位于正半轴。若 $w<0$，导数 $w-z-\lambda=0$，解 $w=z+\lambda$，只有 $z<-\lambda$ 才成立。若 $w=0$，条件 $0\in -z+\lambda[-1,1]$ 等价于 $|z|\le\lambda$。因此

$$S_\lambda(z)=\operatorname{sign}(z)\max(|z|-\lambda,0)=\begin{cases} z-\lambda, & z>\lambda,\\ 0, & |z|\le\lambda,\\ z+\lambda, & z<-\lambda. \end{cases} \tag{11.9}$$

这个函数称为**软阈值**（soft thresholding）。它既把小量归零，又把保留的大量向零缩小；不同于只决定保留或删除、保留时不改幅度的硬阈值。




图中实线为 $\lambda=1$ 的软阈值，虚线为相同 $\lambda$ 下正交设计的岭收缩 $z/2$。Lasso 在一段输入区间内恰为零；岭通常连续缩小而不产生精确零系数。

> **例题 11.4：正交设计下的岭与 Lasso**
>
> 设输入已中心化且 $X^{\mathrm T}X/n=I$，$\mathbf z=X^{\mathrm T}\mathbf y/n=(3,0.4)^{\mathrm T}$，取 $\lambda=0.5$。分别求 OLS、岭与 Lasso 权重。

**解**　展开平方损失为 $\tfrac12\mathbf w^{\mathrm T}\mathbf w-\mathbf z^{\mathrm T}\mathbf w+\text{const}$，可分解为逐坐标 $\tfrac12(w_j-z_j)^2$ 加常数。因此 OLS 为 $(3,0.4)$；岭为 $(2,4/15)$；Lasso 为 $(2.5,0)$。这里的逐坐标软阈值依赖正交条件，不能对一般 OLS 结果直接软阈值就声称得到 Lasso 解。

## 11.7　坐标下降与最优性核对

### 固定其他坐标，精确更新一个坐标

一般设计下，**坐标下降**（coordinate descent）轮流优化一个权重，其余保持不变。设数据已中心化，去除第 $j$ 列贡献后的部分残差为

$$\mathbf r^{(j)}=\mathbf y-X\mathbf w+\mathbf x_j w_j,$$

这里 $\mathbf x_j\in\mathbb R^n$ 表示第 $j$ 个特征列，区别于此前按下标 $i$ 表示的样本向量。与 $w_j$ 有关的目标为

$$\frac{1}{2n}\|\mathbf r^{(j)}-\mathbf x_j w_j\|^2+\lambda|w_j|=\frac{a_j}{2}w_j^2-c_jw_j+\lambda|w_j|+\text{const},$$

其中 $a_j = \|\mathbf{x}_j\|^2/n$，$c_j = \mathbf{x}_j^{\mathrm{T}}\mathbf{r}^{(j)}/n$。当 $a_j > 0$，分段求导或套软阈值可得

$$w_j \leftarrow S_\lambda(c_j)/a_j. \tag{11.10}$$

若该列全零，数据损失与此权重无关，$\lambda > 0$ 时取零最优；$\lambda = 0$ 时取零作为最小范数约定。更新后再处理下一列，新的残差必须反映已更新权重。

教学实现每次重新计算 $X\mathbf{w}$，一轮 $d$ 个坐标约需 $O(nd^2)$；维护残差并以 $\mathbf{r} \leftarrow \mathbf{r} - \mathbf{x}_j\Delta w_j$ 更新，可降到每轮约 $O(nd)$。应先理解直观实现，再优化缓存，避免残差更新符号错误。

### KKT 条件与停止标准

记平滑部分梯度 $\mathbf{g} = X^{\mathrm{T}}(X\mathbf{w} - \mathbf{y})/n$。Lasso 的凸最优性条件为

$$\begin{cases} g_j + \lambda\,\mathrm{sign}(w_j) = 0, & w_j \neq 0, \\ |g_j| \le \lambda, & w_j = 0. \end{cases}$$

这是本问题的 **Karush–Kuhn–Tucker 条件**（KKT 条件）的具体形式，可直接用数值验证。只检查相邻两轮权重差很小有时不够，尤其是特征强相关、收敛很慢时；还应检查目标、最优性残差和最大迭代次数。

全部权重为零最优的充分必要条件是 $\lambda \ge \max_j |\mathbf{x}_j^{\mathrm{T}}\mathbf{y}|/n$，前提是中心化且目标按本章定义。因而可以从这个 $\lambda_{\max}$ 开始逐渐减小，形成**正则化路径**：每个强度对应一组系数，而不是一次迭代中的学习率变化。

> **例题 11.5**：检查一个零系数是否合理
>
> 某候选 Lasso 解为 $(2.5, 0)$，平滑梯度为 $(-0.5, -0.4)$，$\lambda = 0.5$。判断是否满足最优性条件；若第二个梯度变成 $-0.7$ 呢？

**解** 第一维非零，$-0.5 + 0.5 \times 1 = 0$；第二维为零且 $|-0.4| \le 0.5$，所以满足全部凸最优性条件。若第二梯度为 $-0.7$，绝对值大于阈值，沿第二维正方向的小变化可使目标下降，因此不能停止。

### 相关特征、稀疏解释与 Elastic Net

若两个特征高度相关，Lasso 可能保留其中一个，轻微数据变化就切换选择；被保留的变量不一定是唯一真实原因。完全重复列可造成权重分配不唯一，但预测仍可能稳定。岭倾向分摊权重，Lasso 偏好稀疏，两者都不能独立完成因果变量发现。

**弹性网**（Elastic Net）结合 $\lambda_1\|\mathbf{w}\|_1 + \frac{\lambda_2}{2}\|\mathbf{w}\|^2$。在坐标更新中，分子仍为 $S_{\lambda_1}(c_j)$，分母变成 $a_j + \lambda_2$。当 $\lambda_2 > 0$ 时权重目标严格凸，可改善相关列下的唯一性。它多出一个权衡设置，也增加验证工作；不应仅因名称更复杂而优先采用。

## 11.8 残差、指标与模型适用边界

### MAE、MSE、RMSE 与 R 平方

对 $m$ 条评价记录，统计残差 $e_i = y_i - \hat{y}_i$，定义

$$\mathrm{MAE} = \frac{1}{m}\sum_i |e_i|, \quad \mathrm{MSE} = \frac{1}{m}\sum_i e_i^2, \quad \mathrm{RMSE} = \sqrt{\mathrm{MSE}}.$$

平方指标更强调大误差；RMSE 与 MAE 有原始单位，但不表示二者偏好同一个模型。一个方案大多数误差小、少数误差极大，可能 MAE 较低而 RMSE 较高。

对于评价标签非常数，**决定系数** $R^2$ 定义为

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y}_{\mathrm{eval}})^2}. \tag{11.11}$$

分母使用当前评价集合的均值，作为定义上的参照，并不意味着可以把这个未知均值用于部署预测。训练得到的均值基线应另行保存并在测试上评价。$R^2$ 可以为负，表示平方误差比评价集合均值这个参照更大；不应裁为 0 掩盖问题。

若标签全部相同，分母为零，数学上的比值未定义。不同库可能给出非有限值或以便于模型搜索的约定替代，报告时应明确，不能把默认输出当作普遍定义。训练集含截距 OLS 且目标非常数时，$R^2$ 在 $[0, 1]$；这一性质不推广到任意测试集。

> **例题 11.6：负的测试 R 平方**
>
> 测试目标为 $(1, 2, 3)$，预测均为 0。计算 MSE、RMSE、MAE 与 $R^2$。

**解** 平方和 14，MSE 为 $14/3$，RMSE 为 $\sqrt{14/3} \approx 2.16025$，MAE 为 2。测试均值 2，总离差平方和 2，故 $R^2 = 1 - 14/2 = -6$。这不是计算错误，而是预测远差于定义中的均值参照。

### 残差图能提供什么信息

画残差对预测值、关键输入和时间的散点图。若呈弯曲趋势，线性表达可能遗漏非线性；若呈漏斗形，误差波动可能随预测水平变化；若相邻时间残差同向，可能存在序列依赖；孤立极大残差需要核查数据或罕见机制。

这些图给出需要检验的线索，不能仅凭外观确定唯一原因。模型选择阶段可据验证残差调整特征，再用独立测试评价；若不断查看最终测试残差来修改模型，原测试已参与选择，需要新的独立评价。

### 外推、杠杆与解释边界

训练重量集中在 1–5 千克，直线对 50 千克的输出属于**外推**（extrapolation）。没有数据支持该区间的关系，数学上可以计算不代表预测可靠。高次多项式尤其可能在边界外迅速偏离。

对于满列秩 OLS，帽子矩阵 $H_A = A(A^{\mathrm{T}}A)^{-1}A^{\mathrm{T}}$ 把标签映射为拟合值。对角元 $h_{ii}$ 称为杠杆值，反映输入位置对拟合的潜在影响。高杠杆点可能把模型拉向自己而获得很

小的训练残差，因此“残差小”不必然表示这条记录无问题。实际影响还与残差和其他数据有关。

线性系数解释应限定为其他已纳入变量固定时的模型变化。若输入经过标准化，权重对应增加一个训练标准差；若包含交互项，单一主效应权重不能独立描述全域变化。预测、关联和因果解释应分别表述。

## 11.9 实验 11.1：直接解、岭系数与库实现

入口 `ch11_regression.py` 使用 NumPy 和 scikit-learn。实验先拟合例题三点数据，再在 $\lambda = 0, 0.2, 1$ 下比较本书求解与库实现。自实现采用增广最小二乘：

$$\left\| \begin{bmatrix} X_c \\ \sqrt{n\lambda} I \end{bmatrix} \mathbf{w} - \begin{bmatrix} \mathbf{y}_c \\ \mathbf{0} \end{bmatrix} \right\|^2 = \|X_c\mathbf{w} - \mathbf{y}_c\|^2 + n\lambda\|\mathbf{w}\|^2.$$

它与目标乘以 $2n$ 后一致，不显式求逆。零惩罚时可自然退回最小范数解。完整函数检查输入形状、非有限值和负惩罚。

```
xm = X.mean(axis=0)
ym = y.mean()
Z = X - xm
aug = np.vstack([Z, np.sqrt(len(y)*lam)*np.eye(X.shape[1])])
target = np.r_[y-ym, np.zeros(X.shape[1])]
w = np.linalg.lstsq(aug, target, rcond=None)[0]
b = ym - xm @ w
```

scikit-learn 的 Ridge 采用平方和加 `alpha` 乘权重平方和的目标，故本书应传入 `alpha=n*lam`，而不是直接传 `lam`。实验逐项断言截距与系数相同，容差为 $10^{-12}$；换不同线性代数环境时可放宽到 $10^{-9}$。

预期 OLS 截距 $7/6$、斜率 $1/2$；$\lambda = 0.2$ 的斜率为 $1/2.6 = 5/13$；$\lambda = 1$ 的斜率为 $1/5$。重复列 OLS 最小范数解为 $(1/4, 1/4)$。原三点拟合 MAE 为 $2/9$，MSE 为 $1/18$，RMSE 约 $0.235702$，$R^2 = 0.75$。

修改任务：将所有目标加 100，不罚截距时权重不变、截距加 100；把一列输入乘 100，检查未标准化岭解并不简单按逆比例变化。再制造一个常数输入列，确认程序不因除以输入离差平方和而报错。比较预测与目标值，不只比较参数，以免忽略秩亏下的等价解。

## 11.10 实验 11.2：从零实现 Lasso 坐标下降

入口 `ch11_lasso.py` 使用一个四行两列的中心化正交设计：

$$X=\begin{bmatrix}1 & 1\\ 1 & -1\\ -1 & 1\\ -1 & -1\end{bmatrix},\qquad \mathbf{y}=X\begin{bmatrix}3\\ 0.4\end{bmatrix}.$$

每列均值为零且 $X^{\mathrm{T}}X/4=I$，因此已知精确解可核对算法。取 $\lambda=0.5$，结果应为 $(2.5,0)$，平滑梯度为 $(-0.5,-0.4)$。

```
for j in range(X.shape[1]):
    partial = y - X @ w + X[:, j] * w[j]
    a = np.mean(X[:, j] ** 2)
    c = np.mean(X[:, j] * partial)
    w[j] = soft(c, lam) / a if a > 0 else 0.
```

完整函数明确要求 $X,y$ 已中心化，若不满足则报错；本例不悄悄惩罚或遗漏截距。scikit-learn 的 Lasso 目标含 $1/(2n)$ 的平方项，因此其 `alpha` 恰等于本书 $\lambda$；这与 Ridge 的映射不同。程序与 `Lasso(alpha=lam, fit_intercept=False)` 对照，并分别验证非零、零系数的 KKT 条件。

修改任务：将第二列改成第一列加少量扰动，重新中心化后比较不同列顺序的结果和收敛速度；将 $\lambda$ 提高到 3，全部权重应为零。对于一般相关数据，不要求坐标下降经过一轮就收敛。若达到最大迭代数，脚本显式报错而不是把未收敛参数标成正确答案。

## 11.11 多元回归的手算：相关列如何共同决定系数

一元公式容易使人误以为多元回归只需对每列分别回归。实际上，只要列相关，每个系数都依赖其他列。考虑已经中心化的两列输入

$$X=\begin{bmatrix}-1 & -1\\ 0 & 1\\ 1 & 0\end{bmatrix},\qquad \mathbf{y}=\begin{bmatrix}-2\\ 1\\ 1\end{bmatrix}.$$

这里 $n=3,d=2$，列均值和目标均值均为零，因此最优截距为零。逐项内积给出

$$X^{\mathrm{T}}X=\begin{bmatrix}2 & 1\\ 1 & 2\end{bmatrix},\qquad X^{\mathrm{T}}\mathbf{y}=\begin{bmatrix}3\\ 3\end{bmatrix}.$$

正规方程为 $2w_1+w_2=3$、$w_1+2w_2=3$，相减得 $w_1=w_2$，代回得两者都为 1，预测恰为 $\mathbf{y}$。如果分别单独回归，两列各得到斜率 $3/2$；把两条单变量斜率拼起来会得到错误预测，因为共同变化被重复计算。

这也说明回归系数具有条件解释：多变量系数描述固定其他已纳入列时的变化，单变量系数吸收了与其他列共同变化的部分。此处没有使用任何因果假设，因此只能解释模型的条件关联。

同一设计的岭回归取 $\lambda = 1/3$，于是 $n\lambda = 1$。方程变成

$$\begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \mathbf{w} = \begin{bmatrix} 3 \\ 3 \end{bmatrix},$$

由对称性得两权重均为 3/4。原始平方误差从 0 增加到 $\|(1/4)\mathbf{y}\|^2 = 3/8$，但平方范数从 2 减到 9/8。总目标从 OLS 参数处的 1/3 降到岭解处的 1/4：数据项为 $(3/8)/6 = 1/16$，惩罚项为 $(1/6)(9/8) = 3/16$，两者相加为 1/4。优化器是在降低完整目标，而不是要求数据误差单独下降。

## 11.12 岭回归的偏差与方差可以同时算清

对一个中心化特征方向，设 $s = \sum_i x_i^2 > 0$，真实生成方式为 $y_i = x_i w_* + \varepsilon_i$，固定输入下误差独立、均值 0、方差 $\sigma^2$。岭解为

$$\widehat{w}_\lambda = \frac{s w_* + \sum_i x_i \varepsilon_i}{s + n\lambda}.$$

对噪声取期望，估计均值为 $s w_*/(s + n\lambda)$，故偏差为 $-n\lambda w_*/(s + n\lambda)$。利用独立误差的方差相加，得到

$$\operatorname{Var}(\widehat{w}_\lambda) = \frac{\sigma^2 s}{(s + n\lambda)^2}.$$

于是权重估计的均方误差为

$$\mathbb{E}[(\widehat{w}_\lambda - w_*)^2] = \frac{(n\lambda)^2 w_*^2 + \sigma^2 s}{(s + n\lambda)^2}. \tag{11.12}$$

它是偏差平方与方差之和；这里讨论的是参数误差。若新输入 $X'$ 与训练噪声独立且二阶矩为 $v$，对应条件均值预测误差再乘以 $v$；若评价带噪声的新标签，还要加上新标签的不可约噪声项。

取 $s = 4, n = 4, w_* = 1, \sigma^2 = 4$。OLS 方差为 1、偏差为零，参数均方误差为 1。取 $\lambda = 1$ 后偏差为 $-1/2$，方差为 $16/64 = 1/4$，总均方误差为 1/2。这个具体模型展示了引入偏差仍能降低总误差。若噪声方差为零，同样的收缩却会把原来准确的系数拉偏，因此不存在不看数据条件就永远更好的正则强度。

未知真实 $w_*$ 与 $\sigma^2$ 时，不能直接拿上述理论式完成调参。它用于解释机制；实际选择仍应在符合部署目标的验证数据上进行。若输入方向相关，需在特征分解后的方向中分析，不能将每个原始坐标当成独立的一元问题。

## 11.13 实验 11.3：特征次数、正则强度与最终测试

前两个实验核对求解是否正确，本实验增加一个完整的模型选择过程。入口 `ch11_selection.py` 使用相同依赖，固定种子 1104，生成训练 60 条、验证 60 条、测

试 400 条。输入均从 $[-2,2]$ 均匀抽样，目标为

$$Y = 1 + 0.5X + 0.8X^2 + \varepsilon, \qquad \varepsilon \sim N(0, 0.35^2),$$

所有记录独立，三个子集采用同一生成分布。数据生成规律为教学已知条件，但选择代码只读取训练和验证来决定方案。

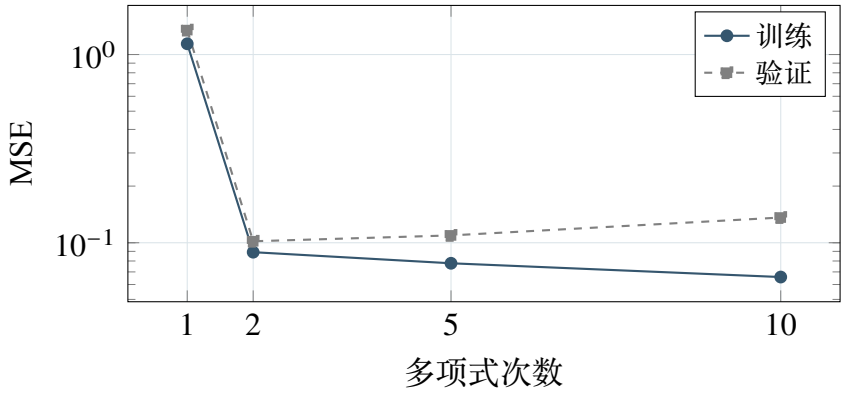
候选次数为 1、2、5、10，惩罚强度为 0、0.001、0.1、1，共 16 组。每组重新建立“多项式特征—标准化—岭回归”流水线；不重复添加常数特征，截距由回归器负责。标准化在幂次展开之后拟合，因为 $x$ 和 $x^{10}$ 的尺度差异很大。

```
pipe = Pipeline([
    ('poly', PolynomialFeatures(degree, include_bias=False)),
    ('scale', StandardScaler()),
    ('ridge', Ridge(alpha=len(y)*lam, solver='svd'))
])
pipe.fit(X, y)
validation_mse = np.mean((pipe.predict(V) - v) ** 2)
```

程序记录训练与验证 MSE，按最小验证值选定一组。若严格相等，循环中先出现的候选保留；复杂度优先的容差规则也是合理选择，但必须事先规定，不能在看完测试后改变。选定模型在原 60 条训练数据上保持不动，最后只对测试集评价一次。也可以事先规定选定超参数后用训练加验证重拟合，但那是另一个最终训练协议，不能与本实验混报。

本次实测选中次数 10、$\lambda = 0.001$，验证 MSE 约 0.101639；次数 2、$\lambda = 0$ 的验证 MSE 约 0.101831，两者非常接近。真实生成均值是二次函数，有限验证集仍可能选择更复杂的候选。这不是程序错误，而是有限样本模型选择的波动；不能由这次排名推断十次多项式更接近真实机制。

选定方案测试 MAE 约 0.314445、RMSE 约 0.389134、$R^2$ 约 0.887756。程序把全部候选表写入 `ch11_results/selection.csv`，把固定最终预测与残差写入 `residuals.csv`。这些数值仅属于固定教学数据，不能在真实任务中直接作为效果承诺。




图只展示 $\lambda = 0$ 的四个候选，纵轴采用对数尺度。增加次数使训练误差下降，但验证

误差在二次以后回升；它说明这一固定抽样中的现象，不是所有随机种子下的必然曲线。加入正则化后各次数的相对次序还会变化，完整结果应查看 16 行候选表。

修改任务：只改变训练样本数，保留生成分布与预先规定的候选，观察选择波动；另建一个专门的外推实验，使测试输入位于 $[2,3]$，并明确将其报告为分布改变的评价。原测试结果一旦用于设计下一方案，就不能继续把它当作未接触的最终测试。

## 11.14 方法比较与知识联系

| 方法 | 主要偏好 | 需要关注 | 本章解法 |
|---|---|---|---|
| OLS | 最低训练平方损失 | 秩亏、噪声和外推 | QR、SVD |
| 岭 | 连续缩小权重 | 尺度、惩罚强度 | 增广最小二乘 |
| Lasso | 缩小并产生零系数 | 相关列、选择不稳定 | 坐标下降 |
| 弹性网 | 稀疏兼顾连续收缩 | 两类惩罚的验证 | 修改坐标更新 |

三种回归应在相同数据划分和评价指标上比较，标准化也必须纳入训练流程。低训练误差不能替代第 9 章的总体目标；某个稀疏系数表也不能替代第 10 章的数据可用性检查。第 12 章将在同一个平方目标上比较迭代训练方式，让“求什么”和“怎样求”保持清楚的联系。

计算与编程答案可运行 `ch11_solutions.py` 核对。该入口验证数值与实现边界；概念题仍需依据下列推理说明判断。

## 11.15 分层练习

11.1 判断 $b + w_1 x + w_2 \sin x$ 与 $b + \sin(wx)$ 哪个是对参数线性的模型，说明理由。

11.2 手算点 $(0,2),(1,3),(2,5)$ 的 OLS 截距、斜率与残差。

11.3 从逐样本平方目标推导 $\nabla_b J$、$\nabla_{\mathbf{w}} J$，核对维度。

11.4 证明含不罚截距的 OLS 与岭回归在训练集上的残差和为零。Lasso 是否也满足？

11.5 本章 $n = 20, \lambda = 0.3$，调用 Ridge 与 Lasso 分别传什么 alpha？若损失改成平方和除以 2，系数映射如何变化？

11.6 中心化单列数据满足 $\sum x_i^2 = 8, \sum x_i y_i = 12, n = 4$，取 $\lambda = 0.5$，求 OLS、岭、Lasso 系数。

11.7 证明 Lasso 全零解条件，并解释为什么截距应先中心化处理。

11.8 $z = (-2, 0.3, 1.5)$，求 $S_{0.5}(z)$；同强度正交岭解是什么？

11.9 测试目标 $(2,2,2)$，预测 $(1,2,3)$，计算 MAE、MSE 并讨论 $R^2$。

11.10 解释为何特征乘 100 会改变岭的偏好；给出保持预测与惩罚都不变的惩罚权重调整。

11.11 将实验 11.2 加入一个全零列，验证它的系数为零，并检查 KKT 条件。

11.12 为强相关设计比较 OLS、岭、Lasso：必须保存哪些条件，怎样避免把测试集当成选择正则强度的工具？

## 11.16 参考答案与推理

11.1 第一式的已知特征为 $x, \sin x$，未知参数线性出现；第二式中 $w$ 位于非线性正弦内部，不属于线性参数模型。

11.2 $\bar{x} = 1, \bar{y} = 10/3$，交叉离差和 3，输入离差平方和 2，故 $w = 3/2, b = 11/6$。预测 $(11/6, 10/3, 29/6)$，统计残差 $(1/6, -1/3, 1/6)$，平方和为 $1/6$。

11.3 令 $\mathbf{r} = X\mathbf{w} + b\mathbf{1} - \mathbf{y}$，有 $\nabla_b J = \mathbf{1}^{\mathrm{T}}\mathbf{r}/n$ 为标量，$\nabla_{\mathbf{w}} J = X^{\mathrm{T}}\mathbf{r}/n$ 为 $d$ 维。每个残差通过对应输入导数贡献到权重梯度。

11.4 对截距求偏导只涉及平方损失，最优时 $\sum_i (\hat{y}_i - y_i) = 0$。Lasso 虽然权重处非光滑，截距方向仍可微且不受罚，所以同样成立；如果截距被罚或模型受其他约束，结论需重审。

11.5 原约定 Ridge 取 6，Lasso 取 0.3。若新目标写为 $\frac{1}{2}\mathrm{SSE} + \frac{\lambda}{2}\|w\|^2$，Ridge 取 $\lambda$；若写为 $\frac{1}{2}\mathrm{SSE} + \lambda\|w\|_1$，Lasso 取 $\lambda/n$。先写目标再映射，不能只认变量名。

11.6 OLS 为 $12/8 = 1.5$。岭为 $12/(8 + 4 \times 0.5) = 1.2$。Lasso 有 $a = 2, c = 3$，系数 $S_{0.5}(3)/2 = 1.25$。

11.7 零点平滑梯度为 $-X_c^{\mathrm{T}}\mathbf{y}_c/n$，零系数 KKT 条件要求每个分量绝对值不超过 $\lambda$，合起来就是最大值条件。未中心化时先确定截距，不能把目标均值误当需要稀疏惩罚的信号。

11.8 软阈值为 $(-1.5, 0, 1)$，岭为 $(-4/3, 0.2, 1)$。第三个分量巧合相等，其他分量体现两种收缩的区别。

11.9 MAE 为 $2/3$，MSE 为 $2/3$。总离差平方和 0，所以标准 $R^2$ 未定义；应报告标签常数及实际绝对或平方误差，不掩盖为普通可比较分数。

11.10 $x' = 100x, w' = w/100$ 保持乘积不变，但 $w'^2 = w^2/10000$。要保持这一列原惩罚，应对 $w'^2$ 使用原来 10000 倍的系数；统一标准化是另一种明确坐标尺度的做法。

11.11 追加零列后 $a_j = 0$，代码选择零；该列梯度也是 0，满足零系数条件。对照库预测与原结果一致，而不是因除零得到 NaN。

11.12 保存生成种子、样本划分、相关程度、噪声、训练缩放状态、候选系数与指标。只在验证部分选强度，锁定后一次测试；多次模拟可比较系数波动与预测风险，不能用单次漂亮系数表证明稳定选择。

# 12 优化算法与训练诊断

**先修知识、学习目标与本章位置**

本章接续第 7 章的梯度下降、第 9 章的学习目标和第 11 章的回归梯度。学习目标是正确实现全批量、随机和小批量更新，推导动量及自适应优化器，区分 Adam 的耦合惩罚与 AdamW 的衰减，并通过受控实验定位训练失败。这里先用可检查的凸目标理解机制；深度网络的非凸性与特定训练技巧在第 24、25 章继续展开。

同一个模型和同一个损失，可以用不同算法训练。直接最小二乘可作为线性回归的小规模参照，但数据量或模型结构变化后，解析解未必适用。迭代算法每次只利用部分信息更新参数，计算更灵活，同时引入步长、批量、状态与停止规则等新选择。理解这些选择，首先要固定“正在最小化哪个函数”。

## 12.1 训练目标与三种梯度估计

### 全批量梯度

设目标为

$$J(\theta) = \frac{1}{n}\sum_{i=1}^{n} \ell_i(\theta) + \lambda\Omega(\theta), \qquad \theta \in \mathbb{R}^p.$$

**全批量梯度下降**（batch gradient descent）每次计算全部样本梯度

$$\mathbf{g}_t = \frac{1}{n}\sum_{i} \nabla\ell_i(\theta_t) + \lambda\nabla\Omega(\theta_t), \qquad \theta_{t+1} = \theta_t - \eta_t\mathbf{g}_t.$$

这里假设所用项可微；Lasso 绝对值惩罚不可直接套普通梯度，第 11 章已有坐标下降。$\eta_t > 0$ 为学习率。线性回归一次全梯度约需 $O(nd)$ 运算，不必构造 $d \times d$ 的矩阵，适合按数据块累加。

全梯度准确描述当前经验目标，但不等于知道总体风险梯度；训练样本的有限性不会因使用全批量而消失。每一步计算多，更新次数可能少；与其他算法比较时应说明按更新步数、处理样本数还是实际耗时比较。

### 随机与小批量梯度

**随机梯度下降**（stochastic gradient descent，SGD）狭义上每步均匀抽一个样本 $I_t$，使用 $\nabla\ell_{I_t}(\theta_t)$。**小批量**（mini-batch）每步使用 $B$ 个样本：

$$\mathbf{g}_t = \frac{1}{|\mathcal{B}_t|}\sum_{i\in\mathcal{B}_t} \nabla\ell_i(\theta_t) + \lambda\nabla\Omega(\theta_t). \tag{12.1}$$

$\mathcal{B}_t$ 是当步下标集合。最后一批不足 $B$ 时，分母应使用实际批量 $|\mathcal{B}_t|$，不能仍除以固定 $B$。正则项添加一次，不要随着批量平均又除一次批量。

若在给定 $\theta_t$ 时独立、均匀、有放回抽样，则数据梯度的条件期望等于全梯度。单个梯度协方差为 $\Sigma$ 时，$B$ 个独立样本的均值协方差为 $\Sigma/B$。无放回抽样在固定参数下

另有有限总体修正；每轮洗牌后顺序访问时，参数依赖此前样本，因此不能把每一步都无条件声称为相同的独立无偏抽样。

小批量使一次计算较快、可利用矩阵运算，但噪声让当前目标不一定每步下降。较大批量通常减小梯度抽样波动，却增加内存与每步成本；当数据本身高度重复时，增加批量未必带来相同比例的新信息。

**例题 12.1：单样本梯度的平均**

模型 $\hat{y} = wx$，损失为每样本 $\frac{1}{2}(wx - y)^2$。两个样本为 $(1, 1), (2, 0)$，在 $w = 0$ 处计算全梯度、两个单样本梯度与一次步长 0.1 的更新。

**解** 单样本梯度为 $x(wx - y)$，分别为 $-1, 0$，全梯度为 $-1/2$。全梯度一步得到 $w = 0.05$。随机均匀抽一个样本，一步可能得到 0.1 或 0，两者期望为 0.05，但单次结果不必等于全批量结果。若抽样偏向第一条却没有校正权重，梯度期望也随之改变。

## 12.2 epoch、step 与训练日志

一步（step）通常指一次参数更新，一轮（epoch）指完整遍历一次训练数据。若 $n = 103, B = 16$ 且保留最后一批，一轮有 $\lceil 103/16 \rceil = 7$ 步，最后一批 7 条。丢弃最后一批时只有 6 步，且每轮有部分样本未使用；是否丢弃必须记录。

一次迭代有时指数据加载一次，有时指优化器更新一次，使用梯度累积时二者不同。日志应明确单位，例如“每 100 次参数更新验证一次”，不要只写“迭代 100 次”。学习率调度器也必须知道按步还是按轮更新。

### 平均损失必须按样本数加权

假设第一批 16 条平均损失 1，末批 4 条平均损失 3，全轮平均应为 $(16\times1+4\times3)/20 = 1.4$，不是 $(1 + 3)/2 = 2$。正确方式累计每批损失总和，再除以累计样本数。

还有一个常被忽略的区别：训练过程中每批损失对应不同参数，累加得到的是沿更新轨迹的**在线训练损失**。它不等于一轮结束后固定 $\theta$ 在完整训练集上的损失。比较训练和验证曲线时，最好在同一轮结束状态下分别重新计算两者，并标明是否包含正则项。

```
for epoch in range(epochs):
    order = rng.permutation(len(y))
    for start in range(0, len(y), batch_size):
        idx = order[start:start + batch_size]
        residual = X[idx] @ w - y[idx]
        gradient = X[idx].T @ residual / len(idx)
        w = w - learning_rate * gradient
```

该片段对应无额外惩罚、设计矩阵已包含截距列的线性模型。输入和标签通过相同 `idx` 索引；每轮只生成一个排列；分母是本批真实长度。第 3 章的副作用知识同样适用：如果将最佳参数直接赋给另一个变量，后续原地更新可能连“保存值”一起改变。

## 12.3 学习率、初始化与坐标尺度

### 学习率与曲率共同决定稳定性

第 7 章对二次目标 $J(\theta)=\frac{1}{2}\theta^{\mathrm{T}}H\theta$ 给出更新 $\theta_{t+1}=(I-\eta H)\theta_t$。若 $H$ 正定，所有特征方向收敛要求 $0<\eta<2/\lambda_{\max}(H)$。不同方向衰减因子为 $1-\eta\lambda_j$；步长在大曲率方向稳定时，小曲率方向仍可能很慢。

> **例题 12.2：同一步长下的三种现象**
> 目标 $J(w_1,w_2)=\frac{1}{2}(w_1^2+9w_2^2)$，初值 $(1,1)$。比较 $\eta=0.1,2/9,0.3$ 的特征方向更新。

**解** 更新因子分别为：0.1 时 $(0.9,0.1)$，两方向衰减；$2/9$ 时 $(7/9,-1)$，第二方向正负交替但幅度不降；0.3 时 $(0.7,-1.7)$，第二方向振荡放大。曲线出现上下震荡并不总是随机抽样造成，确定的过大步长也会产生。

非二次目标的曲率随位置变化，不能只用初始 Hessian 给出全程保证。小批量训练还包含噪声，固定步长可能在最优点附近维持波动。减小步长通常缩小波动，但也可能减慢前期进展。

### 初始化为什么有时重要、有时不重要

对满列秩线性回归，目标严格凸，充分收敛后初值不改变唯一最优解。对秩亏平方损失，梯度总在设计矩阵行空间内，初始零空间分量可能保留；从零初始化通常得到最小范数方向的解。不能把“线性模型可零初始化”直接搬到多层网络：相同隐藏单元若始终获得相同梯度，可能无法学习不同表示，第 24 章讨论打破这种对称性。

应区分初始化影响最终可达解，还是仅影响有限训练步数下的结果。比较优化器时，使用相同起点和数据顺序可减少干扰；真正评估稳定性时还要重复多个合理种子。

### 标准化是改变几何

若一列输入以米计，另一列以微米计，梯度数值差异可能很大。标准化相当于换坐标，能使狭长等高线更接近均衡。自适应优化器会对坐标调整步长，但不能保证完全抵消任意不良尺度，也不能修复由输入高度相关形成的所有耦合。先核对单位与缩放，再比较优化器，通常更容易解释结果。

## 12.4 动量：保留过去的更新方向

**动量**（momentum）引入状态 $\mathbf{v}_t$。从本节起，优化器内部状态的计数 $t$ 从 1 开始，$\mathbf{g}_t$ 在本次更新前的参数处计算，$\theta_{\mathrm{old}}$ 与 $\theta_{\mathrm{new}}$ 分别表示本次更新前后参数。本章采用

$$\mathbf{v}_t=\beta\mathbf{v}_{t-1}+\mathbf{g}_t,\qquad \theta_{\mathrm{new}}=\theta_{\mathrm{old}}-\eta\mathbf{v}_t,\quad \mathbf{v}_0=0,\ 0\le\beta<1. \tag{12.2}$$

$\beta$ 决定历史保留比例。展开得 $\mathbf{v}_t=\sum_{k=1}^{t}\beta^{t-k}\mathbf{g}_k$，所以持续同向的梯度累加，频繁变号的分量部分抵消。这可以加快平缓方向的移动并减轻某些振荡，但过大动量和学习率也可能越过最优点。

另一种常见约定为 $\mathbf{m}_t=\beta\mathbf{m}_{t-1}+(1-\beta)\mathbf{g}_t$。若其学习率与上式完全相同，更新并

不相同；在零初始状态下 $\mathbf{m}_t = (1-\beta)\mathbf{v}_t$，需要相应调整学习率才能对应。阅读库文档时应核对约定，而不只看 momentum 名称。

**例题 12.3：动量状态的两步计算**

一维，$v_0 = 0$，$w_0 = 1$，$\beta = 0.9, \eta = 0.1$，人为给定梯度序列 $g_1 = 2, g_2 = -1$。按本章约定求两步参数。

**解** $v_1 = 2, w_1 = 1 - 0.2 = 0.8$；$v_2 = 0.9 \times 2 - 1 = 0.8$，$w_2 = 0.8 - 0.08 = 0.72$。第二步当前梯度为负，但历史累积方向仍为正，参数继续减小。此处梯度序列专为核对更新机制而给定，不声称来自某个固定目标。

用 $w_t$ 表示完成第 $t$ 次更新后的参数。一维二次目标的下一步梯度为 $hw_t$，消去动量状态可得

$$w_{t+1} = (1 + \beta - \eta h)w_t - \beta w_{t-1}.$$

它是二阶递推，与普通梯度下降的一阶递推不同。分析其特征根才能判断震荡与稳定性，不能继续机械套用无动量的步长上界。

## 12.5 AdaGrad 与 RMSProp：按坐标调整更新

### AdaGrad 累计平方梯度

**AdaGrad** 为每个参数保留平方梯度累计量，所有平方、除法和平方根均逐元素进行：

$$\mathbf{s}_t = \mathbf{s}_{t-1} + \mathbf{g}_t \odot \mathbf{g}_t, \qquad \theta_{\text{new}} = \theta_{\text{old}} - \eta \frac{\mathbf{g}_t}{\sqrt{\mathbf{s}_t} + \epsilon}. \tag{12.3}$$

$\epsilon > 0$ 用于防止分母为零，本章将它放在平方根之外。长期频繁出现大梯度的坐标，其有效步长减小；稀少更新的坐标可能保留较大步长，因此对某些稀疏特征问题有用。累计量单调增加，长期训练中步长也可能变得过小。

$\mathbf{s}_t$ 并非梯度方差，因为没有减去均值平方；它是平方梯度的累计量。自适应步长也不能使错误梯度变正确，若输入和标签错位，算法只是更灵活地优化错误目标。

### RMSProp 使用遗忘平均

**RMSProp** 用指数移动平均替代无界累计：

$$\mathbf{s}_t = \rho \mathbf{s}_{t-1} + (1-\rho)\mathbf{g}_t^2, \qquad \theta_{\text{new}} = \theta_{\text{old}} - \eta \frac{\mathbf{g}_t}{\sqrt{\mathbf{s}_t} + \epsilon}, \quad 0 \le \rho < 1. \tag{12.4}$$

历史权重随时间衰减，能够适应梯度尺度变化。本章使用未中心化、无额外动量的基本版本；实际库可能提供中心化或动量选项，其状态和更新有所不同。

“均方根”来自平方平均再开根号。若梯度长期恒为 $g$，$s_t$ 逐渐接近 $g^2$，更新幅度接近 $\eta\,\mathrm{sign}(g)$，而不是原始的 $\eta g$。零初始化在初期使平方平均偏小，基本 RMSProp 通常不使用 Adam 式偏差修正，因此第一步可能较大。

**例题 12.4：AdaGrad 与 RMSProp 的第一步**

$g = (3, 4)$，初始累计量为零，$\eta = 0.1$，暂忽略 $\epsilon$。计算 AdaGrad 第一步的减量；RMSProp 取 $\rho = 0.9$ 时呢？

解　AdaGrad 累计量为 $(9, 16)$，减量为 $0.1(3/3, 4/4) = (0.1, 0.1)$。RMSProp 为 $(0.9, 1.6)$，减量两个分量均为 $0.1/\sqrt{0.1} \approx 0.316228$。两者第一步不同，不能仅因公式都除以平方平均就认为行为相同。

## 12.6　Adam：一阶平均与二阶平均

**Adam**（adaptive moment estimation）结合梯度指数平均与平方梯度指数平均。为避免索引混淆，本节令 $t = 1, 2, \ldots$ 表示当前已完成的梯度计算次数，$\mathbf{g}_t$ 在更新前参数处计算：

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1)\mathbf{g}_t, \tag{12.5}$$

$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2)\mathbf{g}_t^2, \tag{12.6}$$

$$\widehat{\mathbf{m}}_t = \mathbf{m}_t/(1 - \beta_1^t), \qquad \hat{\mathbf{v}}_t = \mathbf{v}_t/(1 - \beta_2^t), \tag{12.7}$$

$$\theta_{\text{new}} = \theta_{\text{old}} - \eta_t \frac{\widehat{\mathbf{m}}_t}{\sqrt{\hat{\mathbf{v}}_t} + \epsilon}. \tag{12.8}$$

初始 $\mathbf{m}_0 = \mathbf{v}_0 = 0$。一阶平均保留方向，二阶原始矩估计提供坐标尺度；$\mathbf{v}$ 不是中心化方差。常见超参数起点是 $\beta_1 = 0.9, \beta_2 = 0.999, \epsilon = 10^{-8}$，但学习率与其他设置仍需根据目标和数据验证。

### 偏差修正从何而来

若为了分析暂假设梯度均值恒为 $\mu$，则

$$\mathbb{E}[m_t] = (1 - \beta_1) \sum_{k=1}^{t} \beta_1^{t-k} \mu = (1 - \beta_1^t)\mu.$$

零初始化使早期平均向零偏，除以 $1 - \beta_1^t$ 可去掉这一初始化因子。平方平均同理。实际训练中梯度分布随参数变化，修正并不保证对当前瞬时均值完全无偏，也不保证非线性比值更新是无偏估计；它针对的是初始零状态的衰减效应。

**例题 12.5：手算 Adam 第一步**

一维 $w = 1, g = 2$，取 $\eta = 0.1, \beta_1 = 0.9, \beta_2 = 0.999$，忽略 $\epsilon$。求 $m_1, v_1$、修正量与新参数。

解　$m_1 = 0.2$，$v_1 = 0.004$；除以 0.1 与 0.001，得到 $\widehat{m}_1 = 2, \hat{v}_1 = 4$，更新为 $w = 1 - 0.1 \times 2/2 = 0.9$。若忘记偏差修正，第一步减量约为 $0.1 \times 0.2/\sqrt{0.004} = 0.316228$，明显不同。步数必须从 1 开始，不能在 $t = 0$ 时除以零。

Adam 常能较快降低初始目标，但不会保证对所有问题更快、更稳定或泛化更好。不同参数的更新方向经过逐坐标缩放，不再总与原始负梯度共线。比较时应让每种优

化器获得合理的学习率，而不是强迫它们共享一个可能只适合某一方法的数值。

## 12.7 权重衰减、L2 惩罚与 AdamW

对于普通 SGD，在目标中加入 $\frac{\lambda}{2}\|\theta\|^2$，梯度变为 $\mathbf{g}+\lambda\theta$，更新可写成

$$\theta_{t+1}=\theta_t-\eta(\mathbf{g}_t+\lambda\theta_t)=(1-\eta\lambda)\theta_t-\eta\mathbf{g}_t.$$

因此在这个无动量、同一学习率、同一惩罚参数集合的条件下，$L^2$ 惩罚与乘性**权重衰减**（weight decay）具有相同更新。

如果先把 $\lambda\theta$ 加进梯度再送入 Adam，惩罚项也进入一阶、二阶状态，并受到坐标自适应缩放。**AdamW** 将衰减与梯度自适应过程分开，使用不含该惩罚的损失梯度更新状态，再计算

$$\theta_{\text{new}}=(1-\eta_t\lambda)\theta_{\text{old}}-\eta_t\frac{\widehat{\mathbf{m}}_t}{\sqrt{\widehat{\mathbf{v}}_t}+\epsilon}. \tag{12.9}$$

衰减项没有混入矩估计。这里 $\lambda$ 仍通过每步 $\eta_t\lambda$ 起作用，不表示衰减完全独立于学习率或训练步数。两种算法通常不能用相同数值的系数解释成同一个静态正则目标。

> **例题 12.6：第一步也能区分耦合惩罚与衰减**
>
> 沿用 $w=1, g=2, \eta=0.1$，设 $\lambda=0.2$，忽略 $\epsilon$。比较 Adam 加 L2 梯度与 AdamW 第一步。

**解** 耦合 L2 的梯度是 2.2，Adam 第一步偏差修正后分子 2.2、分母 2.2，所以参数约为 0.9。AdamW 先有衰减因子 $1-0.1\times0.2=0.98$，数据梯度的自适应减量为 0.1，得到 0.88。差异已经出现在第一步，后续矩状态也不同。

是否衰减截距、归一化参数或其他参数组，需要显式规定。本书线性回归默认不惩罚截距；深度网络实践中也常按参数组设置，但不能从名字自动推断。保存实验时应记录优化器类型、全部超参数和参与衰减的参数集合。

## 12.8 学习率调度与早停

### 按既定规则调整步长

**学习率调度**（learning-rate schedule）改变训练过程中的 $\eta_t$。阶梯衰减每隔一定步数乘以 $\gamma\in(0,1)$；指数衰减可写 $\eta_t=\eta_0\gamma^t$；余弦形式常写

$$\eta_t=\eta_{\min}+\frac{\eta_{\max}-\eta_{\min}}{2}\left[1+\cos\left(\frac{\pi t}{T}\right)\right],\quad 0\le t\le T.$$

起点为 $\eta_{\max}$，终点为 $\eta_{\min}$，$T$ 是计划步数。**预热**（warmup）在最初一段从较小值逐步升高，再接其他规则；它改变前期更新尺度，不保证修复实现错误。

根据验证指标停滞后减小学习率属于数据驱动的调度，它使用了验证反馈，因此应与模型选择一起记录。调度器若按每步调用却把周期写成每轮数，会导致衰减速度错误。恢复训练时也要恢复调度进度，否则同一个参数检查点会接上不同轨迹。

### 早停是选择参数状态

**早停**（early stopping）在验证指标长期不改善时结束训练，并恢复历史最佳验证状态。耐心值 `patience` 表示允许连续多少次检查未改善；最小改善量 `min_delta` 避免浮点末位变化不断重置等待计数。

如果只停止而不恢复最佳参数，得到的是最后状态，不是用于报告的最佳状态。保存时必须复制数组；继续训练还需保存优化器一阶、二阶状态、步数、随机状态和调度器状态。仅为推理则主要需要模型及预处理状态。

早停使用验证集选择训练长度，所以最佳验证分数具有选择影响，仍不能替代最终独立测试。对线性平方目标，早停还会改变不同特征方向的学习程度。初值为零且 Hessian 特征值 $h > 0$ 时，沿该方向第 $t$ 步相对最优解的学习比例为 $1 - (1 - \eta h)^t$：小曲率方向学习较慢，有限步数产生一种收缩，但它与单一岭系数的形式一般不同。

## 12.9 梯度裁剪与数值稳定性

### 按整体范数裁剪

**梯度裁剪**（gradient clipping）限制异常大的更新来源。整体范数裁剪采用

$$\tilde{\mathbf{g}} = \mathbf{g} \min\left(1, \frac{c}{\|\mathbf{g}\|_2}\right), \qquad c > 0,$$

零梯度保持零。若范数超过 $c$，保持方向并缩小长度；逐元素裁剪则对每个分量截断，通常改变方向。应在更新矩状态或参数之前裁剪，并说明裁剪的是数据梯度还是已加惩罚的梯度。

梯度 $(3, 4)$ 范数为 5，阈值 2 时整体裁剪结果为 $(1.2, 1.6)$。裁剪可以避免单步剧烈跳动，却也可能掩盖损失归一化、输入单位或导数错误。若几乎每步都触发，应检查根因而不只是不断减小阈值。

### 非有限值不能靠盲目替换修复

NaN 表示无定义运算结果，Inf 表示溢出等产生的无穷值。应在输入、预测、损失、梯度和参数几个边界检查有限性，找到最早出现的位置。对数零值、指数溢出、除零、过大输入和学习率都可能是来源。

数值稳定的等价表达优先于事后裁剪。例如对数指数和可写为

$$\log \sum_j e^{z_j} = m + \log \sum_j e^{z_j - m}, \quad m = \max_j z_j,$$

避免大正数指数溢出。第 13 章会将它用于多分类损失。本章回归实验使用 float64 便于差分与直接解核对；改用更低精度时要重新评估可用的容差与动态范围。

把所有 NaN 换成 0 可能让程序继续运行，却使梯度失去原目标意义。正确诊断应保存触发批次、参数尺度和最近日志，并缩小到可以重复的最小例子。

## 12.10 训练诊断：先建立能验证的对照

**曲线提供线索，不给出唯一诊断**

| 现象 | 可能原因 | 优先核对 |
| --- | --- | --- |
| 损失爆炸或非有限 | 步长、输入尺度、数值表达 | 最早异常位置与梯度范数 |
| 剧烈震荡 | 步长大、批量噪声、动量 | 固定小批次与减小步长对照 |
| 长期近乎水平 | 梯度错、更新未执行、步长小 | 梯度检查与参数实际变化 |
| 训练低、验证高 | 过拟合、划分变化、泄漏处理不一致 | 数据分布与统一预处理 |
| 两者都高 | 模型限制、优化不足、标签问题 | 直接解、小样本拟合、对齐 |
| 验证偶尔优于训练 | 数据难度、惩罚口径、随机训练机制 | 相同参数与相同损失定义 |

训练损失与验证损失不可比时，先统一计算条件。比如训练曲线包含正则项，验证只记数据误差；或者前者是沿轨迹在线平均，后者是轮末固定模型值。这些差异可以造成表面反常，不应立即解释为模型具有特殊泛化能力。

### 从局部正确到整体有效

先用极小数据检查一次前向计算和一次参数更新，手算梯度的符号与系数；再用第 7 章中心差分检查可微目标。对于回归，可把迭代结果与直接最小二乘比较；如果连无噪声可表达的三点任务都无法拟合，应先检查程序，再调复杂超参数。

**小样本过拟合检查**是让足够表达能力的模型拟合很小的训练子集，以确认数据流与梯度链路可工作。模型有表达限制、标签相互矛盾或强正则时不应期待零误差；该检查也不评价真实泛化。对随机标签做对照有助于发现可疑泄漏，但单个结果仍需结合模型容量与样本量解释。

### 公平比较优化器

每种优化器使用相同目标、初值和数据划分，分别在验证集上选择合理的学习率。保存每步目标或每轮固定状态指标，同时记录实际耗时与处理样本数。Adam 多保存两组参数同形数组，动量保存一组，全批量算法的时间与小批量不同；只比较 200 步后的损失会忽略每步成本差异。

若只研究更新机制，可固定无噪声二次函数；若研究预测质量，应保留独立测试和重复种子。一个二次函数上某算法更快，不能推广为对深度网络、所有数据和所有资源约束都更好。

## 12.11 实验 12.1：统一接口比较六种更新

入口 `ch12_optimizers.py` 仅依赖 NumPy。每个优化器实例保存独立状态，接口为 `step(w, g)`，返回新参数。名称包括 SGD、momentum、AdaGrad、RMSProp、Adam、AdamW。目标为 $\frac{1}{2}(w_1^2 + 9w_2^2)$，起点 $(2, 2)$，梯度 $(w_1, 9w_2)$，执行 200 步。

为观察机制，脚本给各方法设置不同的演示学习率：SGD 为 0.1，动量 0.05，AdaGrad 为 0.3，RMSProp 为 0.05，Adam 与 AdamW 为 0.1；RMSProp 平方平均系数 0.9，Adam 二阶系数 0.999；AdamW 衰减 0.01。这些不是调参后的性能排名，AdamW 还改变了更新规则，不应将输出表当作严格同目标最优化竞赛。

程序打印最终参数与目标，检查均有限且比初始目标 20 小。另用例题 12.5、12.6 的固定梯度核对 Adam 第一步 0.9、AdamW 第一步 0.88，容差 $10^{-8}$ 包含 $\epsilon$ 的影响。接近最优点时 RMSProp 可能维持小幅震荡，这是固定学习率与自适应分母共同作用的例子。

修改任务：把 SGD 学习率改为 0.3，核对第二方向发散；把 AdaGrad 训练步数增加，观察累计平方量如何限制后续步长；对每种算法增加一列参数更新范数。比较不同学习率时，每次新建优化器，不能让旧矩状态残留到新实验。

## 12.12 实验 12.2：小批量训练与最佳状态恢复

入口 `ch12_training.py` 复用上一脚本的 Adam。固定种子 1202 生成 103 条训练输入与 47 条验证输入，每条两个标准正态特征，真实目标为 $1 + 2x_1 - x_2$ 加标准差 0.3 的独立正态噪声。设计矩阵首列为 1；本实验不使用权重衰减，因此截距不会被罚。

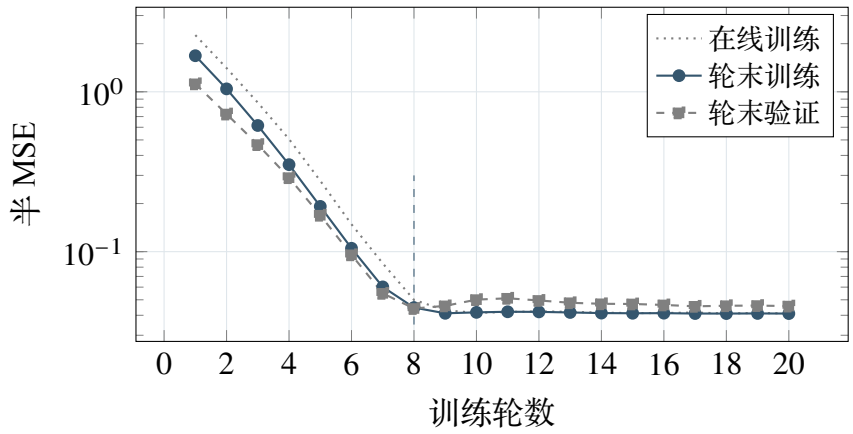
批量 16，最多 120 轮，学习率 0.05，耐心 12，改善阈值 $10^{-8}$。每轮 7 次更新，末批 7 条。程序同时记录在线半 MSE、轮末训练半 MSE、轮末验证半 MSE，并将日志写入 `ch12_results/training.csv`；最佳轮数、验证值与权重写入同目录 `summary.json`。

```
if validation_loss < best_loss - 1e-8:
    best_loss = validation_loss
    best_weights = w.copy()
    best_epoch = epoch
    stale = 0
else:
    stale += 1
    if stale >= patience:
        break
```

训练结束返回 `best_weights`，而非最后一个 `w`。脚本重新计算返回参数的验证损失，断言等于日志中对应最佳轮的值。这比只打印“已早停”更能揭示保存与恢复错误。所返回参数通常接近真实 $(1, 2, -1)$，但有限样本与噪声使其不必完全相同。

本实验使用验证数据选择停止轮，没有独立最终测试，因此只用于训练流程教学，不把最佳验证损失宣称为无偏泛化估计。修改任务：把末批错误地除以 16，比较更新及日志；把 `copy()` 删除并改成原地更新，观察保存对象为什么可能随训练改变；把耐

心值改为 1 或 30，解释停止时刻和返回状态的区别。




图为实验 12.2 实际日志，纵轴为对数尺度，竖线标出第 8 轮。最初在线损失与轮末训练损失差距较大，因为一轮内参数正在快速改进；进入较稳定阶段后，两者接近但不完全相同。验证曲线在低值附近轻微波动，单看这一局部起伏不能断言梯度发散。判断发散应结合尺度、连续趋势、梯度范数和参数是否有限。

该图的训练和验证指标都不含额外惩罚，并使用相同半 MSE 定义，因而可以直接比较。它没有显示测试曲线，因为本实验未设置最终测试集。若读图时忽略这一点，会把用于选择早停的验证结果误读成独立性能证据。

## 12.13 随机梯度为什么在最优点附近仍会波动

考虑最简单的常数均值估计目标 $R(w) = \frac{1}{2}\mathbb{E}[(w - Y)^2]$，其中每一步新抽取独立 $Y_t$，均值为 $\mu$、方差为 $\sigma^2$。总体最优点是 $\mu$，但单样本梯度在 $w = \mu$ 时为 $\mu - Y_t$，通常不等于零。固定学习率更新为

$$w_{t+1} = w_t - \eta(w_t - Y_t) = (1 - \eta)w_t + \eta Y_t.$$

令误差 $e_t = w_t - \mu$，有 $e_{t+1} = (1 - \eta)e_t + \eta(Y_t - \mu)$。若初值固定，期望满足

$$\mathbb{E}[e_t] = (1 - \eta)^t e_0.$$

在 $0 < \eta < 2$ 下平均误差衰减，但这并不意味着每条随机轨迹趋于一个固定点。

因为新 $Y_t$ 独立于旧参数，交叉项期望为零，二阶误差满足

$$\mathbb{E}[e_{t+1}^2] = (1 - \eta)^2\mathbb{E}[e_t^2] + \eta^2\sigma^2.$$

稳态若存在，令两边为 $V$，得

$$V = \frac{\eta^2\sigma^2}{1 - (1 - \eta)^2} = \frac{\eta\sigma^2}{2 - \eta}. \tag{12.10}$$

当学习率变小，稳态波动减小；但期望误差的因子 $1 - \eta$ 更接近 1，初期移动更慢。这一公式把速度与噪声之间的权衡写成了可以计算的关系。

若每次使用 $B$ 个独立新样本的均值，噪声方差变为 $\sigma^2/B$，稳态误差也相应除以 $B$。这里是假设每步有新独立数据的理想模型；在固定有限数据上反复洗牌、使用动量或自适应步长时，不能直接照用同一个数值公式，但它能解释为何小批量曲线不必单调。

取 $\sigma^2 = 9, \eta = 0.1, B = 1$，稳态参数误差约为 $9/19 \approx 0.473684$；$B = 10$ 时为 0.0473684。若把均值参数波动误认为数据噪声本身，又将同一噪声加两次，就会算错预测风险。对独立新标签的 MSE 还应加不可约方差 9。

## 12.14 梯度累积：内存批量与更新批量不同

当内存无法一次装入大批量时，可以分成若干**微批量**（micro-batch），在参数保持不变期间累计梯度，最后更新一次。这称为**梯度累积**（gradient accumulation）。若一组微批量大小分别为 $b_1, \dots, b_K$，每批平均数据梯度为 $\mathbf{g}_k$，总样本数 $N = \sum_k b_k$，等价大批量梯度为

$$\mathbf{g}_{\text{large}} = \frac{1}{N} \sum_{k=1}^{K} b_k \mathbf{g}_k.$$

只有每个微批量同样大时，才等于对 $\mathbf{g}_k$ 简单求平均。最后一组不足预定累积数时，也应使用实际总样本数。

例如 8 条微批量的平均梯度为 2，2 条微批量的平均梯度为 $-1$，合并梯度为 $(8 \times 2 + 2 \times (-1))/10 = 1.4$，不是 $(2 - 1)/2 = 0.5$。两批必须在同一参数点求导；若先用第一批更新参数再算第二批，就已经是两个 SGD 步骤，不再等价于一次大批量更新。

累积时每个微批量只累计数据梯度，正则梯度在最终更新前添加一次；或者严格按样本权重分摊同一正则梯度。Adam 的时间计数与矩状态只能在真正更新时推进一次，不能对每个微批量先更新矩状态再声称等价。含依赖批统计量的网络层时，微批前向也可能与大批前向不同，第 24 章会讨论这一限制。

```
accumulated = np.zeros_like(w)
count = 0
for idx in micro_batches:
    residual = X[idx] @ w - y[idx]
    accumulated += X[idx].T @ residual
    count += len(idx)
gradient = accumulated / count
w = optimizer.step(w, gradient)
```

片段假设 `micro_batches` 非空，`w` 在循环内保持固定，损失为无正则半平方损失。累计未平均的梯度总和，最后统一除以样本数，可避免末批不等长的错误。真实实现还应在每组更新开始时清零累计数组，防止上一组梯度残留。

## 12.15 用日志区分收敛、选择与保存错误

实验 12.2 的固定运行在第 8 轮达到最佳验证半 MSE 约 0.044122，连续 12 轮未达到设定改善量后，于第 20 轮结束。返回权重约为 $(1.006168, 1.921829, -0.929537)$。这组参数属于第 8 轮，不属于停止时的第 20 轮；“运行 20 轮”与“选中第 8 轮”应同时报告。

为了检查早停，应先验证返回参数的指标与最佳轮日志一致，再讨论最佳轮是否有统计意义。如果日志只每隔 5 轮保存，最佳状态应与实际检查频率对应，而不能虚构中间未评价的最佳轮。若验证数据很小，曲线的细小差异可能只是抽样波动；本实验改善阈值很小是为了演示机制，不是所有任务的通用选择。

一次完整诊断还应检查参数是否真的变化。梯度范数非零但参数始终不变，可能是更新后的数组没有赋回模型；参数变化但损失曲线不变，可能是日志使用缓存预测；训练损失很低而验证异常差，可能是验证时重新 fit 了缩放器。将输入、输出、梯度、状态保存和评价分别核对，可以缩小问题范围。




流程从容易独立验证的局部事实开始，再扩大到训练与评价。若第一步已经发现标签错位，应先修复并重新运行后续步骤；无须同时尝试十种学习率。若局部计算全部正确但泛化仍差，则回到数据代表性、表达能力与选择协议，而不是无限增加优化步数。

## 12.16 知识联系与自检

优化器解决的是第 9 章中已指定的经验目标；数据划分和输入状态由第 10 章控制；第 11 章的直接解与 KKT 条件提供可检验参照。诊断时要分别问：目标是否表达任务，数据是否允许评价，导数与更新是否正确，计算预算是否足以接近目标最优。更换优化器通常只改变最后两项中的一部分。

计算与编程答案可运行 `ch12_solutions.py` 核对。该入口验证数值与实现边界；概念题仍需依据下列推理说明判断。

## 12.17 分层练习

12.1 $n = 250, B = 32$，保留末批，一轮几步，末批多少条？20 轮共多少次更新？

12.2 两批分别含 8 条、2 条，平均损失 0.5、2.0。求正确全体平均与错误的批均值平均。

12.3 证明独立均匀有放回抽样的小批量梯度条件期望等于全梯度，并说明平方协方差为何除以批量。

12.4 对 $J(w) = 2w^2$，从 1 开始，学习率 0.1 更新两步；稳定步长区间是什么？

12.5 按本章动量约定，$v_0 = 0, \beta = 0.5$，连续三个梯度均为 2，求各步 $v$。恒定梯度下长期极限是多少？

12.6 AdaGrad 连续两个梯度均为 2，$\eta = 0.1$，忽略 $\epsilon$，求两次更新减量。

12.7 Adam 第一步梯度为 $-3$，$\eta = 0.01$，忽略 $\epsilon$，参数如何变化？为什么负梯度时参数增加？

12.8 AdamW 某一步 $w = 2, \eta = 0.1, \lambda = 0.05$，数据自适应方向为 0，求新参数；若矩状态非零而当前数据梯度为 0，方向是否必为 0？

12.9 梯度 $(6, 8)$，整体范数阈值 5 与逐元素阈值 5 分别得到什么？哪一种保持方向？

12.10 验证损失依次为 0.5、0.4、0.42、0.41、0.43，耐心 2、改善阈值 0，何时停止，恢复哪一轮？

12.11 恢复训练为什么不能只加载参数？列出 Adam 与随机洗牌情况下还需保存的状态。

12.12 为实验 12.2 设计检查：最后一批确实只有 7 条，返回参数确实是最佳验证状态，日志均有限；这些检查仍不能证明什么？

## 12.18 参考答案与推理

12.1 $\lceil 250/32 \rceil = 8$ 步，前 7 批 224 条，末批 26 条；20 轮 160 次更新。若使用梯度累积，数据批次数与更新次数需另行区分。

12.2 正确平均 $(8 \times 0.5 + 2 \times 2)/10 = 0.8$；错误平均 $(0.5 + 2)/2 = 1.25$，后者把小批次赋予过高权重。

12.3 条件于当前参数，单次均匀抽样梯度期望为 $n^{-1} \sum_i \nabla \ell_i$；对 $B$ 次平均再用线性期望即得结论。独立时交叉协方差为零，$B^{-2} \times B\Sigma = \Sigma/B$。数据依赖的无放回轨迹不能直接照搬独立条件。

12.4 梯度为 $4w$，更新因子 0.6，两步为 0.6、0.36。Hessian 为 4，故 $0 < \eta < 1/2$；端点 $\eta = 1/2$ 为等幅变号。

12.5 $v_1 = 2, v_2 = 3, v_3 = 3.5$。稳态满足 $v = 0.5v + 2$，故趋于 4。对一般恒定 $g$，极限为 $g/(1 - \beta)$。

12.6 累计平方为 4、8，减量分别 0.1、$0.1/\sqrt{2} \approx 0.070711$。即使梯度不变，累计分母也使步幅缩小。

12.7 偏差修正后分子为 $-3$，分母 3，更新减量 $-0.01$，所以参数增加 0.01。梯度负表示增加参数会在局部降低目标，与沿负梯度走一致。

12.8 纯衰减得到 $(1 - 0.005) \times 2 = 1.99$。当前梯度零时历史一阶矩仍可非零，故自适应方向不必为零；题目前半明确给定方向为零才可只计算衰减。

12.9 范数 10，整体结果 $(3, 4)$；逐元素结果 $(5, 5)$。前者是原向量的 0.5 倍，保持方向；后者改变分量比例。

12.10 第 2 轮最佳 0.4，第 3、4 轮连续两次未改善，在第 4 轮结束停止，恢复第 2 轮。第 5 轮不会运行；不能恢复第 4 轮却报告 0.4。

12.11 Adam 需一阶、二阶矩和累计步数；还要保存学习率、调度进度、随机数状态、轮次及必要的数据加载位置。仅加载参数后清零矩状态，会得到不同更新轨迹。预处理状态与配置也应一致。

12.12 在批下标生成处记录长度应为六个 16 加一个 7；训练返回后重新计算验证值并与记录的最佳轮比较；对日志使用有限性断言。这些验证程序机制，不证明数据无泄漏、目标合理或未来泛化良好。