5 pandas、数据探索与可视化

先修知识、学习目标与本章位置

本章使用第 2 章的容器、函数与条件，第 3 章的文件路径、CSV 与异常，以及第 4 章的数组、布尔筛选和轴。统计部分从均值与排序开始，补充方差、分位数和相关系数的含义，不要求已经学完概率统计。

学习后应能读取带字段名的表格，区分位置与标签，检查类型、缺失和重复；完成筛选、分组和受约束合并；用统计量与图形回答具体问题；形成说明数据范围、处理规则、证据与局限的数据探索报告。第 10 章会把这里的处理规则纳入训练流程，第 41 章再用于完整项目。

同一列里出现数字、空白和文字，两个文件中的记录顺序不一致，某个区域的平均费用明显较高，这些现象都发生在训练模型以前。若直接把表格转成数组，程序可能成功执行，却已经把缺失理解成零、把两条不同记录拼在一起，或者把重复记录计数两次。数据处理首先要明确每行代表什么、每列怎样测得，以及哪些记录可以互相配对。

pandas 是处理带标签表格的 Python 库。它适合读取、整理、汇总与检查结构化数据；第 4 章的 NumPy 更侧重规则形状上的数值运算。**探索性数据分析**（exploratory data analysis，EDA）指通过数据质量检查、描述统计和可视化认识数据，提出或修正问题。EDA 可以发现值得进一步检验的关系，但图形中的规律不自动成为因果解释或可靠预测结果。

本章使用人为构造的包裹记录。连续目标是费用，二元字段是是否延迟。数据故意包含空白、非法文本、一条完全重复记录与一条大重量记录。其规模足以手算，却不能代表真实配送业务。

5.1 从 CSV 到带标签的表格

安装、入口与数据字典

按第 2 章建立虚拟环境后，在终端安装本章依赖：

```
python3 -m pip install pandas matplotlib numpy
python3 -c "import pandas as pd; print(pd.__version__)"
```

pandas 负责表格，**Matplotlib** 负责绘图；惯用导入别名分别为`pd`与`plt`。别名不属于 Python 关键字。配套依赖文件记录本批实际运行版本，安装命令本身不保证以后安装的是相同版本。

第 3 章已经说明 **CSV**（comma-separated values，逗号分隔值）是一种文本表格格式。文件保存字段文本，不保存可靠的“这一列一定是整数”约束。首行一般是字段名，之后每行是记录；含逗号或换行的字段需要正确引用，不能用简单字符串切分替代 CSV 读取器。

数据字典说明字段的业务含义、单位、允许值和使用时点。先写字典，再判断类

型与处理规则。

字段	含义与单位	约束及用途
id	包裹标识，文本	非空、唯一；不是数值特征
split	预先固定的划分	train、val、test
area	区域代码，文本	A 或 B，合并区域说明
weight_kg	重量，kg	有限非负；允许缺失待处理
distance_km	距离，km	有限非负
late	是否延迟，0 或 1	分类任务的示例标签
fee_yuan	最终费用，元	连续目标；有限非负

本章不把late用于预测费用的输入：是否延迟往往要在配送后才知道。一个字段是否可用，取决于实际预测时点，不取决于它在 CSV 中是否已经存在。第 10 章会进一步讨论这种时间上的数据泄漏。

实验文件位于配套实验/ch05_data/。parcels.csv共 13 条原始记录，其中t03被完全重复一次；去重后训练 8 条、验证 2 条、测试 2 条。areas.csv为区域代码与区域名称的一一对应表。

```
from pathlib import Path
import numpy as np
import pandas as pd

root = Path(__file__).resolve().parent
raw = pd.read_csv(root / "ch05_data" / "parcels.csv",
                  dtype="string", keep_default_na=False)
print(raw.shape)
print(raw.head(3))
print(raw.dtypes)
```

本框在配套脚本中执行；交互环境没有__file__时，应显式设置实际的数据目录。head(3)只查看前三行，不证明其余行也合法。dtype="string"让各字段先保留文本含义，keep_default_na=False关闭默认缺失文本识别，空字段暂为""，随后按数据字典转换。否则文本“NA”可能被默认识别成缺失，而它也可能恰是一个合法区域代码。

Series、DataFrame 与索引

Series 是一维带标签的数据序列；**DataFrame** 是二维带行索引和列名的表格，各列可以有不同类型。索引（index）是用于标识轴位置的标签集合。默认行索引常为 0、1、2，但这不意味着索引永远等于当前位置，也不意味着索引自动具有唯一业务含义。

```
df = pd.DataFrame({"id": ["p1", "p2", "p3"],
                   "weight": [1.0, 2.0, 4.0],
                   "area": ["A", "B", "A"]},
                  index=[10, 20, 30])
print(df["weight"].shape)
print(df[["weight"]].shape)
print(df.columns.tolist())
```

单个列名得到Series，形状(3,)；列名列表得到DataFrame，形状(3, 1)。与第 4 章的一维数组、列数组区别相似，但表格还携带标签。读取shape只得到轴长，不能代替读取字段名称与顺序。

标识“0012”不能仅因含数字而转换成整数 12，否则会丢失前导零。区域代码 1、2、3 也不必是可计算距离的数值：代码之差不表示区域之间的物理距离。**数值变量、类别变量与标识字段**由含义区分，不能完全由文件中的字符或自动推断类型决定。

5.2 按标签、位置与条件选择记录

loc 与 iloc 回答不同问题

loc按标签选行列，iloc按从零开始的位置选行列。

```
print(df.loc[20, "weight"])
print(df.iloc[1, 1])
print(df.loc[10:20, ["id", "weight"]])
print(df.iloc[0:2, [0, 1]])
```

前两项都为 2.0，但依据不同。当前有序唯一整数索引下，loc[10:20]包含结束标签 20；iloc[0:2]遵守 Python 半开位置区间，不含位置 2。不要把标签切片的此例推广成任意无序或重复索引都能无歧义切片。

条件筛选先为每行生成一个布尔值，再取满足条件的记录。多个逐元素条件用&、|与~组合，并给每个比较加括号：

```
mask = (df["weight"] >= 2) & (df["area"] == "A")
selected = df.loc[mask, ["id", "weight"]].copy()
print(selected)
df.loc[df["id"] == "p2", "weight"] = 2.5
```

筛选得到p3与重量 4。最后一行在原表上明确赋值。and要判断整个对象的真假，不能替代 Series 逐行逻辑。连续写df[mask]["weight"] = 0会使赋值对象与原表的关系不清楚；本书统一用一次loc定位原表赋值。独立处理子表时用copy()表达意图，避免依赖不同 pandas 版本的复制细节。

标签对齐：有用的规则也可能掩盖错配

pandas 中的许多运算先按索引标签对齐，再逐位置计算；NumPy 主要按形状和位置计算。下面的两条 Series 顺序不同：

```
a = pd.Series([10, 20], index=["a", "b"])
b = pd.Series([1, 2], index=["b", "a"])
print(a + b)
print(a.to_numpy() + b.to_numpy())
```

Series 相加得到标签 a 为 12、b 为 21；去掉标签后的位置相加为 11、22。对齐并不是重新按数值排序，而是找相同标签。“a”处取 10 与 2，“b”处取 20 与 1。若标签只出现在一边，许多对齐运算会产生缺失值，不会自动认为缺失的一项是 0。

例题 5.1：排序后直接拼接标签

特征表按重量排序后，标识顺序为`p2,p1,p3`；标签表仍为`p1,p2,p3`，目标为 8、6、12。直接把目标数组按位置赋给特征表，会得到什么对应？如何正确配对？

解 错误对应为`p2:8,p1:6,p3:12`，前两条目标交换。正确对应应为`p2:6,p1:8,p3:12`。若双方仍保留可信的同一唯一索引，可以按标签对齐；若索引已经重置，应按显式`id`合并，并检查唯一性与未匹配记录。给两个表分别`reset_index(drop=True)`只能制造相同的位置编号，不能恢复原样本关系。

最终向 NumPy 转换时，要显式固定字段顺序并检查有限值：

```
feature_names = ["weight", "distance"]
example = pd.DataFrame({"distance": [10., 20.],
                        "weight": [1., 2.]})
X = example[feature_names].to_numpy(dtype=np.float64)
if X.ndim != 2 or not np.isfinite(X).all():
    raise ValueError("invalid feature matrix")
print(X)
```

结果为两行`[1,10]`、`[2,20]`。选择列表规定了特征顺序，而不是沿用原表偶然的列顺序。训练和预测使用相同名称、单位与顺序，才对应第 4 章的同一个数值输入空间。

5.3 类型转换与缺失值：保留失败原因

缺失、非法、零与无穷不同

缺失值表示本应存在的信息未获得或未记录；数值零表示确实测得零；非法文本表示字段不符合约定；正负无穷表示超出有限数范围或某些计算的极限结果。它们不能混为一种“空数据”。

pandas 可能用`np.nan`、`pd.NA`或日期缺失值表示不同类型的缺失。判断应使用`isna()`和`notna()`，不要用`x == np.nan`。采用可空整数类型`"Int64"`可以在整数列中保留缺失，和 NumPy 普通`int64`不同；本章重量、距离与费用最终采用浮点类型。

```
text = pd.Series(["1", "", "bad", "0"], dtype="string")
original_missing = text.eq("")
number = pd.to_numeric(text.mask(original_missing),
                       errors="coerce")
invalid = number.isna() & ~original_missing
print(original_missing.tolist())
print(invalid.tolist())
```

原缺失位置为第二项，转换失败位置为第三项。`mask`把条件成立的位置替换为缺失；`errors="coerce"`把不能转换的内容转成缺失。若只在转换后统计`isna()`，两种原因都会显示为缺失，无法判断是采集遗漏还是文件中写入了“bad”。完整脚本还用`np.isfinite`拒绝非有限文本数值，并在审计表中保存标识、字段、原文本与原因。

审计记录在这里指足以追踪数据变化的处理记录，不是复杂的管理系统。原文件保持不改，派生表记录转换结果，另一张表列出异常原因。这样在发现错误处理时，可以回到原文本重做，而不是继续在已丢失信息的表上猜测。

统计函数通常跳过缺失

```
s = pd.Series([1.0, np.nan, 3.0])
print(s.mean(), s.count(), s.size)
print(s.isna().mean())
print(s.sum(min_count=1))
```

均值 2.0 来自两个有效值，`count()`为 2，`size`为 3，缺失比例为 1/3。均值的分母不能默认为原始行数。全缺失序列的默认求和可能得到 0，`sum(min_count=1)`要求至少一个有效值，否则返回缺失；全缺失均值也不能作为有效训练参数。

删除所有带缺失的行会改变样本范围。若重量缺失主要发生在某类包裹，删除后剩余数据可能更少包含这一类。`dropna(subset=[...])`可以只要求当前分析所需字段有效；相关分析只删除两个参与字段不完整的行，不必因无关字段缺失而删除整行。

例题 5.2：均值填补并没有补回观测

一列观测为 1、缺失、3。用有效值均值 2 填补，比较填补前后的均值、样本方差和有效观测数量。

解 两个有效观测的均值为 2，样本方差为 $[(1-2)^2+(3-2)^2]/(2-1)=2$。填补后数值列为 1、2、3，均值仍为 2，若机械地按三条计算样本方差则为 1。填入的 2 由原数据计算而来，并非新增独立测量；有效原始观测仍只有 2 条。均值未变不说明分布、相关性或不确定性未变。

本章只演示一种透明规则：从训练集有效重量计算中位数，填补各集合，同时保留缺失指示列。是否适合实际问题要通过训练与验证流程判断。不能为使图形好看而提前把所有缺失改成零，也不能用全部集合的中位数再声称测试集完全隔离。

```
train = clean.loc[clean["split"] == "train"].copy()
median = train["weight_kg"].median()
if pd.isna(median):
    raise ValueError("no valid training weight")
prepared = clean.copy()
prepared["weight_missing"] = prepared["weight_kg"].isna().astype(int)
prepared["weight_kg"] = prepared["weight_kg"].fillna(median)
```

本框的clean来自实验 5.1 的load_tables()。缺失指示为 1 表示该数原来缺失或转换后无效；原因仍由审计表分别保存。第 10 章会讨论如何让这种“拟合参数，再复用参数”的过程嵌入模型评价。

5.4 重复记录与关键约束

完全重复和标识冲突

duplicated()检查参与比较的列值是否与已有记录重复；drop_duplicates()默认保留第一条。完全重复行可能来自重复导出，也可能恰好是合法的两次独立观测，去重前必须结合标识与采集含义。

本章数据字典规定一条id只对应一个包裹；完全相同的t03是重复导出，删除一条合理。若同一id出现费用 10 与 11，则是标识冲突。仅按id去重并留第一条会任意决定“真值”，应报告冲突并中止，等待核对来源。

```
duplicate_count = int(raw.duplicated().sum())
clean = raw.drop_duplicates().copy()
if clean["id"].eq("").any() or clean["id"].duplicated().any():
    raise ValueError("empty or conflicting id")
if not clean["split"].isin(["train", "val", "test"]).all():
    raise ValueError("unknown split")
```

检查放在数值转换前，便于辨认原文本冲突。本章先对字段去首尾空白；这是一项明确的规范化规则，并非任意文本都能随意删除空格。重复记录若分别进入训练与测试，会使评价样本不再独立于训练过程；不能等到训练后才检查这一问题。

从局部合法到整体一致

字段合法还不足以保证表格可信。应检查行数变化、必需字段、标识唯一性、允许类别、取值范围和样本配对；跨表还要检查关系是否满足一对一或多对一。每一步记录输入行数、输出行数和变化原因，才有机会发现无意丢行或扩行。

对于大型文件，全量读取可能超过内存。read_csv(chunksize=...)可以逐块读入；但“各块内无重复”不能推出全文件无重复，跨块标识需要另外维护。分组均值也不能直接平均各块均值，应同时累计总和与有效数量。本章使用小数据，目标是先把完整规则说明清楚。

5.5 分组、聚合与合并

分组是先拆开，再汇总

分组（grouping）按一个或多个字段把记录分成若干组，聚合（aggregation）把每组的多条记录归纳为一个或几个统计量。区域平均费用、每类标签数量、每日记录数都属于这类问题。

```
train = clean.loc[clean["split"] == "train"].copy()
grouped = train.groupby("area", dropna=False, sort=True).agg(
    rows=("id", "size"), weights=("weight_kg", "count"),
    mean_fee=("fee_yuan", "mean"), late_rate=("late", "mean"))
print(grouped)
```

`agg`采用命名聚合：输出列名后给出“输入列、汇总规则”。`size`数记录，`count`数该字段的非缺失值。`dropna=False`保留分组键缺失的组，避免无意忽略；完整实验仍通过数据字典约束区域。`sort=True`明确规定输出组顺序，不依赖默认显示顺序。

二元标签均值等于正类比例：若组内 m 条有效 0/1 标签中有 k 条为 1，则均值为 k/m。标签若包含 2 或非法值，这一解释立即失效。写出组内记录数与有效值数，有助于判断均值来自多少证据。

> **例题 5.3：组均值怎样合成总体均值**
>
> 区域 A 有 4 条费用，均值 11.5；区域 B 也有 4 条，均值 20.5。求整体均值。若 A 只剩 1 条且均值仍为 11.5，B 仍有 4 条，整体均值又是多少？

解 第一种为 $(4\times 11.5+4\times 20.5)/8=16$。第二种为 $(1\times 11.5+4\times 20.5)/5=18.7$，不是两组均值的简单平均 16。一般有

$$\bar{x}=\frac{\sum_g n_g\bar{x}_g}{\sum_g n_g},$$

其中 n_g 必须是该统计量实际使用的有效值数。若汇总的是重量，而某组有缺失，不能把总行数误作有效重量数。

按键合并，核对关系与未匹配项

键（key）是连接两张表时用于确定对应关系的字段。包裹表有多条 A 区域记录，区域表中 A 只应出现一次，关系为多对一（many-to-one）。左连接保留左表记录，并查找右表对应说明。

```
joined = clean.merge(lookup, on="area", how="left",
                     validate="many_to_one", indicator=True)
if not joined["_merge"].eq("both").all():
    raise ValueError("unmatched area")
joined = joined.drop(columns="_merge")
```

`validate`检查右表键唯一性；`indicator`增加`_merge`列，指出记录只在左侧、只在右侧或两侧均有。内连接`how="inner"`只保留两边都匹配的键，可能悄悄丢失未知

区域；因此本章先左连接，再显式拒绝未匹配项。

> **例题 5.4：重复键为什么使行数增加**
>
> 左表有两条键 A 的包裹，右表有两条键 A 的区域说明。对键 A 进行普通合并，会产生多少行？这会怎样影响统计？

解 左侧每条 A 都与右侧两条 A 配对，共 $2\times2=4$ 行。这是多对多连接的组合结果，不能理解为新增了两条独立包裹。若 A 被重复而 B 没有，A 在整体均值中的权重会无意增加。`validate="many_to_one"`会拒绝右侧重复键，避免把异常扩行继续送入训练。

合并前还应拒绝缺失键；pandas 的合并可能让两侧缺失键互相匹配，不能照搬其他数据库对空值的直觉。若时间变化的区域表每区有多个生效日期，就需要“区域加日期”等复合规则，不能简单去掉重复键来强行满足多对一。

上下追加同结构记录可以使用拼接函数：

```
combined = pd.concat([part1, part2], ignore_index=True)
```

其中两个输入是已读取的同结构表。它与按键补充字段的`merge`不同，拼接时仍需检查字段集合、类型、单位与跨文件重复标识。

5.6 描述统计：中心、离散与分位数

描述的对象与分母

描述统计归纳已观测数据的数量、中心位置、离散程度与分布形态。它首先回答“这批数据是什么样”，不直接回答更大总体是否也如此。`describe()`可以提供计数、均值、标准差、分位数和极值，但其输出仍需结合单位、有效数量与缺失规则解释。

对 m 个有效实数 $x_1,\dots,x_m$，均值为

$$\bar{x}=\frac{1}{m}\sum_{i=1}^{m}x_i.$$

均值与原变量单位相同，所有数值都参与计算，因此极端值会影响它。**中位数**（median）为排序后居中的值；有效数量为偶数时，本章取中间两值的平均。中位数更关注次序，不能反映尾部大数到底有多大。

描述离散程度可用**方差**与**标准差**。本章明确区分两种分母：

$$v_0=\frac{1}{m}\sum_{i}(x_i-\bar{x})^2,$$

$$s^2=\frac{1}{m-1}\sum_{i}(x_i-\bar{x})^2,\qquad m\ge 2.$$

v_0 描述这批数的平均平方离差；s^2 是常见的样本方差，作为总体方差估计的条件在第 8 章讨论。方差单位是原单位的平方，标准差为方差平方根，回到原单位。pandas 的`std()`通常默认`ddof=1`，NumPy 的`std()`默认`ddof=0`；同一列得到不同结果时，应先核对分母，不立即归因于浮点误差。

分位数需要约定插值方法

分位数（quantile）描述排序数据中某个比例位置上的值。不同有限样本定义可能给出不同结果，本章采用 pandas 的线性插值约定。对升序 $x_{(1)}, \dots, x_{(m)}$ 与比例 $p \in [0,1]$，先用零起点位置

$$h = (m-1)p, \qquad j = \lfloor h \rfloor, \qquad \alpha = h - j.$$

若 $j < m-1$，取 $q_p = (1-\alpha)x_{(j+1)} + \alpha x_{(j+2)}$；若 $j = m-1$，取最后一项。第一四分位数 $Q_1 = q_{0.25}$、中位数 $Q_2 = q_{0.5}$、第三四分位数 $Q_3 = q_{0.75}$。

> **例题 5.5：大重量记录怎样影响统计**
>
> 训练集中有效重量按升序为 1、2、3、5、6、20 kg。按上述约定计算均值、中位数、样本方差、四分位数和四分位距，并给出基于四分位距的异常标记。

解 总和 37，均值 $37/6 \approx 6.166667$ kg；中位数 $(3+5)/2 = 4$ kg。平方和 475，因此平方离差和为

$$\sum_i (x_i - \bar{x})^2 = 475 - 6(37/6)^2 = \frac{1481}{6}.$$

样本方差为 $1481/30 \approx 49.366667\ \text{kg}^2$，分母 6 的方差为 $1481/36 \approx 41.138889\ \text{kg}^2$。

四分位位置分别为 1.25 和 3.75，故 $Q_1 = 2 + 0.25(3-2) = 2.25$ kg，$Q_3 = 5 + 0.75(6-5) = 5.75$ kg。**四分位距**（interquartile range，IQR）为 $Q_3 - Q_1 = 3.5$ kg。常见探索规则将

$$[Q_1 - 1.5\,\text{IQR},\ Q_3 + 1.5\,\text{IQR}] = [-3, 11]\ \text{kg}$$

作为围栏，20 kg 超出上围栏，被标记为待检查记录。下围栏为负数不允许真实重量为负，它只是统计规则计算出的界限；物理合法性仍按数据字典检查。

异常值（outlier）指相对某种参考分布或规则显得特殊的记录，不一定是错误值。20 kg 可能是合法重包裹，不能仅凭围栏就删除；若真实任务要处理重包裹，删掉它反而会掩盖模型最需要面对的情况。本章保留`t08`，在报告中单独说明。

```
weight = train["weight_kg"].dropna()
q1, median, q3 = weight.quantile([.25, .5, .75]).tolist()
iqr = q3 - q1
flag = (train["weight_kg"] < q1 - 1.5 * iqr) | (
        train["weight_kg"] > q3 + 1.5 * iqr)
print(train.loc[flag, ["id", "weight_kg"]])
print(weight.mean(), weight.std(ddof=1))
```

缺失值不参与围栏估计，也不会因“没有被标记”就成为正常观测。报告中要同时列有效数量、缺失数量和被标记数量。IQR 为 0 时围栏可能退化，离散或极小样本不能机械套用连续大样本的解释。

5.7 相关性、标签分布与比较边界

相关系数测量线性共同变化

对同一批 m 个完整配对 (x_i, y_i)，**Pearson 相关系数**定义为

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2}\sqrt{\sum_i (y_i - \bar{y})^2}}.$$

本式要求两列均不是常数，并按相同样本配对。分子为同向偏离的乘积总和，分母把两列离差尺度消去，使 r 无量纲。两列在均值同侧时乘积为正，反侧时为负。第 6 章会把它解释为两个中心化向量夹角的余弦，从而说明 $-1 \le r \le 1$。

训练集中重量有效的 6 条记录费用为 6、8、10、14、16、44，满足 $y = 2x + 4$。故 $y_i - \bar{y} = 2(x_i - \bar{x})$，代入分子分母得到 $r = 1$。这个结果反映教学构造中的精确线性关系，不反映真实业务必然达到的预测精度。

```
pairs = train[["weight_kg", "fee_yuan"]].dropna()
r = pairs["weight_kg"].corr(pairs["fee_yuan"])
print(len(pairs), r)
print(train["late"].value_counts(dropna=False))
print(train["late"].value_counts(normalize=True, dropna=False))
```

输出有效配对数 6 与接近 1 的相关系数。二元标签 0、1 各 4 条，比例各 0.5。`normalize=True`把频数除以相应总数；若允许缺失标签，应明确分母是否包含缺失，不能把“已标注样本中的比例”称为全部样本比例。

> **例题 5.6：零相关不等于没有关系**
>
> 令 $x = (-2, -1, 0, 1, 2)$，$y = (4, 1, 0, 1, 4)$。计算相关系数的分子，并说明散点图能补充什么信息。

解 $\bar{x} = 0$、$\bar{y} = 2$，乘积和为 $(-2)2 + (-1)(-1) + 0(-2) + 1(-1) + 2 \cdot 2 = 0$。两列方差非零，因此 $r = 0$；但每个点严格满足 $y = x^2$。散点图能显示 U 形关系，线性相关系数无法概括这一非线性结构。

相关还可能来自共同原因、选择过程、分组构成或少数极端值。区域 A/B 的平均费用不同，但两组重量构成也不同；只有 8 条构造数据，不能把区域差解释为区域造成的费用差。可以提出进一步核对重量、距离和业务规则的需求，不能从这张表直接给出因果结论。

分类任务需要检查各类数量与比例。若 1000 条标签中 990 条为 0，始终预测 0 也有 99% 准确率；“高准确率”可能只来自类别构成。标签缺失、标注规则变化与重复样本都可能使分布失真。第 14 章会进一步讨论适合不平衡任务的评价指标。

5.8 Matplotlib：图形对象与四种基本图

Figure 和 Axes 各负责什么

`Figure`是整张画布，`Axes`是画布中带坐标轴的一块绘图区。`plt.subplots()`同时创建它们。一个 Figure 可以包含多个 Axes，多个图应分别添加轴标、单位和标题。

```
import matplotlib.pyplot as plt
fig, ax = plt.subplots(figsize=(5, 3.5), layout="constrained")
ax.scatter([1, 2, 3], [6, 8, 10], color="#35566E")
ax.set(xlabel="Weight (kg)", ylabel="Fee (yuan)",
       title="Three teaching observations")
fig.savefig("scatter.png", dpi=180)
plt.close(fig)
```

`figsize`单位为英寸，`dpi`为每英寸像素数；增大 DPI 提高栅格输出像素数量，不增加数据证据。`layout="constrained"`为轴标与标题留出空间；仍应打开输出检查，不能把自动布局当作不裁切的保证。`close`释放画布，避免批量绘图时不断积累。

本章配套图使用英文轴标以减少不同系统中文字体差异，含义与单位在正文说明；主讲义中的示意图仍用既有宋体和主题色。需要中文图时应设置可用中文字体并核对缺字，不能仅改变字符串而忽略渲染警告。

散点图、直方图、柱形图与曲线

散点图（scatter plot）把每个配对样本画成一个点，适合查看两列关系、聚集、非线性与特殊点。它不连接样本，不暗示时间连续性。点重叠时可调整透明度，但不能因为看见一个点就断言只有一条记录。

直方图（histogram）把数值轴划分成区间，统计落入各区间的数量。分箱边界会影响外观；应记录边界，不能通过反复调箱宽只展示最符合预期的形状。训练重量按 0、5、10、15、20、25 kg 分箱，半开区间依次为 $[0,5)$、$[5,10)$、$[10,15)$、$[15,20)$，最后一箱 $[20,25]$ 包含右端点，频数为 3、2、0、0、1。

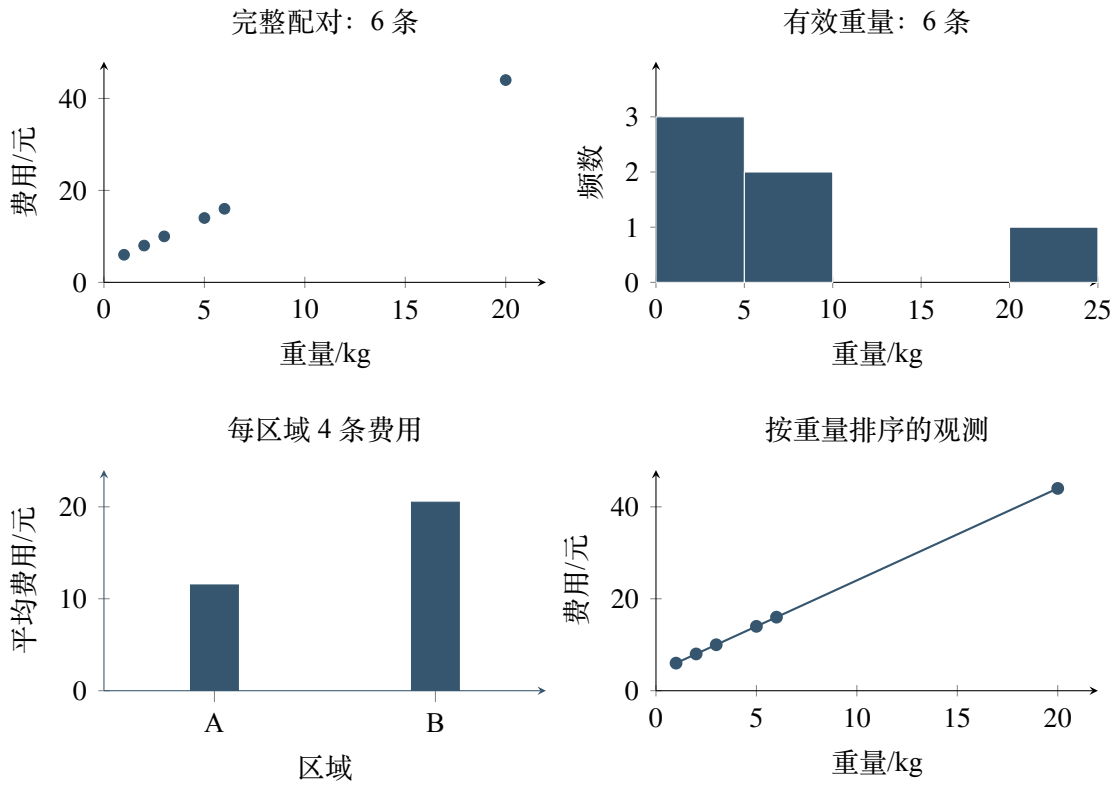
柱形图（bar chart）比较离散类别或已汇总统计量，横轴 A/B 不是连续数值区间。费用均值柱形图应同时报告各组数量。本章两组各 4 条，均值分别 11.5 与 20.5 元；它只描述这 8 条数据。

曲线图（line plot）按给定顺序连接点，适合显示时间或有意义的有序变化。`plot`不会自动替数据排序。按重量排序后连接费用点，可以辅助观察随重量的变化，但不能把横轴当作时间，也不能把连线当作已拟合模型。

```
fig, axes = plt.subplots(2, 2, figsize=(9, 6.5),
                         layout="constrained")
axes[0, 0].scatter(pairs["weight_kg"], pairs["fee_yuan"])
axes[0, 1].hist(weight, bins=[0, 5, 10, 15, 20, 25])
axes[1, 0].bar(grouped.index, grouped["mean_fee"])
ordered = pairs.sort_values("weight_kg")
axes[1, 1].plot(ordered["weight_kg"], ordered["fee_yuan"], "o-")
plt.close(fig)
```

此框只展示各图调用，对外保存前还要像完整脚本一样设置全部轴标与标题。`axes`

形状为`(2, 2)`，位置由两维索引指定；只有一幅图时返回的对象结构可能不同，不能照抄二维下标。



四图仅使用训练集。散点和曲线含 6 个完整配对，直方图使用 6 个有效重量，区域柱图使用 8 条有效费用。曲线的连线按重量排序，横轴不是时间；它也不表示已经训练出一个可外推模型。两条重量缺失记录仍计入区域费用统计，所以各图样本数不能含混地统一写成 8。

频数、密度与可比坐标

直方图的`density=True`把柱高换成概率密度估计，使柱形面积之和为 1，而非柱高之和为 1。若第 j 箱宽 h_j、频数 c_j，共有 m 条纳入分箱的记录，则密度高为 $c_j/(mh_j)$。单位为横轴单位的倒数。

例题 5.7：密度图为什么不是概率柱高

6 个重量按宽 5 kg 的箱分组，频数 3、2、0、0、1。求第一箱和第二箱的密度高，以及第一箱的经验比例。

解 密度高分别为 $3/(6\times5)=1/10\ \text{kg}^{-1}$ 与 $2/(6\times5)=1/15\ \text{kg}^{-1}$。第一箱面积为 $(1/10)\times5=1/2$，等于该箱的样本比例。箱宽改变时高也会变，不能把密度高理解为箱内比例，第二箱并非占 10%。若指定箱边界没有覆盖全部数据，还要说明分母实际涵盖哪些记录。

多图比较应尽量用相同分箱与坐标范围，图上标明样本数。柱形图一般从零起画，否则会夸大比例差异；散点图局部放大可以使用不同范围，但必须说明。对数坐标能

展开数量级差异，却要求正数或另作变换，并改变距离的视觉含义。本章不以删除尾部、截轴或隐藏缺失来改善图形外观。

5.9 实验 5.1：表格清理与可核对汇总

入口为配套实验`/ch05_tables.py`，使用 NumPy 和 pandas，CPU 可运行。程序从脚本位置读取两个 CSV，按第 3 章的入口保护运行；普通导入不会启动实验或写结果。

```
python3 ch05_tables.py
```

流程按如下顺序执行：核对字段与非空输入；保留文本并去首尾空白；删除完全重复行并拒绝标识冲突；转换数值并记录原缺失/转换失败；检查范围与标签；受约束地合并区域说明；仅取训练行作分组汇总。先审计再统计，避免把原始错误隐去。

完整训练表如下，横线表示数值缺失。

标识	区域	重量/kg	距离/km	延迟	费用/元
t01	A	1	10	0	6
t02	A	2	20	0	8
t03	B	3	10	1	10
t04	B	—	20	1	12
t05	A	5	10	0	14
t06	B	6	20	0	16
t07	A	—	10	1	18
t08	B	20	20	1	44

验证标识`v01,v02`的重量为 7、8，费用 18、20；测试标识`s01,s02`的重量为 9、10，费用 22、24。它们只参与固定字段合法性检查；本章不使用其目标值选择清理、填补或删点规则。

关键输出应满足：原始 13 行、唯一 12 行、完全重复 1 行；训练/验证/测试数量 8/2/2；审计表含`t04:missing`与`t07:invalid`；A/B 各 4 条，各有 3 个有效重量，费用均值 11.5/20.5，延迟比例 0.25/0.75。标签对齐演示为`a:12,b:21`。

修改任务每次从原版独立开始：把重复`t03`的费用改 11，应触发冲突错误；把区域表的 B 重复一次，应触发合并关系错误；把`s01`区域改 C，应触发未匹配错误；把延迟值改 2，应触发标签范围错误。不要捕获异常后继续打印旧报告。配套答案在临时目录做冲突核对，不修改原始数据。

5.10 实验 5.2：统计、图形与数据探索报告

问题与输出

入口为配套实验`/ch05_eda.py`，在实验 5.1 基础上增加 Matplotlib。它选择无需窗口的`Agg`后端并保存图片，适合在终端或自动运行环境使用。

```
python3 ch05_eda.py
python3 ch05_solutions.py
```

脚本在`ch05_results/`生成审计表、分组表、填补演示表、`summary.json`、`overview.png`与`report.md`。摘要保存依赖版本与输入文件 SHA-256，便于辨认所分析的文件字节；摘要不能证明数据真实或质量充分。

本实验回答两个预先提出的问题：有效重量与费用如何共同变化？区域平均费用差是否足以解释为区域作用？统计先使用未填补的训练表，报告原始缺失情况；填补演示另存派生表，避免把合成数值冒充观测。

应得到训练重量有效 6 条、均值 37/6、中位数 4、四分位数 2.25 与 5.75、围栏 $[-3, 11]$；只标记`t08`。重量费用完整配对 6 条，相关系数在浮点容差内为 1。直方频数 3、2、0、0、1；延迟标签各 4 条。离散计数与标识应完全一致，浮点统计允许约 10^{-9} 绝对差异。

报告从问题走向证据与局限

一份数据探索报告至少说明：问题与分析单位、数据来源与范围、质量问题及处理、统计与图形证据、能够支持的结论、不能支持的结论和下一步核对需求。仅贴`describe()`和几张图，读者无法判断样本为何变少，也无法知道结论基于原始值还是填补值。

> **报告示例：本教学数据能够支持什么**
>
> 原始表 13 行，去除 1 条完全重复后 12 行，其中训练 8 行。训练重量有 6 个有效值；`t04`原缺失、`t07`为非法文本，分别保留审计原因。有效重量均值 6.166667 kg、中位数 4 kg；20 kg 超出 IQR 围栏，但无录入错误证据，保留并注明。
>
> 6 个完整配对呈精确正线性关系，这是教学构造的性质。区域 A/B 费用均值为 11.5/20.5 元，每组 4 条；两组重量组成不同，不能把均值差解释为区域因果效应。训练标签两类各 4 条，不能据此推断真实业务也平衡。
>
> 填补演示只用训练中位数 4 kg，并保留缺失指示。数据少、缺失原因未知、尾部仅 1 条，不能据此证明预测泛化、识别缺失机制或估计真实业务风险。后续需要核对采集流程并扩充数据。

报告中“相关系数为 1”要同时列配对数；“有异常”要指出采用何规则；“已清理”要列出删改数量；“区域差异”要指出可能混杂因素。解释的力度应与证据相称，不把描述性结果自动写成模型选择依据。

修改任务：只改变测试费用为 999，训练统计与四幅训练图应不变；把`t08`重量由

20 改 8，重新计算分位数、围栏和相关系数，费用 44 仍保留，原线性关系不再成立；在原版上只比较`ddof=0`与 1，说明有效分母为何分别为 6 与 5；另画相同数据的两种分箱，记录外观变化但不改变原始记录。

5.11 流程成本、常见误区与知识联系

对 n 行、d 字段的表格，读取与逐字段检查至少要接触 $O(nd)$ 个单元。均值和计数可单遍累计；排序型分位数的直接做法需要 $O(n \log n)$ 排序。分组与合并常用哈希或排序，实际成本取决于实现、键类型与输出规模；多对多连接的输出本身可能接近乘积规模。不能只因一行`merge`就认为成本恒定。

EDA 容易出错的地方包括：把自动类型推断当作数据字典；把零当缺失；把转换失败与原缺失混在一起；把`count`当总行数；先分别排序再按位置配对；按键去重时隐去冲突；让重复键扩行；看全部测试标签后反复调处理规则；从少量散点推断因果关系。

本章把第 3 章的文件读写与审计衔接起来，把第 4 章的布尔筛选扩展到带标签表格。相关系数中的离差乘积将在第 6 章变成内积；方差、协方差与抽样波动将在第 8 章系统解释。第 10 章会区分一次固定的数据合法性核对和从数据估计的预处理参数，第 14 章会解释为何频繁依据测试结果作选择会损害最终评价。

自检时应能说明：一行数据对应什么实体；标签与位置何时不同；每个统计量有多少有效记录；每次删改为何合理；合并行数为何变化；图的横纵轴、单位、分箱与样本范围是什么；哪些结论只是对本批样本的描述。

5.12 分层习题

以下编号为 5.1–5.12；统计题使用本章线性分位数约定，实验题从原版独立修改。

5.1 **概念**。区分 CSV、Series、DataFrame、行索引与业务标识。为什么“0012”不宜自动转成整数？

5.2 **索引**。给定索引 10、20、30，比较`loc[10:20]`与`iloc[0:2]`。两条索引分别为 a/b 与 b/a 的 Series 相加为何不等于转数组后相加？

5.3 **筛选**。写出选择区域 A 且重量至少 2 kg 的代码；明确是在原表赋值还是独立子表处理，解释为何不用 Python 的`and`。

5.4 **缺失**。文本列为“1”、空白、“bad”、“0”。分别标出原缺失、非法文本与有效零，写出保留失败原因的转换顺序。

5.5 **统计**。对 1、2、3、5、6、20 计算均值、中位数、两种分母的方差及四分位数。删除 20 后重算均值与中位数，说明信息变化。

5.6 **分组**。区域 A 有 4 行，其中 3 个有效重量；B 也如此。`size`与重量`count`分别是多少？若 A/B 费用均值 11.5/20.5，组数变为 1/4，总均值是多少？

5.7 **合并**。左表键 A 出现 2 次、B 出现 1 次，右表 A 出现 2 次、B 出现 1 次。普通内连接有多少行？若右表漏 B，左连接与内连接分别留下什么？

5.8 **相关**。完成例题 5.6，解释为何零相关不能推出独立。常数列的相关系数为什么不能按普通公式计算?

5.9 **图形**。6 条重量的分箱频数为 3、2、0、0、1，箱宽 5 kg。写出各箱密度与面积；解释柱形图和直方图的区别。

5.10 **边界**。为什么不能直接删除全部缺失行或所有超出 IQR 围栏的行？列出还需核对的三类信息。

5.11 **编程**。运行两个实验及答案脚本；改变测试标签，核对训练汇总不变；构造右表重复键与冲突标识，确认主动失败。

5.12 **综合报告**。用本章数据写一份含问题、范围、质量、两项证据、结论与局限的报告。不得把相关性或区域均值差改写成因果结论。

5.13 习题参考答案

5.1–5.4：结构、选择与转换

5.1 CSV 是文本文件格式；Series 是一维带标签序列；DataFrame 是带行列标签的二维表；行索引用于定位，不自动等于包裹身份；业务标识由数据字典规定唯一性。“0012”作为标识时前导零属于信息，转成 12 会改变表示，并可能与另一条“12”发生冲突。

5.2 在给定有序唯一索引下，二者都取前两行，但前者按标签且包含 20，后者按位置且不含位置 2。设数值分别 10/20 与 1/2，按标签得到 a 为 12、b 为 21；去标签按位置为 11、22。排序或重置索引后应重新核对对应依据。

5.3 先分别比较，再逐行取交集；独立子表用复制明确用途。

```
mask = (df["area"] == "A") & (df["weight"] >= 2)
selected = df.loc[mask, ["id", "weight"]].copy()
# 若目的改为修改原表，则用下面的明确定位赋值：
df.loc[mask, "weight"] = 0
```

Series 真假不是一个整体标量，逐行组合需要&。

5.4 先保留文本，再规范化本例首尾空白，记录`text.eq("")`；随后按规则转换，原非空但转换失败的是非法文本。零为有效数值，不是缺失。对文本无穷还应检查有限性。转换后同时保存原文本与原因，避免用一个 NaN 丢掉来源。

5.5–5.8：统计、合并与相关

5.5 均值 37/6，中位数 4，平方离差和 1481/6，方差分母 6 时 1481/36，分母 5 时 1481/30。$Q_1 = 2.25$、$Q_3 = 5.75$。删除 20 后剩 1、2、3、5、6，均值 17/5 = 3.4，中位数 3。变化说明尾部影响很大，却不能证明尾部本应删除；样本范围已改变。

5.6 每组`size`=4、重量`count`=3。费用都有效时，组数 1/4 对应总均值 $(11.5 + 4 \times 20.5)/5 = 18.7$；重量均值合成时要用重量有效数量。不能把不同字段的有效分母混用。

5.7 A 贡献 $2 \times 2 = 4$ 行，B 贡献 1 行，总 5 行。漏 B 时，左连接仍保留左表的 B

行，右侧说明缺失；内连接只剩 4 条 A 配对。约束多对一会拒绝 A 重复；未匹配 B 另由`indicator`检查，两个检查职责不同。

5.8 离差乘积和 0，两列离差平方和均非零，故 $r = 0$；但 $y = x^2$ 由 x 确定，存在明确非线性关系。独立是概率分布关系，在第 8 章定义，不能由一个线性统计量为零推出。常数列离差范数为 0，分母为 0，相关未定义；不应自动填成 0。

5.9–5.12：图形、程序与解释

5.9 密度依次为 $1/10, 1/15, 0, 0, 1/30\ \mathrm{kg}^{-1}$，面积依次为 $1/2, 1/3, 0, 0, 1/6$，和为 1。直方图的横轴是数值区间，柱宽具有含义；柱形图横轴是离散类别，通常通过柱高比较某项汇总。

5.10 需核对缺失发生的采集过程与群体差异，极端记录的原始凭据、单位与业务合理性，以及处理后样本范围是否仍符合预测目标。缺失可能不是随机发生，合法尾部也可能正是任务重点。处理规则应可追溯，并在后续训练流程中验证。

5.11 参考`ch05_solutions.py`。先从`load_tables()`取得清理表，再复制表并只改`split=="test"`行的费用；两次训练分组结果使用 pandas 的表格相等核对函数比较。重复键应为`MergeError`，冲突标识应为`ValueError`，不能只比较最终均值是否碰巧相同。

5.12 参考实验生成的`report.md`。至少列出 13 到 12 行的去重变化、训练 8 行与重量有效 6 条、缺失两种原因；证据可选相关系数 1 及 6 个配对、A/B 均值 11.5/20.5 且各 4 条。结论限于构造训练样本；局限包含小样本、缺失原因未知与尾部不足，不以测试标签调探索规则。

5.14 本章小结

表格处理同时管理数值、类型、标签与记录关系。合理流程先明确数据字典，再保留原始信息、核对字段、追踪缺失与重复、约束合并关系，最后进行统计与图形解释。每个统计量都应能回到对应记录、有效分母与处理规则。

探索报告把问题、证据和解释连接起来。描述性关系可以指导后续调查与建模，但因果判断、泛化评价和预处理参数选择需要各自的条件。图形清晰与代码运行成功，都不能替代这些条件。

6 线性代数复习

先修知识、学习目标与本章位置

本章复习已学过的线性代数，使用第 4 章的数组、矩阵乘法和形状检查。推导只要求基本代数、平方和与一元导数；矩阵微分从分量展开说明，第 7 章再系统讨论梯度和链式法则。

学习后应能解释内积、范数、距离与余弦；把矩阵理解为线性变换；用秩、列空间和零空间判断解的存在与唯一性；从投影推导最小二乘；辨认特征值、正定性、SVD 和条件数；推导平方损失的梯度并核对维度。本章为第 11 章线性回归、第 21 章 PCA、第 23 章反向传播与第 34 章低秩适配准备共同语言。

第 4 章说明了`X @ w`怎样计算，第 5 章说明了怎样把字段转成数值列。现在需要解释：矩阵的列代表哪些可组合的方向？当目标不在这些方向张成的空间中，拟合实际上在做什么？两列非常接近时，为什么预测可能稳定，参数却剧烈变化？这些问题需要把代数式、几何图像与数值计算放在一起。

本章只讨论有限维实向量与实矩阵。复数情况下内积需要共轭转置，本章不沿用实数公式直接处理复数。除说明数组实现外，向量均约定为列向量；数学上的转置不等同于 NumPy 一维数组的`.T`。

6.1 向量、坐标与统一维度约定

向量不仅是一列数字

向量（vector）可以表示带方向的几何量，也可以表示多个特征、模型参数或一批预测。坐标依赖所选基与字段顺序。包裹的重量和距离构成 $\mathbf{x} = (x_1, x_2)^{\mathrm{T}} \in \mathbb{R}^2$；两个分量单位不同，不应仅因放在同一向量中就认为其大小可直接比较。

$\mathbb{R}^d$ 表示由 d 个实数坐标组成的向量空间，d 为该空间的维数。若有 n 个样本、每样本 d 特征，则约定

$$X = \begin{pmatrix} \mathbf{x}_1^{\mathrm{T}} \\ \vdots \\ \mathbf{x}_n^{\mathrm{T}} \end{pmatrix} \in \mathbb{R}^{n \times d}, \qquad \mathbf{w} \in \mathbb{R}^d, \quad \mathbf{y} \in \mathbb{R}^n.$$

X 的行是样本，列是特征；$\mathbf{w}$ 为每个特征的系数；$X\mathbf{w}$ 为每个样本的线性得分或预测。本章用大写字母表示矩阵，粗体小写表示向量，普通小写表示标量。

线性组合是若干向量按系数缩放后求和，例如 $a_1\mathbf{v}_1 + a_2\mathbf{v}_2$。系数可正可负，可为零。张成空间（span）是所有这类组合组成的集合；它包含零向量，并对加法与数乘封闭。

基与坐标变化

线性无关表示只有所有系数都为 0 时，线性组合才等于零；若存在非全零系数组合为零，则线性相关。一组能张成空间的线性无关向量称为**基**（basis）。基的数量等于空间维数。

例如 $\mathbf{e}_1 = (1,0)^{\mathrm{T}}$、$\mathbf{e}_2 = (0,1)^{\mathrm{T}}$ 是 $\mathbb{R}^2$ 标准基。向量 $(3,2)^{\mathrm{T}} = 3\mathbf{e}_1 + 2\mathbf{e}_2$。换用 $\mathbf{b}_1 = (1,1)^{\mathrm{T}}$、$\mathbf{b}_2 = (1,-1)^{\mathrm{T}}$，同一向量为 $(5/2)\mathbf{b}_1 + (1/2)\mathbf{b}_2$。物体未变，坐标变了；不能拿不同基下的两组坐标直接相减。

第 5 章的列顺序是坐标约定的一部分。若训练时 X 列为重量、距离，预测时换成距离、重量，仍然可能得到同样形状的乘积，却已经把系数配给了错误特征。维度检查是必要条件，字段语义检查同样必要。

6.2 内积、范数、距离与余弦相似度

内积描述同向程度

两个 d 维实向量的**内积**（inner product，点积）定义为

$$\langle \mathbf{a}, \mathbf{b} \rangle = \mathbf{a}^{\mathrm{T}}\mathbf{b} = \sum_{j=1}^{d} a_j b_j \in \mathbb{R}.$$

内积对两个输入分别线性，交换输入不改变结果。对非零向量，它还满足几何关系

$$\mathbf{a}^{\mathrm{T}}\mathbf{b} = \|\mathbf{a}\|_2 \|\mathbf{b}\|_2 \cos\theta,$$

其中 θ 为夹角。内积为 0 的向量称为**正交**（orthogonal）；零向量与所有向量内积都为 0，但零向量没有确定方向或夹角。

平方和为何能产生距离和角度约束？对 $\mathbf{b} \neq 0$，任意实数 t 都有 $\|\mathbf{a} - t\mathbf{b}\|_2^2 \geq 0$。取 $t = (\mathbf{a}^{\mathrm{T}}\mathbf{b})/\|\mathbf{b}\|_2^2$，展开得到

$$\|\mathbf{a}\|_2^2 - \frac{(\mathbf{a}^{\mathrm{T}}\mathbf{b})^2}{\|\mathbf{b}\|_2^2} \geq 0.$$

于是

$$|\mathbf{a}^{\mathrm{T}}\mathbf{b}| \leq \|\mathbf{a}\|_2 \|\mathbf{b}\|_2,$$

这就是实向量的 **Cauchy–Schwarz 不等式**。它保证余弦落在 $[-1,1]$ 内；等号对应向量共线，包括相反方向。

范数测量大小，距离测量差

范数（norm）是符合非负性、零向量判别、绝对齐次性与三角不等式的大小度量；范数为 0 当且仅当向量为零。常见的 L_1、L_2 与 L_∞ 范数为

$$\|\mathbf{x}\|_1 = \sum_j |x_j|, \qquad \|\mathbf{x}\|_2 = \sqrt{\sum_j x_j^2}, \qquad \|\mathbf{x}\|_\infty = \max_j |x_j|.$$

齐次性指 $\|c\mathbf{x}\| = |c|\|\mathbf{x}\|$；三角不等式指 $\|\mathbf{a}+\mathbf{b}\| \le \|\mathbf{a}\|+\|\mathbf{b}\|$。由范数得到距离 $d(\mathbf{a},\mathbf{b}) = \|\mathbf{a}-\mathbf{b}\|$。平方欧氏距离 $\|\mathbf{a}-\mathbf{b}\|_2^2$ 便于优化和排序，但一般不满足距离的三角不等式，例如 0、1、2 之间有 $4 > 1 + 1$。

余弦相似度（cosine similarity）在两向量都非零时定义为

$$\cos(\mathbf{a},\mathbf{b}) = \frac{\mathbf{a}^{\mathrm{T}}\mathbf{b}}{\|\mathbf{a}\|_2\|\mathbf{b}\|_2}.$$

它关注方向，正比例缩放不改变结果，但负比例会翻转方向。对零向量应约定拒绝、单独处理或按应用定义特殊结果；随意给分母加小量会改变数学定义，也可能改变近零向量之间的排序。

例题 6.1：三种比较标准

取 $\mathbf{a} = (1,2)^{\mathrm{T}}$、$\mathbf{b} = (2,0)^{\mathrm{T}}$。求内积、两向量的三种范数、欧氏距离和余弦。比较 $\mathbf{a}$ 与 $10\mathbf{a}$ 的方向和距离。

解 内积为 2。$\mathbf{a}$ 的范数依次为 3、$\sqrt{5}$、2；$\mathbf{b}$ 的范数均为 2。差向量 $(-1,2)^{\mathrm{T}}$ 的欧氏范数为 $\sqrt{5}$，余弦为 $2/(2\sqrt{5}) = 1/\sqrt{5}$。$\mathbf{a}$ 与 $10\mathbf{a}$ 余弦为 1，欧氏距离为 $9\sqrt{5}$；方向相同不代表大小接近。

单位化 $\tilde{\mathbf{a}} = \mathbf{a}/\|\mathbf{a}\|_2$ 后，对两个非零向量有

$$\|\tilde{\mathbf{a}} - \tilde{\mathbf{b}}\|_2^2 = 2 - 2\cos(\mathbf{a},\mathbf{b}).$$

这是展开平方、利用单位范数得到的关系。仅在同样单位化条件下，按余弦从大到小与按欧氏距离从小到大排序一致；原向量直接比较时不保证一致。

第 5 章 Pearson 相关系数就是两个中心化数据向量的余弦。先减各自均值，再单位化，能消去平移与正尺度变化。原始向量余弦不减均值，因此两者不能互换。特征尺度变化也会改变原始欧氏距离，这正是第 4 章标准化需要明确的几何影响。

6.3 矩阵与线性变换

按行看得分，按列看组合

矩阵 $A \in \mathbb{R}^{m\times d}$ 定义映射 $T(\mathbf{x}) = A\mathbf{x} \in \mathbb{R}^m$。**线性变换**满足

$$T(\alpha\mathbf{x} + \beta\mathbf{z}) = \alpha T(\mathbf{x}) + \beta T(\mathbf{z}).$$

因此必有 $T(\mathbf{0}) = \mathbf{0}$。$A\mathbf{x} + \mathbf{b}$ 若 $\mathbf{b} \neq 0$，称为**仿射变换**（affine transformation），包含平移，不严格属于线性变换。

记 A 的第 j 列为 $\mathbf{a}_j$，第 i 行为 $\mathbf{r}_i^{\mathrm{T}}$，同一乘积可解释为

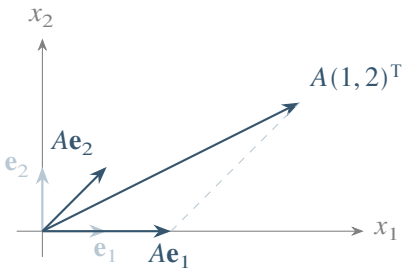
$$A\mathbf{x} = \sum_{j=1}^{d} x_j\mathbf{a}_j, \qquad (A\mathbf{x})_i = \mathbf{r}_i^{\mathrm{T}}\mathbf{x}.$$

前者按列解释输出由哪些方向组合，后者按行解释每个输出怎样求得分。对数据矩阵 X 与系数 $\mathbf{w}$，前者说明预测在特征列张成的空间中，后者说明每样本预测是特征与参数的内积。

例题 6.2：基向量决定变换

令 $A = \left(\begin{smallmatrix} 2 & 1 \\ 0 & 1 \end{smallmatrix}\right)$。求 $A\mathbf{e}_1$、$A\mathbf{e}_2$ 与 $A(1,2)^{\mathrm{T}}$，并解释矩阵两列的作用。

解 $A\mathbf{e}_1 = (2,0)^{\mathrm{T}}$、$A\mathbf{e}_2 = (1,1)^{\mathrm{T}}$，分别是两列。输出为 $1(2,0)^{\mathrm{T}} + 2(1,1)^{\mathrm{T}} = (4,2)^{\mathrm{T}}$。知道每个基向量变到哪里，就能由线性性确定任意输入的结果。



图中使用同一平面坐标展示输入基与变换后向量，虚线表示第二列方向的两倍。一般矩阵也可以在不同维度空间之间映射，不能都画成平面内拉伸。

矩阵乘法是变换的复合

若 $B : \mathbb{R}^d \to \mathbb{R}^k$，$A : \mathbb{R}^k \to \mathbb{R}^m$，则先 B 后 A 为 $AB : \mathbb{R}^d \to \mathbb{R}^m$。维度为 $(m \times k)(k \times d) = (m \times d)$。乘法通常不交换，因为顺序改变后变换不同，甚至无法相乘。

转置把行列交换，满足 $(AB)^{\mathrm{T}} = B^{\mathrm{T}}A^{\mathrm{T}}$。一个检验是考察元素：$(AB)_{ij} = \sum_k A_{ik}B_{kj}$；交换 i、j 后与右侧相符。**单位矩阵** I 保留向量不变；方阵 A 若有逆 A^{-1}，则 $A^{-1}A = AA^{-1} = I$，逆变换恢复原输入。长方形矩阵通常没有这种双侧逆。

6.4 秩、列空间、零空间与线性方程

秩表示独立方向的数量

A 的**列空间** $\mathcal{C}(A) = \{A\mathbf{x} : \mathbf{x} \in \mathbb{R}^d\}$ 是所有可能输出。**秩**（rank）为列空间维数，也等于行空间维数，满足 $\operatorname{rank}(A) \le \min(m, d)$。列数是存储的方向数量，秩是其中独立方向数量，两者可能不同。

零空间（null space）$\mathcal{N}(A) = \{\mathbf{x} : A\mathbf{x} = \mathbf{0}\}$ 表示在变换中消失的输入方向。若 $A\mathbf{x}_0 = \mathbf{b}$，那么任意 $\mathbf{z} \in \mathcal{N}(A)$ 都有 $A(\mathbf{x}_0 + \mathbf{z}) = \mathbf{b}$。因此

- $A\mathbf{x} = \mathbf{b}$ 可解，当且仅当 $\mathbf{b} \in \mathcal{C}(A)$；
- 在可解前提下，解唯一，当且仅当 $\mathcal{N}(A) = \{\mathbf{0}\}$，即满列秩；
- 输入维数满足 $d = \operatorname{rank}(A) + \dim \mathcal{N}(A)$。

最后一式称为秩与零度关系。直观上，输入空间被分成可辨认方向与被压掉方向；并不意味着任意给出的原始坐标列可以直接一一分开。

例题 6.3：重复特征造成不唯一

令

$$X = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 1 \\ 1 & 2 & 2 \end{pmatrix}.$$

求秩与一个非零零空间向量。若预测为截距加斜率乘 x，第二、三项系数分别能否唯一确定？

解 第一列常数方向与第二列不成比例，独立；第三列等于第二列，故秩为 2。$\mathbf{z} = (0, 1, -1)^{\mathrm{T}}$ 满足 $X\mathbf{z} = \mathbf{0}$。预测只依赖第一项系数和后两项系数之和。对任何 t，把后两项改成 $w_2 + t, w_3 - t$，预测均不变，参数不能唯一识别。

方阵满秩时可逆；有零特征值时不可逆。长方形满列秩 $m \geq d$ 保证不同参数产生不同输出，但任意目标未必在列空间。满行秩 $m \leq d$ 保证任意输出可达到，却通常存在多组输入。存在解、解唯一与拟合误差为零，是三个需要分别回答的问题。

数值秩还依赖容差

精确代数中的秩不需要阈值；浮点程序从数值上判断独立方向时，需要把很小的奇异值与误差尺度比较。`np.linalg.matrix_rank`采用数值容差；`lstsq`中的`rcond`也影响哪些方向视为可辨认。把 0 改成 10^{-16} 可能改变精确秩，却未必增加可可靠求解的信息。

因此报告数值秩时应同时记录形状、奇异值、尺度和容差规则。“程序报告秩为 2”不能直接推出原始测量系统严格只有两种独立变化。SVD 与阈值将在后文统一说明。

6.5 正交基与投影

投影到一条直线

给定非零方向 $\mathbf{a} \in \mathbb{R}^n$，寻找直线 $\{c\mathbf{a} : c \in \mathbb{R}\}$ 中离目标 $\mathbf{y}$ 最近的点。平方距离为

$$f(c) = \|\mathbf{y} - c\mathbf{a}\|_2^2 = \mathbf{y}^{\mathrm{T}}\mathbf{y} - 2c\mathbf{a}^{\mathrm{T}}\mathbf{y} + c^2\mathbf{a}^{\mathrm{T}}\mathbf{a}.$$

配方得

$$f(c) = \|\mathbf{a}\|_2^2 \left(c - \frac{\mathbf{a}^{\mathrm{T}}\mathbf{y}}{\|\mathbf{a}\|_2^2} \right)^2 + \|\mathbf{y}\|_2^2 - \frac{(\mathbf{a}^{\mathrm{T}}\mathbf{y})^2}{\|\mathbf{a}\|_2^2}.$$

第一项非负，最小时

$$c_* = \frac{\mathbf{a}^{\mathrm{T}}\mathbf{y}}{\mathbf{a}^{\mathrm{T}}\mathbf{a}}, \qquad \hat{\mathbf{y}} = \mathbf{a}c_*, \qquad \mathbf{a}^{\mathrm{T}}(\mathbf{y} - \hat{\mathbf{y}}) = 0.$$

最后一式说明误差垂直于允许移动的方向。若仍有该方向上的误差分量，就可以沿直线移动以进一步缩短距离。

投影到正交子空间

若 $Q \in \mathbb{R}^{n\times r}$ 的列正交且均为单位向量，则 $Q^{\mathrm{T}}Q = I_r$。这是**标准正交列**，Q 不一定是方阵。投影为

$$\hat{\mathbf{y}} = QQ^{\mathrm{T}}\mathbf{y}, \qquad P = QQ^{\mathrm{T}} \in \mathbb{R}^{n\times n}. \tag{6.1}$$

每项 $\mathbf{q}_j^{\mathrm{T}}\mathbf{y}$ 是沿第 j 个单位方向的坐标，再乘 $\mathbf{q}_j$ 并求和，得到子空间内部分。投影矩阵满足

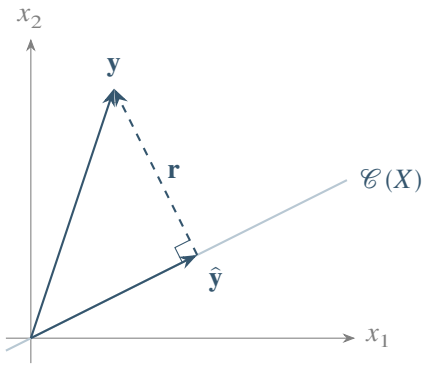
$$P^{\mathrm{T}} = P, \qquad P^2 = Q(Q^{\mathrm{T}}Q)Q^{\mathrm{T}} = P.$$

后者称为**幂等**：已在子空间中的投影再次投影不变。残差 $\mathbf{r} = (I - P)\mathbf{y}$ 满足 $Q^{\mathrm{T}}\mathbf{r} = 0$。若 $r < n$，QQ^{T} 是投影而不是 I_n；不能把 $Q^{\mathrm{T}}Q = I_r$ 颠倒为 $QQ^{\mathrm{T}} = I_n$。

对任意子空间内向量 $\mathbf{z}$，$\hat{\mathbf{y}} - \mathbf{z}$ 与残差正交，故

$$\|\mathbf{y} - \mathbf{z}\|_2^2 = \|\mathbf{r}\|_2^2 + \|\hat{\mathbf{y}} - \mathbf{z}\|_2^2.$$

这给出最短距离与投影唯一性的证明，不依赖图形维数是否能画出来。



图为二维几何示意：取目标 $(1,3)^{\mathrm{T}}$ 与沿 $(2,1)^{\mathrm{T}}$ 的子空间，投影为 $(2,1)^{\mathrm{T}}$，残差为 $(-1,2)^{\mathrm{T}}$。虚线误差与子空间正交；右角标记说明最短距离条件。实际拟合中目标在 n 维样本空间，几何条件仍相同。

例题 6.4：在三维空间投影到一条线

令 $\mathbf{q} = (1,1,0)^{\mathrm{T}}/\sqrt{2}$，$\mathbf{y} = (2,0,3)^{\mathrm{T}}$。求投影、残差、投影矩阵，并核对正交分解。

解 $\mathbf{q}^{\mathrm{T}}\mathbf{y} = \sqrt{2}$，投影为 $(1,1,0)^{\mathrm{T}}$，残差为 $(1,-1,3)^{\mathrm{T}}$。

$$P = \mathbf{q}\mathbf{q}^{\mathrm{T}} = \begin{pmatrix} 1/2 & 1/2 & 0 \\ 1/2 & 1/2 & 0 \\ 0 & 0 & 0 \end{pmatrix}.$$

$\mathbf{q}^{\mathrm{T}}\mathbf{r} = 0$，且 $\|\mathbf{y}\|_2^2 = 13 = 2 + 11 = \|\hat{\mathbf{y}}\|_2^2 + \|\mathbf{r}\|_2^2$。原始第三坐标 3 完全位于这条线的正交补中，不会被投影“解释”。

怎样获得正交列：QR 的意义

QR 分解把满列秩 $X \in \mathbb{R}^{n\times d}$（$n \geq d$）写成 $X = QR$，其中 $Q \in \mathbb{R}^{n\times d}$ 列标准正交，$R \in \mathbb{R}^{d\times d}$ 为可逆上三角矩阵。Q 描述相同列空间的正交坐标，R 描述从原系数到正交坐标的变换。

逐列减去前面方向上的投影再归一化，是构造正交基的一种直观方法，称为 Gram–Schmidt 正交化。近相关列可能使朴素实现出现明显舍入误差；实际库通常使用更稳定的变换实现 QR。这里理解分解的意义，数值求解采用库接口，不把短教学实现当作稳定性充分的工业实现。

6.6 最小二乘：从几何到正规方程

目标可能不在列空间

设 $X \in \mathbb{R}^{n\times d}$、$\mathbf{y} \in \mathbb{R}^n$，寻找 $\mathbf{w} \in \mathbb{R}^d$ 使预测 $X\mathbf{w}$ 接近目标。**最小二乘**（least squares）问题为

$$\min_{\mathbf{w}} \|X\mathbf{w} - \mathbf{y}\|_2^2. \tag{6.2}$$

“二乘”指误差平方；本章使用普通未加权欧氏距离，每样本贡献相同。若误差单位或可信度不同，需要另外说明权重或噪声假设，第 11 章再讨论回归建模。

所有预测都在 $\mathcal{C}(X)$ 中，因此最优预测是 $\mathbf{y}$ 在该子空间上的正交投影。设残差约定为 $\mathbf{r} = \mathbf{y} - X\mathbf{w}$，最优条件是残差与每一列正交：

$$X^{\mathrm{T}}\mathbf{r} = \mathbf{0} \quad \Longleftrightarrow \quad X^{\mathrm{T}}X\mathbf{w} = X^{\mathrm{T}}\mathbf{y}. \tag{6.3}$$

这称为**正规方程**（normal equations）；normal 在这里与几何垂直有关，不表示误差必须服从正态分布。要解释回归估计的统计性质，可以引入概率假设；定义和求解这个平方距离问题本身不需要正态假设。

为什么正交条件足够？若 $\mathbf{w}_*$ 满足它，对任意参数变化 $\mathbf{h}$ 有

$$\begin{aligned}\|\mathbf{y} - X(\mathbf{w}_* + \mathbf{h})\|_2^2 &= \|\mathbf{r}_* - X\mathbf{h}\|_2^2 \\ &= \|\mathbf{r}_*\|_2^2 - 2\mathbf{h}^{\mathrm{T}}X^{\mathrm{T}}\mathbf{r}_* + \|X\mathbf{h}\|_2^2 \\ &= \|\mathbf{r}_*\|_2^2 + \|X\mathbf{h}\|_2^2 \geq \|\mathbf{r}_*\|_2^2.\end{aligned}$$

因此所有满足正规方程的参数都是全局最优解。若 X 满列秩，非零 $\mathbf{h}$ 不会被 X 消去，解唯一；若秩亏，沿零空间方向移动不改变最优预测。

满列秩时的表达式与计算方法

对任意 $\mathbf{v}$，有 $\mathbf{v}^{\mathrm{T}}X^{\mathrm{T}}X\mathbf{v} = \|X\mathbf{v}\|_2^2$。满列秩时，非零向量对应严格正数，因此 $X^{\mathrm{T}}X$ 可逆。形式上

$$\mathbf{w}_* = (X^{\mathrm{T}}X)^{-1}X^{\mathrm{T}}\mathbf{y}, \quad P = X(X^{\mathrm{T}}X)^{-1}X^{\mathrm{T}}.$$

这是理论表达式，实际计算通常不显式求逆。即便使用正规方程，也应`solve(X.T @ X, X.T @ y)`求解线性系统；更一般地，优先`np.linalg.lstsq`，避免平方条件数带来的误差风险。

用 QR 可把目标分解为

$$\|QR\mathbf{w}-\mathbf{y}\|_2^2=\|R\mathbf{w}-Q^{\mathrm{T}}\mathbf{y}\|_2^2+\|(I-QQ^{\mathrm{T}})\mathbf{y}\|_2^2.$$

第二项不依赖参数，第一项可通过上三角方程 $R\mathbf{w}=Q^{\mathrm{T}}\mathbf{y}$ 置零。这样不必形成 $X^{\mathrm{T}}X$。对稠密 $n\ge d$ 输入，常见分解求解约需 $O(nd^2)$ 量级计算，具体成本随算法与矩阵结构变化。

例题 6.5：完整手算带截距的直线拟合

对输入 $x=0,1,2$ 与目标 $y=1,2,2$，拟合 $\hat{y}=b+ax$。写出设计矩阵，解正规方程，计算预测、残差与平方和，并核对正交性。

解 把参数写成 $\mathbf{w}=(b,a)^{\mathrm{T}}$，设计矩阵为

$$X=\begin{pmatrix}1&0\\1&1\\1&2\end{pmatrix},\qquad \mathbf{y}=\begin{pmatrix}1\\2\\2\end{pmatrix}.$$

第一列常数 1 负责截距。于是

$$X^{\mathrm{T}}X=\begin{pmatrix}3&3\\3&5\end{pmatrix},\qquad X^{\mathrm{T}}\mathbf{y}=\begin{pmatrix}5\\6\end{pmatrix}.$$

方程为 $3b+3a=5$、$3b+5a=6$，相减得 $a=1/2$，再得 $b=7/6$。预测与残差为

$$\hat{\mathbf{y}}=\begin{pmatrix}7/6\\5/3\\13/6\end{pmatrix},\qquad \mathbf{r}=\begin{pmatrix}-1/6\\1/3\\-1/6\end{pmatrix}.$$

残差和为 0，输入与残差的内积为 $0(-1/6)+1(1/3)+2(-1/6)=0$，故 $X^{\mathrm{T}}\mathbf{r}=0$。平方和为 $1/36+1/9+1/36=1/6$，MSE 为 $1/18$。残差不为零，因为这三个点不在一条直线上；参数唯一，因为两列线性无关。

“带截距时残差和为零”来自设计矩阵含常数列与未加权最小二乘最优条件。去掉截距、改变权重、加入参数约束或只做尚未收敛的迭代时，不能直接沿用该结论。

秩亏解与最小范数选择

把例题 6.5 的第二列复制一遍，预测只依赖 w_2+w_3。最优参数满足 $w_1=7/6$、$w_2+w_3=1/2$，有无穷多组。预测向量仍唯一，因为它是同一子空间中的正交投影。

如果额外要求参数欧氏范数最小，则后两项应均分为 $1/4,1/4$。证明是令 $w_2=t, w_3=1/2-t$，有

$$t^2+(1/2-t)^2=2(t-1/4)^2+1/8,$$

最小值在 $t=1/4$。这种选择给出了唯一代表，但没有证明两列特征具有独立可解释的作用。伪逆将在 SVD 之后给出一般表达。

6.7 特征值、二次型与正定性

特征方向保持方向不变

方阵 $A \in \mathbb{R}^{d\times d}$ 的**特征向量**（eigenvector）为满足

$$A\mathbf{v} = \lambda\mathbf{v}, \qquad \mathbf{v} \neq \mathbf{0}$$

的向量，λ 为对应**特征值**（eigenvalue）。在此方向，变换只作缩放或翻转。零向量被排除，否则任何数都能满足等式，定义失去辨别力。

一般实方阵可能有复特征值，也可能缺少足够多的线性无关特征向量；不能对任意方阵直接写正交特征分解。**实对称矩阵** $H = H^{\mathrm{T}}$ 具有实特征值和一组标准正交特征向量，能写成

$$H = Q\Lambda Q^{\mathrm{T}}, \quad Q^{\mathrm{T}}Q = QQ^{\mathrm{T}} = I, \quad \Lambda = \mathrm{diag}(\lambda_1, \dots, \lambda_d).$$

diag 表示把数放在主对角线上。本节只对这类对称矩阵使用正交谱分解。数值上可用 `np.linalg.eigh`或只求值的`eigvalsh`；它们利用对称结构，区别于一般`eig`。

二次型在各方向的符号

二次型 $q(\mathbf{x}) = \mathbf{x}^{\mathrm{T}}H\mathbf{x}$ 是标量。令 $\mathbf{z} = Q^{\mathrm{T}}\mathbf{x}$，则

$$q(\mathbf{x}) = \mathbf{z}^{\mathrm{T}}\Lambda\mathbf{z} = \sum_j \lambda_j z_j^2.$$

于是对实对称 H，有如下对应：

性质	对非零向量的条件	特征值条件
正定	$\mathbf{x}^{\mathrm{T}}H\mathbf{x} > 0$	所有 $\lambda_j > 0$
半正定	$\mathbf{x}^{\mathrm{T}}H\mathbf{x} \geq 0$	所有 $\lambda_j \geq 0$
不定	有正值方向也有负值方向	至少一个正值、一个负值

半正定允许某些非零方向的二次型为 0，因此不保证可逆。负定与半负定分别反转符号。只看矩阵元素是否为正不能判断正定；只看行列式为正也不充分。

例题 6.6：二次型的主方向

令 $H = \left(\begin{smallmatrix} 2 & 1 \\ 1 & 2 \end{smallmatrix}\right)$。求特征值、单位特征向量与二次型表达，说明是否正定。再判断 $\left(\begin{smallmatrix} 1 & 2 \\ 2 & 1 \end{smallmatrix}\right)$。

解 第一矩阵作用于 $(1,1)^{\mathrm{T}}$ 得到 3 倍，作用于 $(1,-1)^{\mathrm{T}}$ 得到 1 倍；单位化后为 $\mathbf{q}_1 = (1,1)^{\mathrm{T}}/\sqrt{2}$ 与 $\mathbf{q}_2 = (1,-1)^{\mathrm{T}}/\sqrt{2}$。设 $z_1 = (x_1+x_2)/\sqrt{2}, z_2 = (x_1-x_2)/\sqrt{2}$，则

$$\mathbf{x}^{\mathrm{T}}H\mathbf{x} = 3z_1^2 + z_2^2 > 0 \quad (\mathbf{x} \neq 0).$$

第二矩阵沿同样两个方向的特征值为 3 和 -1，二次型为 $3z_1^2 - z_2^2$，是不定矩阵。其所有元素均为正，仍有负二次型方向。

$X^{\mathrm{T}}X$ 称为列向量的 **Gram 矩阵**，元素为列间内积。由平方范数恒非负可知它总半正定，满列秩时才正定。它在平方损失中描述参数变化引起的曲率；第 7 章会用 Hessian 把这一说法写成导数结论。

6.8 奇异值分解：长方形矩阵的方向与尺度

定义与形状

奇异值分解（singular value decomposition，SVD）适用于任意实矩阵 $A \in \mathbb{R}^{m\times d}$。完整形式为

$$A = U\Sigma V^{\mathrm{T}}, \quad U \in \mathbb{R}^{m\times m}, \quad V \in \mathbb{R}^{d\times d}, \quad \Sigma \in \mathbb{R}^{m\times d}.$$

U 和 V 为方形正交矩阵，Σ 只有主对角线可能非零，其 $k = \min(m, d)$ 个非负数 $\sigma_1 \geq \cdots \geq \sigma_k \geq 0$ 称为**奇异值**（singular values）。对长方形对角阵，主对角线之后的整行或整列为零。

NumPy 的`full_matrices=False`给出经济形状：

$$U_k : (m, k), \quad \Sigma_k : (k, k), \quad V_k^{\mathrm{T}} : (k, d).$$

它保留 k 个方向，可能仍包含零奇异值；不等同于只保留 r 个非零方向的秩分解，也不等同于只保留更小 q 的近似。NumPy 实际返回一维`s:(k,)`，不是对角矩阵。

```
A = np.array([[3., 0.], [0., 1.], [0., 0.]])
U, s, Vt = np.linalg.svd(A, full_matrices=False)
reconstructed = (U * s) @ Vt
print(U.shape, s.shape, Vt.shape)
print(s)
```

形状为`(3,2)`、`(2,)`、`(2,2)`，奇异值 3 与 1。`U * s`按列缩放 U，等价于 $U\,\mathrm{diag}(\mathbf{s})$；如果写`s[:, None] * U`，一般缩放方向错误或广播失败。`Vt`已经是 V^{T}，重建时不要再转置一次。

旋转坐标、缩放，再变到输出坐标

乘积 $A\mathbf{x} = U\Sigma V^{\mathrm{T}}\mathbf{x}$ 可分三步：V 转置把输入表示到右奇异向量坐标；Σ 沿这些方向缩放或消去；U 把结果表示到输出空间。U/V 中的正交变换保长度，可能包括反射，不能全称为严格的旋转。

对第 j 个右奇异向量 $\mathbf{v}_j$，有

$$A\mathbf{v}_j = \sigma_j \mathbf{u}_j, \qquad A^{\mathrm{T}}A\mathbf{v}_j = \sigma_j^2 \mathbf{v}_j.$$

因此奇异值是 Gram 矩阵非负特征值的平方根。最大奇异值描述单位输入的最大输出长度，零奇异值对应被消去的方向。非零奇异值数量是精确秩；对应左奇异向量张成列空间。

伪逆与最小范数最小二乘

设 r 个奇异值非零，秩分解为 $A = U_r \Sigma_r V_r^{\mathrm{T}}$。**Moore–Penrose 伪逆**为

$$A^{+} = V_r \Sigma_r^{-1} U_r^{\mathrm{T}} \in \mathbb{R}^{d \times m}.$$

它只对非零奇异值取倒数，零方向保持为零；不是对矩阵每个元素取倒数。若 $\mathbf{b} \in \mathbb{R}^m$，则

$$\mathbf{x}_* = A^{+}\mathbf{b}, \qquad A\mathbf{x}_* = U_r U_r^{\mathrm{T}}\mathbf{b}.$$

后者正是到列空间的投影。任意最小二乘解可写成 $\mathbf{x}_* + \mathbf{z}$，其中 $\mathbf{z} \in \mathcal{N}(A)$。$\mathbf{x}_*$ 在右奇异向量的非零方向中，与零空间正交，因此

$$\|\mathbf{x}_* + \mathbf{z}\|_2^2 = \|\mathbf{x}_*\|_2^2 + \|\mathbf{z}\|_2^2,$$

证明了它是最小范数解。

实际计算对很小的奇异值使用阈值，避免对近零值取极大倒数。`np.linalg.lstsq` 直接求最小范数最小二乘解；本章设置`rcond=None`，同时返回残差数组、数值秩与奇异值。返回残差数组为空可能是秩亏或形状条件不满足该返回形式，不能直接理解成拟合误差为零；应显式算`b - A @ x`。

低秩近似及误差含义

SVD 还可写为若干秩一外积之和：

$$A = \sum_{j=1}^{k} \sigma_j \mathbf{u}_j \mathbf{v}_j^{\mathrm{T}}.$$

内积 $\mathbf{u}^{\mathrm{T}}\mathbf{v}$ 是标量；外积 $\mathbf{u}\mathbf{v}^{\mathrm{T}}$ 是矩阵，两者不能混淆。保留前 q 项得到 A_q，秩至多 q。它在 **Frobenius 范数**下具有最优低秩近似性质：

$$\|A\|_F = \sqrt{\sum_{i,j} A_{ij}^2}, \qquad \|A - A_q\|_F^2 = \sum_{j=q+1}^{k} \sigma_j^2.$$

误差公式来自各外积在矩阵内积下标准正交。最优性质的完整证明不在本章要求内，但必须限定误差度量：它不保证任何下游分类指标或语义相似度最优。奇异值有并列时，最优近似表示可能不唯一。

> **例题 6.7：SVD、伪逆与截断**
> 对 $A = \left(\begin{smallmatrix} 3 & 0 \\ 0 & 1 \\ 0 & 0 \end{smallmatrix}\right)$，给出经济 SVD、伪逆、对 $\mathbf{b} = (3,2,4)^{\mathrm{T}}$ 的最小二乘解，以及秩一近似误差。

解 可取 U_k 为三维前两个标准基组成的矩阵、$\Sigma_k = \mathrm{diag}(3,1)$、$V = I_2$。伪逆为

$$A^{+} = \begin{pmatrix} 1/3 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}, \quad \mathbf{x}_* = (1,2)^{\mathrm{T}}.$$

预测为 $(3,2,0)^{\mathrm{T}}$，第三项 4 不能由 A 的列表示，残差范数 4。秩一近似仅保留 3 对应项，得到第一元素 3、其余 0 的矩阵；Frobenius 误差为 1，平方误差为 1。这里矩阵近似误差与拟合 b 的误差是两个不同对象。

低秩近似为第 21 章 PCA 提供工具，第 34 章会用低秩矩阵表示参数更新；不能仅由“低秩”推出压缩后一定保留任务所需信息。实际库的奇异向量符号可能同时翻转，重建矩阵不变，核对时应比较重建、子空间与奇异值，不强制某一列符号固定。

6.9 条件数：问题的敏感性与算法的稳定性

微小输入变化可能引起很大解变化

对可逆方阵 A，采用欧氏范数对应的**谱范数** $\|A\|_2 = \max_{\|\mathbf{x}\|_2=1} \|A\mathbf{x}\|_2 = \sigma_{\max}$，**条件数**定义为

$$\kappa_2(A) = \|A\|_2\|A^{-1}\|_2 = \frac{\sigma_{\max}}{\sigma_{\min}} \geq 1.$$

条件数大表示某些方向被强烈压缩，反向求解时误差可能被放大。奇异矩阵没有有限的可逆求解条件数。满列秩长方形矩阵也常用最大与最小奇异值之比描述数值条件，但本节扰动上界首先针对可逆方阵。

若 A 固定，$A\mathbf{x} = \mathbf{b}$、$A(\mathbf{x} + \delta\mathbf{x}) = \mathbf{b} + \delta\mathbf{b}$，则 $\delta\mathbf{x} = A^{-1}\delta\mathbf{b}$。结合 $\|\mathbf{b}\| \leq \|A\|\|\mathbf{x}\|$，得到在 $\mathbf{b} \neq 0$ 时

$$\frac{\|\delta\mathbf{x}\|_2}{\|\mathbf{x}\|_2} \leq \kappa_2(A)\frac{\|\delta\mathbf{b}\|_2}{\|\mathbf{b}\|_2}.$$

这是最坏方向的上界，不是每次扰动必然放大这么多。若 A 本身也被扰动，还需要额外条件与误差项，不能直接把本式当作所有误差的完整界。

例题 6.8：残差很小，解仍敏感

令 $A = \mathrm{diag}(1, 10^{-8})$，$\mathbf{b} = (1,0)^{\mathrm{T}}$。把右端改为 $\mathbf{b} + \delta\mathbf{b} = (1, 10^{-8})^{\mathrm{T}}$，比较两次解、相对变化与条件数。

解 原解 $(1,0)^{\mathrm{T}}$，新解 $(1,1)^{\mathrm{T}}$。右端相对变化为 10^{-8}，解相对变化为 1，放大倍数 10^8。奇异值 1 与 10^{-8}，条件数 10^8，此例达到上界。两次解都可对各自方程产生极小残差，却不代表原始问题对输入误差不敏感。

正规方程为什么放大条件数

若 X 满列秩，其奇异值为 $\sigma_1, \ldots, \sigma_d$，则 $X^{\mathrm{T}}X$ 特征值为 $\sigma_1^2, \ldots, \sigma_d^2$，故

$$\kappa_2(X^{\mathrm{T}}X) = \kappa_2(X)^2.$$

当 $\kappa_2(X) = 10^8$ 时，Gram 矩阵条件数约 10^{16}，已接近`float64`舍入尺度的倒数。显式形成 Gram 矩阵可能丢失原先尚可辨认的小方向；再求逆不能恢复这些信息。

病态（ill-conditioned）描述问题本身对扰动敏感；**数值稳定性**描述算法怎样传播舍入误差。稳定算法不能消除问题固有的敏感性，却能避免额外放大。QR 或 SVD 一般优于直接形成正规方程，但仍应检查尺度、奇异值与残差。

特征缩放可能改善仅由单位差异造成的条件问题；它不能自动消除近重复列。把全部 A 乘同一非零标量不会改变奇异值比，而逐列缩放会改变坐标度量。第 11 章的岭回归会用正则化抑制小奇异值方向，但同时改变优化目标，不是“免费修复”原最小二乘问题。

6.10 矩阵微分：从标量输出核对梯度

微分与梯度的约定

本节只对标量函数 $f:\mathbb{R}^d\to\mathbb{R}$ 求导，梯度约定为列向量：

$$\nabla_{\mathbf{x}} f=\begin{pmatrix}\partial f/\partial x_1\\ \vdots\\ \partial f/\partial x_d\end{pmatrix},\qquad \mathrm{d}f=(\nabla_{\mathbf{x}} f)^{\mathrm{T}}\mathrm{d}\mathbf{x}.$$

$\mathrm{d}f$ 是输入微小变化的线性部分；后式乘法维度为 $(1\times d)(d\times 1)=1\times 1$。不同教材可能把导数排成行向量，因此阅读公式时先核对约定，不仅看转置符号。

若 $f(\mathbf{x})=\mathbf{a}^{\mathrm{T}}\mathbf{x}=\sum_j a_j x_j$，则 $\partial f/\partial x_j=a_j$，梯度为 $\mathbf{a}$。若 $f=\mathbf{x}^{\mathrm{T}}A\mathbf{x}=\sum_{i,j}x_iA_{ij}x_j$，对第 k 项求导有两条来源：

$$\frac{\partial f}{\partial x_k}=\sum_j A_{kj}x_j+\sum_i x_iA_{ik},$$
$$\nabla_{\mathbf{x}} f=(A+A^{\mathrm{T}})\mathbf{x}.$$

只有 A 对称时才可简化成 $2A\mathbf{x}$。特别地，$\nabla\|\mathbf{x}\|_2^2=2\mathbf{x}$，而不是误用范数本身的导数。$\|\mathbf{x}\|_2$ 在非零处梯度为 $\mathbf{x}/\|\mathbf{x}\|_2$，在零处不可微；平方范数处处可微。

平方损失的梯度保留每一步

定义 $n\ge 1$，$X:(n,d)$、$\mathbf{w}:(d,1)$、$\mathbf{y}:(n,1)$，并令

$$L(\mathbf{w})=\frac{1}{2n}\|X\mathbf{w}-\mathbf{y}\|_2^2,\quad \mathbf{e}=X\mathbf{w}-\mathbf{y}.$$

此处 $\mathbf{e}$ 为预测减真实值，与前面的残差 $\mathbf{r}$ 方向相反。按分量有

$$e_i=\sum_{j=1}^{d}X_{ij}w_j-y_i,$$
$$\frac{\partial L}{\partial w_k}=\frac{1}{2n}\sum_i 2e_i\frac{\partial e_i}{\partial w_k}=\frac{1}{n}\sum_i e_iX_{ik}.$$

因此

$$\boxed{\nabla_{\mathbf{w}}L=\frac{1}{n}X^{\mathrm{T}}(X\mathbf{w}-\mathbf{y})}. \tag{6.4}$$

外部 X^{T} 把 n 维样本误差汇总成 d 维参数导数。符号来自误差定义，系数 $1/n$ 来自所选损失归一化；若损失没有 1/2，梯度会多 2，若用误差平方和而非均值，又会多 n。

矩阵微分可再次核对：$\mathrm{d}\mathbf{e} = X\mathrm{d}\mathbf{w}$，$\mathrm{d}(\mathbf{e}^{\mathrm{T}}\mathbf{e}) = 2\mathbf{e}^{\mathrm{T}}\mathrm{d}\mathbf{e}$，于是

$$\mathrm{d}L = \frac{1}{n}\mathbf{e}^{\mathrm{T}}X\mathrm{d}\mathbf{w} = \left(\frac{1}{n}X^{\mathrm{T}}\mathbf{e}\right)^{\mathrm{T}}\mathrm{d}\mathbf{w}.$$

一次预测与梯度计算对稠密 X 约需 $O(nd)$ 运算，除输入矩阵外主要存储 n 维误差和 d 维梯度；不需要构造 $d \times d$ 的 Gram 矩阵。

与梯度定义比较即得同一结果。令梯度为 0，再次得到正规方程，几何正交条件与导数条件在这里一致。

> **例题 6.9：手算梯度与形状**
>
> 使用例题 6.5 的 X 与 y，在 $\mathbf{w} = (1/2, 1)^{\mathrm{T}}$ 计算预测、误差、损失 L 与梯度。分别说明两项梯度与哪些变化方向有关。

解 预测为 $(1/2, 3/2, 5/2)^{\mathrm{T}}$，误差为 $(-1/2, -1/2, 1/2)^{\mathrm{T}}$，平方和 $3/4$，故 $L = (3/4)/6 = 1/8$。

$$X^{\mathrm{T}}\mathbf{e} = \begin{pmatrix} -1/2 \\ 1/2 \end{pmatrix}, \qquad \nabla L = \begin{pmatrix} -1/6 \\ 1/6 \end{pmatrix}.$$

第一项对应截距变化，沿负梯度会提高截距；第二项对应斜率变化，沿负梯度会减小斜率。梯度给局部变化方向，不能只根据一项误差正负决定最终参数。第 7 章会讨论步长及下降条件。

多输出参数与 Frobenius 内积

若 $W \in \mathbb{R}^{d\times k}$、$Y \in \mathbb{R}^{n\times k}$，预测为 XW，定义

$$L(W) = \frac{1}{2n}\|XW - Y\|_F^2.$$

这里按样本数 n 归一化，未再除输出数 k。对每个输出列应用同样推导，得到

$$\nabla_W L = \frac{1}{n}X^{\mathrm{T}}(XW - Y) \in \mathbb{R}^{d\times k}.$$

梯度与参数同形状。若代码`np.mean((X @ W - Y)**2)/2`对所有 nk 个元素求平均，则相应梯度分母应为 nk；不能在正文、代码和梯度中混用两个损失定义。

矩阵微分中可用迹（trace）表示 Frobenius 内积：$\mathrm{tr}(A) = \sum_i A_{ii}$，$\langle G, \mathrm{d}W\rangle_F = \mathrm{tr}(G^{\mathrm{T}}\mathrm{d}W)$。只有乘法维度允许时才能循环移动迹中的因子，例如 $\mathrm{tr}(AB) = \mathrm{tr}(BA)$；不能从迹的等式推出 $AB = BA$。本章后续实验不要求掌握复杂迹运算，保留此入口用于阅读深度学习公式。

6.11 实验 6.1：几何条件、QR 与秩亏解

入口为配套实验`/ch06_geometry.py`，只依赖 NumPy，数据在脚本中固定，无需下载。运行：

```
python3 ch06_geometry.py
```

脚本先对例题 6.5 调用最小二乘求解，再显式计算残差和平方和；另外通过 QR 解上三角方程，与最小二乘结果比较；构造 $P = QQ^{\mathrm{T}}$，检查对称、幂等及 $P\mathbf{y} = X\mathbf{w}$。所有这些核对回答的是不同问题，单看参数打印值不足以验证投影关系。

```
X = np.array([[1., 0.], [1., 1.], [1., 2.]])
y = np.array([1., 2., 2.])
w, residuals, rank, singular = np.linalg.lstsq(X, y, rcond=None)
r = y - X @ w
Q, R = np.linalg.qr(X, mode="reduced")
w_qr = np.linalg.solve(R, Q.T @ y)
P = Q @ Q.T
np.testing.assert_allclose(X.T @ r, 0, atol=1e-12)
np.testing.assert_allclose(w_qr, w, atol=1e-12)
```

NumPy 的`y,w,r`在这里用一维数组实现数学列向量，形状为`(3,)`、`(2,)`、`(3,)`；结果约定要与第 4 章一致。若任意把 y 改为`(3,1)`，再减一维预测，会广播成错误的 3 乘 3 矩阵。

预期参数 $(7/6, 1/2)$，预测 $(7/6, 5/3, 13/6)$，残差 $(-1/6, 1/3, -1/6)$，平方和 $1/6$，数值秩 2；$X^{\mathrm{T}}\mathbf{r}$ 两项约为 0。数值比较允许 10^{-12} 量级绝对误差，符号或最后几位舍入可变化。

随后复制第二列，求解三参数问题。预期最小范数参数为 $(7/6, 1/4, 1/4)$，数值秩仍 2；残差返回数组为空，但显式残差平方和仍 $1/6$。再加零空间向量 $(0, 1, -1)$，得到 $(7/6, 5/4, -3/4)$，预测不变、参数范数增加。原最小范数约 1.219062，新范数约 1.867113。

修改任务：只把最后目标 2 改 3，三个点变为直线 $y = 1 + x$，应得参数 $(1, 1)$、误差接近 0；去掉常数列，手算单参数斜率 $\sum_i x_i y_i / \sum_i x_i^2 = 6/5$，残差和不再为 0；给重复列换一个非零比例，解释为何零空间方向随比例变化；不用 P 直接计算`Q @ (Q.T @ y)`，说明避免了哪些存储。

完整 P 含 n^2 元素，大数据中不应仅为做预测而显式构造它。$Q(Q^{\mathrm{T}}\mathbf{y})$ 只需分两次乘法，仍得到同一投影。数学上存在的矩阵表达，不一定是合适的程序存储结构。

6.12 实验 6.2：SVD、敏感性与梯度核对

主入口为配套实验`/ch06_svd.py`，只用 NumPy。

答案核对入口为`ch06_solutions.py`。

```
python3 ch06_svd.py
python3 ch06_solutions.py
```

先对例题 6.7 的矩阵求经济 SVD，检查重建与秩一近似误差；再运行例题 6.8 的扰动，记录 A 与 Gram 矩阵条件数；最后对例题 6.9 的损失核对解析梯度与数值梯度。

有限差分通过很小的输入变化近似导数。对参数第 j 项，中心差分为

$$g_j^{\mathrm{FD}} = \frac{L(\mathbf{w} + h\mathbf{e}_j) - L(\mathbf{w} - h\mathbf{e}_j)}{2h}.$$

本实验用 $h = 10^{-6}$。它是核对公式的数值办法，不是每次训练都逐参数调用两遍损失的高效训练方法。步长太大引入近似误差，太小会出现相近数相减的舍入影响，第 7 章将进一步分析。

```
h = 1e-6
finite = np.empty_like(w)
for j in range(w.size):
    step = np.zeros_like(w)
    step[j] = h
    plus = loss_and_gradient(X, y, w + step)[0]
    minus = loss_and_gradient(X, y, w - step)[0]
    finite[j] = (plus - minus) / (2 * h)
```

本框的 w 为例题 6.9 的`np.array([0.5, 1.])`，`loss_and_gradient`由配套脚本定义。接口先验证实数类型、有限性、非空与形状，再转换成独立`float64`数组，拒绝布尔、复数、字符串以及不等形标签；计算溢出时主动失败，不把无穷损失当作有效结果。

固定预期为：奇异值 3、1；秩一 Frobenius 误差 1；A 条件数 10^8、Gram 条件数约 10^{16}；解从 $(1,0)$ 变为 $(1,1)$；损失 0.125，解析梯度 $(-1/6, 1/6)$。梯度采用相对容差 10^{-7}、绝对容差 10^{-9}；差分最后几位与数值库有关，不能规定完全相等。

输出存于`ch06_results/summary.json`与`svd.npz`，记录环境、奇异值、条件数、梯度误差与分解数组。加载 NPZ 时采用`allow_pickle=False`，沿用第 4 章普通数值数组的保存规则。

修改任务：将 10^{-8} 改成 10^{-4} 并将右端扰动相应改成 10^{-4}，条件数应为 10^4，同样方向的解变化仍为 1；把保留秩从 1 改 2，重建误差应接近 0；给 U 某列和 V 转置对应行同时乘 -1，重建应不变；对 $h = 10^{-2}, 10^{-4}, 10^{-6}, 10^{-8}$ 逐一记录梯度误差。此处损失是二次函数，中心差分的截断误差有特殊抵消，不能据此推广任意函数的最佳步长。

6.13 公式维度表、常见错误与自检

表达式	数学形状	解释或条件
$X\mathbf{w}$	$n \times 1$	n 个预测
$X^{\mathrm{T}}\mathbf{e}$	$d \times 1$	参数方向的误差汇总
$X^{\mathrm{T}}X$	$d \times d$	特征列的 Gram 矩阵
XX^{T}	$n \times n$	样本行的 Gram 矩阵
$Q^{\mathrm{T}}\mathbf{y}$	$r \times 1$	标准正交列上的坐标
$QQ^{\mathrm{T}}\mathbf{y}$	$n \times 1$	r 维子空间中的投影
$A^{+}\mathbf{b}$	$d \times 1$	$A : (m, d)$, $\mathbf{b} : (m, 1)$
$X^{\mathrm{T}}(XW - Y)$	$d \times k$	多输出参数梯度的未归一化部分

维度相符只能说明乘法有定义，不能证明公式正确。$X^{\mathrm{T}}X$ 与 XX^{T} 都可能是方阵，但分别处于参数空间与样本空间；当 $n = d$ 时形状甚至相同，含义仍不同。核对公式要同时说明每个轴代表样本、特征还是输出。

常见误区包括：把相似度当距离；对零向量算余弦；把平方距离当满足三角不等式的距离；用元素全正判断正定；把满行秩当参数唯一；对长方形矩阵直接求普通逆；认为秩亏就没有最小二乘解；把空残差返回数组理解为零误差；把 $Q^{\mathrm{T}}Q = I$ 误反写；把特征分解套到任意实矩阵；直接显式求逆并忽略条件数。

知识联系可以沿一条链理解：字段确定坐标，内积定义方向比较，列空间规定预测能到达哪里，投影确定最佳拟合，秩与零空间确定参数是否唯一，SVD 刻画可辨认方向，条件数刻画求解敏感性，矩阵微分则把同一问题转换成可迭代优化的梯度公式。

自检应能说明为什么 X 的列空间在 $\mathbb{R}^n$ 而非 $\mathbb{R}^d$；为什么残差正交于列而不必为零；为什么预测唯一不能推出系数唯一；为什么小奇异值在反向求解中危险；为什么数值稳定与统计泛化是不同问题。

6.14 分层习题

以下编号为 6.1–6.14；默认实数、列向量与普通欧氏度量，数值实现注明数组形状。

6.1 **基础**。计算例题 6.1 的内积、范数、距离与余弦；若 b 改成 $-2\mathbf{a}$，余弦与欧氏距离分别是什么？

6.2 **推导**。展开两个单位向量的平方距离，证明它与余弦的关系；用 0、1、2 说明平方距离不满足三角不等式。

6.3 **坐标**。求 $(3,2)^{\mathrm{T}}$ 在 $(1,1)^{\mathrm{T}}$ 与 $(1,-1)^{\mathrm{T}}$ 下的坐标。$A\mathbf{x}+\mathbf{b}$ 什么时候是严格线性变换？

6.4 **秩**。完成例题 6.3；解释满列秩、满行秩分别对方程的可解性与唯一性意味着什么。

6.5 **投影**。完成例题 6.4，直接核对 $P^2 = P$ 与 $P^{\mathrm{T}} = P$；为什么 $P \neq I_3$？

6.6 **最小二乘**。完整重算例题 6.5。若去掉截距，求斜率、残差与残差和；误差平方和是多少？

6.7 **不唯一**。在重复特征问题中列出全部最优参数，证明 $(7/6, 1/4, 1/4)$ 是最小范数解。

6.8 **正定性**。求例题 6.6 两个矩阵的特征值；说明为什么 $X^{\mathrm{T}}X$ 总半正定、何时严格正定。

6.9 **SVD**。给出例题 6.7 矩阵的经济 SVD 形状、伪逆、秩一近似与误差。奇异向量同时变号为什么不影响重建？

6.10 **条件数**。将例题 6.8 中 10^{-8} 改为 10^{-4} 并相应改右端扰动，计算放大倍数与 Gram 条件数。为什么残差小不说明系数可靠？

6.11 **微分**。从分量求导证明 $\nabla(\mathbf{x}^{\mathrm{T}}A\mathbf{x}) = (A + A^{\mathrm{T}})\mathbf{x}$，说明何时可写成 $2A\mathbf{x}$。

6.12 **梯度**。重算例题 6.9，再把损失改为 $\frac{1}{n}\|X\mathbf{w} - \mathbf{y}\|^2$。梯度如何变化？多输出时若按全部元素平均，分母如何变化？

6.13 **编程**。运行两个实验与答案核对；改变最后目标为 3，核对参数 1、1 与正交条件；

对 SVD 比较重建而非固定奇异向量符号。

6.14 综合。某数据矩阵有两列几乎相同。解释参数不稳定、训练预测变化小、测试预测可能变化大怎样同时发生，并提出需记录的诊断量。

6.15 习题参考答案

6.1–6.5：度量、秩与投影

6.1 原题内积 2，a 范数 3、$\sqrt{5}$、2，b 范数均 2，欧氏距离 $\sqrt{5}$，余弦 $1/\sqrt{5}$。b 改为 $-2\mathbf{a}$ 时方向相反，余弦 -1，差向量为 $3\mathbf{a}$，距离 $3\sqrt{5}$。

6.2 $\|\mathbf{u}-\mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2 - 2\mathbf{u}^{\mathrm{T}}\mathbf{v} = 2 - 2\cos\theta$。单位化须排除零向量。0 到 2 平方距离 4，大于 0 到 1 与 1 到 2 之和 2，因此不满足距离公理中的三角不等式。

6.3 解 $\alpha+\beta=3, \alpha-\beta=2$，得 $\alpha=5/2, \beta=1/2$。严格线性要求映射零向量到零，故仿射式中的固定 b 必须为零。增广一个常数坐标可以用矩阵表示仿射式，但不改变原空间中它含平移的事实。

6.4 秩 2，零空间由 $(0,1,-1)$ 张成。满列秩保证在可解时唯一，但不保证任意右端可解；满行秩保证任意右端可解，但若列数多于行数就有非零零空间，解不唯一。方阵满秩才同时对任意右端可解且唯一。

6.5 投影 $(1,1,0)$、残差 $(1,-1,3)$；P 的左上 2 乘 2 块全为 1/2，其余 0。平方后该块每项为 $1/4+1/4=1/2$，P 对称且幂等。$P(0,0,1)^{\mathrm{T}}=0$，故不等于 I_3；它只保留一维方向。

6.6–6.10：拟合、分解与敏感性

6.6 带截距参数 $(7/6, 1/2)$，残差 $(-1/6, 1/3, -1/6)$，平方和 1/6。无截距时 $a=6/5$，预测 $(0, 6/5, 12/5)$，残差 $(1, 4/5, -2/5)$，残差和 $7/5$，平方和 $1+16/25+4/25=9/5$。输入与残差内积仍为 0，但常数方向未包含在设计矩阵中。

6.7 全部最优参数为 $(7/6, t, 1/2-t)$。参数范数平方为 $(7/6)^2 + 2(t-1/4)^2 + 1/8$，唯一最小点 $t=1/4$。最小范数选择不增加数据中不存在的辨识信息。

6.8 第一矩阵特征值 3、1，正定；第二矩阵 3、-1，不定。对任意 v，$\mathbf{v}^{\mathrm{T}}X^{\mathrm{T}}X\mathbf{v} = \|X\mathbf{v}\|^2 \geq 0$。严格正定当且仅当 X 没有非零零空间，即满列秩；若存在非零 v 被消去，则二次型可为零。

6.9 U 形状 3 乘 2，s 长 2，V 转置为 2 乘 2；奇异值 3、1，伪逆主非零项为 1/3、1。秩一只保留第一项 3，Frobenius 误差 1。外积中两向量同时变号，乘积 $(-\mathbf{u})(-\mathbf{v})^{\mathrm{T}} = \mathbf{u}\mathbf{v}^{\mathrm{T}}$，所以重建不变。

6.10 A 条件数 10^4，Gram 条件数 10^8，右端相对变化 10^{-4}，解相对变化 1，放大倍数 10^4。残差衡量当前计算解满足当前输入方程的程度，不能说明输入本身没有误差，也不能排除误差在弱方向上的放大。

6.11–6.14：微分、程序与综合判断

6.11 分量和 $\sum_{i,j} x_i A_{ij} x_j$ 中，求第 k 项导数需分别考虑左侧 x_i 与右侧 x_j；得到 $\sum_j A_{kj} x_j + \sum_i A_{ik} x_i$。向量化为 $(A + A^{\mathrm{T}})\mathbf{x}$；A 对称时化为 $2A\mathbf{x}$。反对称部分对二次型没有贡献。

6.12 原损失 1/8、梯度 $(-1/6, 1/6)$。去掉 1/2 后损失 1/4、梯度 $(-1/3, 1/3)$。多输出按 nk 个元素平均的半平方损失梯度为 $X^{\mathrm{T}}(XW - Y)/(nk)$，梯度形状仍与 W 一致。

6.13 改后 $\mathbf{y} = (1, 2, 3)$ 恰在 X 列空间中，参数 $(1, 1)$，残差数值上约为 0。仍应检查形状与有限性，并用容差比较。SVD 核对 $U\Sigma V^{\mathrm{T}}$ 与输入矩阵一致，U/V 对应列行符号不作固定要求。配套脚本额外拒绝列形标签、非数值、非有限与溢出输入。

6.14 近相关列产生小奇异值。参数沿相应右奇异方向变化时，被训练 X 强烈压缩，训练预测可能变化不大；新样本未必保持同样相关结构，参数变化就可能显现为大预测变化。应记录特征单位与缩放、奇异值谱、数值秩及阈值、条件数、残差范数、参数范数与分布变化；不能仅凭训练误差小判断可靠。后续可比较简化特征或正则化，但需遵守验证流程。

6.16 本章小结

线性代数把数值计算组织成方向、空间与变换。内积连接夹角与得分，范数连接大小与误差，列空间限制可实现的预测，正交投影给出平方误差下的最佳近似。秩与零空间解释参数的可辨认性，不能与拟合误差或方程数量简单等同。

特征分解揭示对称二次型的方向，SVD 适用于一般长方形矩阵，并统一解释秩、伪逆、低秩近似和敏感性。矩阵微分则把这些结构转换成参数梯度。后续学习算法时，仍应同时核对公式条件、数组形状、数值尺度与数据含义。