13 逻辑回归与多分类

先修知识、学习目标与本章位置

先修第 6 章的矩阵乘法、第 7 章的链式法则、第 8 章的条件概率与似然，以及第 9–12 章的数据划分、线性模型和梯度优化。本章把线性得分转成类别概率，推导二分类与多分类交叉熵，完成从零实现与库实现的数值对照，并区分概率估计、成本决策和概率校准。第 14 章继续研究怎样评价这些输出；第 22 章将把线性得分推广为神经网络。

某消息平台需要预测一条消息是否应转交人工审核。输入可以是消息长度、特定词频和历史行为统计，标签为 0 或 1。若直接用第 11 章的线性回归拟合标签，输出可能小于 0 或大于 1，无法直接解释成概率。把结果截断到区间内虽然解决了取值范围问题，却没有说明概率模型、拟合目标和决策规则之间的联系。

逻辑回归（logistic regression）用线性函数表达对数几率，再由一个光滑函数映射为概率。名称中的“回归”指它拟合实值的对数几率；通常讨论的应用是分类。它不要求输入服从高斯分布，也不要求特征之间独立。其主要建模假设是：在给定表示下，目标条件概率的对数几率可以用输入的仿射函数近似。

13.1 从线性得分到条件概率

得分、概率与标签三个层次

设输入列向量 $\mathbf{x} \in \mathbb{R}^d$，参数 $\mathbf{w} \in \mathbb{R}^d$，截距 $b \in \mathbb{R}$。先计算**线性得分**（score）

$$z = \mathbf{w}^{\mathrm{T}}\mathbf{x} + b. \tag{13.1}$$

它可以是任意实数。**sigmoid 函数**把得分映射到 $(0,1)$：

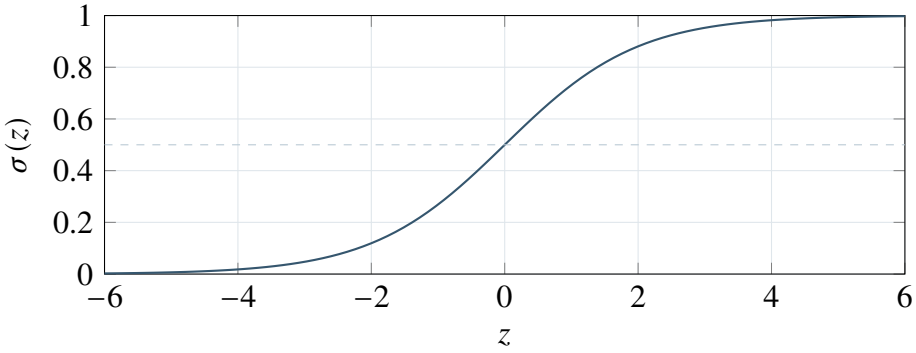
$$p = \sigma(z) = \frac{1}{1+\exp(-z)}, \qquad P_\theta(Y=1 \mid \mathbf{x}) = p, \quad P_\theta(Y=0 \mid \mathbf{x}) = 1-p. \tag{13.2}$$

其中 $\theta = (\mathbf{w}, b)$。对有限 z，数学上的概率严格位于 0 和 1 之间；浮点计算可能舍入为端点。最后还需指定阈值 t，例如用 $\hat{y} = \mathbf{1}[p \ge t]$ 输出类别。得分 z、概率 p 与预测标签 $\hat{y}$ 的含义和数据类型不同，不能在接口中混用。

在 $z = 0$ 时，两类概率各为 $1/2$。若 $z > 0$，类别 1 概率较大；若 $z < 0$，类别 0 概率较大。由链式法则，

$$\sigma'(z) = \frac{\exp(-z)}{(1+\exp(-z))^2} = \sigma(z)[1-\sigma(z)].$$

导数最大值是 $1/4$，出现在 $z = 0$；两侧逐渐变平。这里的饱和只描述概率对得分的变化率，不能据此直接断言交叉熵在错误且自信的预测处梯度也很小，后面将看到两者结合后的导数为 $p - y$。



图中的水平虚线对应默认阈值 0.5。改变阈值不会改变这条概率曲线，只改变哪些概率被判为正类。

几率与对数几率

概率 p 描述事件发生的比例；**几率**（odds）为 $p/(1-p)$，比较发生与不发生的概率。若 $p=0.8$，几率为 4，表示发生概率是不发生概率的 4 倍，并非“概率为 4”。取自然对数得到**对数几率**（log-odds，也称 logit）：

$$\log \frac{p}{1-p} = z = \mathbf{w}^{\mathrm{T}}\mathbf{x} + b. \tag{13.3}$$

在其他输入保持不变时，x_j 增加 1 使对数几率增加 w_j，使几率乘以 e^{w_j}。概率的增量则依赖原来位于曲线的哪个位置，因此不能把 $w_j = 0.2$ 解释为概率增加 20 个百分点。若特征已经标准化，“增加 1”对应原变量增加一个训练标准差。

例题 13.1：从系数解释概率和边界

设 $z = 2x_1 - x_2 - 1$。求 $\mathbf{x} = (1, 0)$ 时的正类概率，阈值 0.5 的边界，以及阈值 0.8 的边界。

解 在给定点 $z = 1$，所以 $p = 1/(1+e^{-1}) \approx 0.731059$。阈值 0.5 对应 $z = 0$，边界为 $2x_1 - x_2 - 1 = 0$。阈值 0.8 对应 $z = \log(0.8/0.2) = \log 4$，边界为 $2x_1 - x_2 - 1 = \log 4$。这个点在默认阈值下判 1，在 0.8 阈值下判 0；概率本身没有变化。固定 x_2 时 x_1 每增加 1，几率乘以 e^2。

当 $0 < t < 1$ 时，sigmoid 单调递增，所以

$$p \geq t \quad \Longleftrightarrow \quad \mathbf{w}^{\mathrm{T}}\mathbf{x} + b \geq \log \frac{t}{1-t}.$$

默认边界是超平面，即高维空间中的平面推广。加入 x_1^2、$x_1 x_2$ 等特征后，模型对新特征仍是线性的，在原始坐标中却可以得到曲线边界。因而“线性模型”应说明线性是相对于哪组表示而言。系数解释是条件相关的模型解释，若有混杂、选择偏差或特征共线性，不能自动视为干预造成的因果变化。

13.2 从伯努利似然到二元交叉熵

把两个类别写进同一公式

对样本 i，$y_i \in \{0,1\}$。给定输入后的伯努利概率为

$$P_\theta(y_i \mid \mathbf{x}_i) = p_i^{y_i}(1-p_i)^{1-y_i}.$$

当 $y_i = 1$，式子取 p_i；当 $y_i = 0$，取 $1-p_i$。假设在给定输入和参数后各标签条件独立，条件似然是各项乘积。为避免许多小数相乘下溢，最大化对数似然，并把符号取反转为最小化：

$$-\log L(\theta) = -\sum_{i=1}^{n}[y_i \log p_i + (1-y_i)\log(1-p_i)], \tag{13.4}$$

$$J(\theta) = \frac{1}{n}\sum_{i=1}^{n}\ell_i, \qquad \ell_i = -y_i \log p_i - (1-y_i)\log(1-p_i). \tag{13.5}$$

ℓ_i 称为**二元交叉熵**（binary cross-entropy，BCE）。本章所有对数均为自然对数，损失单位为 nat。除以 n 不改变无正则最优点，但会改变学习率和正则系数的含义。

若真实条件概率为 $\eta = P(Y=1 \mid \mathbf{x})$，在固定输入处的平均损失是

$$h(p) = -\eta \log p - (1-\eta)\log(1-p).$$

在 $0 < \eta < 1$ 时，$h'(p) = (p-\eta)/[p(1-p)]$，于 $p = \eta$ 达到唯一最小。这个结论说明，充分灵活的模型在总体上最小化交叉熵时会恢复条件概率；有限样本、线性假设和正则化都会引入偏离，不能把训练目标的性质当作已训练模型自动校准的保证。

直接用得分计算损失

利用 $\log p = z - \log(1+e^z)$、$\log(1-p) = -\log(1+e^z)$，得到

$$\ell(z,y) = \log(1+e^z) - yz. \tag{13.6}$$

函数 $\log(1+e^z)$ 常称 **softplus**。当 z 很大时直接求 e^z 会溢出。按 z 的符号提出较大项，可以改写为

$$\ell(z,y) = \max(z,0) - yz + \log(1+e^{-|z|}). \tag{13.7}$$

NumPy 的 `np.logaddexp(0,z)` 稳定计算 $\log(e^0+e^z)$。先算概率、再取对数会在概率舍入为 0 或 1 时失去信息；裁剪概率也会改变极端区间的目标。训练时优先使用得分形式，而概率形式适合解释定义。

例题 13.2：正确、自信错误与数值稳定

对真实标签 1，分别计算得分 0、2、−2 的损失和得分梯度；再考虑得分 −1000。

解 标签 1 时 $\ell = \log(1+e^{-z})$。前三个损失依次约为 0.693147、0.126928、2.126928。梯度 $\sigma(z)-1$ 依次为 −0.5、−0.119203、−0.880797。在 $z=-1000$ 时，式(13.7)给出损失约 1000、梯度约 −1，没有指数溢出。错误且极其自信的预测受到很大损失，得分梯度仍有纠正方向。

交叉熵随着错误置信度增大而增大。准确率却只记录阈值两侧的位置：概率 0.01 与 0.49 在标签 1、阈值 0.5 时都是一次错误。这解释了损失下降而准确率暂时不变的可能性，也说明二者不能互相替代。

13.3 梯度、曲率与正则化

保留链式求导的中间步骤

首先对概率求导：

$$\frac{\partial \ell}{\partial p} = -\frac{y}{p} + \frac{1-y}{1-p} = \frac{p-y}{p(1-p)}.$$

再乘 $\partial p/\partial z = p(1-p)$，便得到

$$\frac{\partial \ell}{\partial z} = p - y, \qquad \frac{\partial \ell}{\partial w_j} = (p-y)x_j, \quad \frac{\partial \ell}{\partial b} = p - y.$$

残差的形式与平方损失回归相似，但这里是概率与二元标签之差，且 p 是参数的非线性函数。不是把线性回归梯度中的输出强行截断就能得到相同算法。

把样本按行放入 $X \in \mathbb{R}^{n\times d}$，$\mathbf{p}, \mathbf{y} \in \mathbb{R}^n$。采用不惩罚截距的 L2 正则目标

$$J(\mathbf{w}, b) = \frac{1}{n}\sum_i \ell_i + \frac{\lambda}{2}\|\mathbf{w}\|_2^2, \quad \lambda \ge 0, \tag{13.8}$$

$$\nabla_w J = \frac{1}{n} X^{\mathrm{T}}(\mathbf{p} - \mathbf{y}) + \lambda \mathbf{w}, \qquad \partial_b J = \frac{1}{n}\sum_i (p_i - y_i). \tag{13.9}$$

X^{T} 的形状为 $d \times n$，乘长度为 n 的残差得到长度为 d 的权重梯度；截距梯度是标量。若标签形状错误地为 $(n,1)$，与 $(n,)$ 概率相减会广播成 (n,n)，所以形状检查属于算法正确性的一部分。

例题 13.3：一次完整梯度更新

取两条数据 $(x,y) = (0,0),(2,1)$，初始 $w = b = 0$，学习率 1，$\lambda = 0.1$。求第一次更新及更新后的预测。

解 两条概率均为 0.5，残差为 $(0.5, -0.5)$。故 $\partial_w J = [0(0.5) + 2(-0.5)]/2 + 0.1(0) = -0.5$，$\partial_b J = 0$。更新得 $w = 0.5, b = 0$。新得分为 $(0,1)$，概率为 $(0.5, 0.731059)$。新数据损失约为 $(0.693147 + 0.313262)/2 = 0.503204$，正则项为 0.0125，总目标约 0.515704，低于初始的 0.693147。

为什么凸，为什么仍可能没有有限解

把截距并入设计矩阵 $\widetilde{X} = [X, \mathbf{1}]$，参数记作 $\widetilde{w}$。令 D 为对角矩阵，第 i 个对角元为 $p_i(1-p_i)$，则

$$H = \frac{1}{n}\widetilde{X}^{\mathrm{T}} D \widetilde{X} + lambdaR, \quad R = \mathrm{diag}(1, \ldots, 1, 0).$$

对任意向量 v，

$$v^{\mathrm{T}} H v = \frac{1}{n}\sum_i p_i(1-p_i)(\tilde{x}_i^{\mathrm{T}} v)^2 + \lambda \sum_{j=1}^{d} v_j^2 \ge 0.$$

因此目标是凸函数。若设计矩阵秩亏，无正则目标可能有多个等价参数；凸性不等于严格凸，也不等于存在有限最优参数。

完全可分指存在一个超平面使全部正样本得分为正、负样本得分为负。将分离方向的参数乘以不断增大的正数，训练概率越来越接近标签，交叉熵趋近 0，却不在任何有限参数处取到 0。因此训练准确率可以很早达到 100%，权重范数仍持续增大。L2 正则限制权重增长；当训练数据两类都存在且 $\lambda > 0$ 时，不惩罚截距的目标也有有限唯一最优解。若所有标签都是同一类，仅让截距趋于正或负无穷仍可降低损失，不能用“加了 L2”一概排除该问题。

在满列秩且有限参数处，Newton 方法可以解 $H\Delta = \nabla J$，再用 $\theta \leftarrow \theta - \Delta$ 更新。实际应求解线性方程，不能显式求逆。Hessian 构造和求解对特征数的成本较高，小批量梯度和拟 Newton 方法在不同规模下各有用途。凸问题也需要检查迭代次数、梯度和停止条件；优化器未收敛时，比较结果可能只是比较了不同程度的训练不足。

13.4 从二分类到多分类 softmax

互斥类别与独立标签

若一张图片属于猫、狗或鸟之一，共有 K 个互斥且穷尽的类别，预测概率应非负且和为 1。若一张图片可以同时包含猫和狗，则是**多标签分类**（multi-label classification），通常给每个标签一个二元输出；不应强行用单个 softmax 使猫和狗互相竞争。

对于单标签多分类，令 $W \in \mathbb{R}^{d\times K}$，$b \in \mathbb{R}^K$，每一列为一个类别的线性权重。单样本得分 $z \in \mathbb{R}^K$。批量计算为

$$Z = XW + \mathbf{1}b^{\mathrm{T}} \in \mathbb{R}^{n\times K}.$$

softmax 函数定义为

$$p_k = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}, \quad k = 1, \dots, K. \tag{13.10}$$

输出是相对得分：某一类的概率同时依赖其他类得分。两类的对数概率比满足

$$\log(p_k/p_l) = z_k - z_l.$$

因此成对比较仍由线性差决定。

给所有得分加同一常数 c，分子分母同乘 e^c，概率不变。因此参数存在共同平移的冗余：给每一列权重加同一个向量、给每个截距加同一个数，不改变预测。可以固定一个参考类的参数，或使用对称参数化配合正则化。比较两个实现时应优先比较预测概率和目标值，不能仅因为参数逐项不同就判定错误。

多分类似然与梯度

用 $Y_{ik} = \mathbf{1}[y_i = k]$ 表示**独热标签**（one-hot label），每行只有一个 1。类别条件分布的负对数似然为

$$\ell_i = -\sum_{k=1}^{K} Y_{ik} \log P_{ik} = -\log P_{i,y_i}.$$

这里整数标签和独热矩阵是同一标签的两种存储方式，并非两种不同的学习问题。把 softmax 代入后，

$$\ell_i = \log \sum_k e^{Z_{ik}} - Z_{i,y_i}.$$

先对 z_j 求导：$\partial \log \sum_k e^{z_k} / \partial z_j = p_j$，而 $\partial z_y / \partial z_j = \mathbf{1}[y = j]$，所以

$$\frac{\partial \ell}{\partial z_j} = p_j - Y_j. \tag{13.11}$$

直接从 softmax 求导也可验证：$\partial p_k / \partial z_j = p_k(\mathbf{1}[k = j] - p_j)$。非对角项不是 0，正好体现类别之间的竞争。

采用 $J = n^{-1} \sum_i \ell_i + (\lambda/2)\|W\|_F^2$，其中 Frobenius 范数平方为矩阵元素平方和，批量梯度为

$$\nabla_W J = \frac{1}{n} X^{\mathrm{T}}(P - Y) + \lambda W, \qquad \nabla_b J = \frac{1}{n} \sum_i (P_{i,:} - Y_{i,:}).$$

维度依次是 $(d \times n)(n \times K) = d \times K$ 和长度 K。每行残差之和为 0，因而未正则化的类别梯度之和为 0；这是实现时可检查的结构性质。

稳定的 log-sum-exp

对数指数和（log-sum-exp，LSE）可写成

$$\mathrm{LSE}(z) = m + \log \sum_k e^{z_k - m}, \qquad m = \max_k z_k.$$

由于 $z_k - m \le 0$，指数最大为 1，避免上溢。直接算对数概率 $\log p_k = (z_k - m) - \log \sum_j e^{z_j - m}$，也能保留极小概率对应的有限负对数。若各得分本来已经是无穷或 NaN，减最大值无法恢复有效计算；仍需检查线性乘法和输入尺度。

例题 13.4：巨大得分的稳定多分类计算

得分为 $(1000, 1001, 999)$，真实类别为第 2 类。计算概率、损失与得分梯度。

解 减最大值 1001 得到 $(-1, 0, -2)$。指数和为 $e^{-1} + 1 + e^{-2} \approx 1.503215$，所以概率约为 $(0.244728, 0.665241, 0.090031)$。损失为 $\log(1 + e^{-1} + e^{-2}) \approx 0.407606$，梯度为 $(0.244728, -0.334759, 0.090031)$，三项和为 0。给三个得分同时加 3000 不改变这些结果。

当 $K = 2$ 时，第一类概率为 $\sigma(z_1 - z_2)$，所以二分类 sigmoid 可以看成对两类得分差建模。若直接比较二类 softmax 的两组 L2 惩罚和单组二元逻辑回归的 L2 惩罚，需要重新换算系数，二者并非在相同数值的 λ 下自动等价。

另一种多分类构造是**一对其余**（one-versus-rest，OvR）：为每个类别训练一个“属于该类/不属于该类”的二分类器，再比较得分。各模型独立拟合，原始概率不一定和为 1。联合 softmax 直接拟合一个多类别分布；不能将 OvR 的原始概率当作已经归一化的联合概率。后续支持向量机章节还会讨论其他拆分方式。

13.5 阈值、类别不平衡与加权目标

从错误成本推出阈值

设把负类判为正类的成本为 $C_{\mathrm{FP}} > 0$，把正类判为负类的成本为 $C_{\mathrm{FN}} > 0$，正确决策成本为 0。若 p 是目标人群的真实条件概率，预测 1 的条件期望成本为 $(1-p)C_{\mathrm{FP}}$，预测 0 为 pC_{FN}。选择较小者得到

$$\hat{y} = 1 \quad \Longleftrightarrow \quad p \geq \frac{C_{\mathrm{FP}}}{C_{\mathrm{FP}} + C_{\mathrm{FN}}}. \tag{13.12}$$

若有审核容量约束、不同样本成本或拒绝选项，决策问题需要相应改写。这个公式依赖概率适用于部署人群；失准的评分即使位于 0 到 1 之间，也不能直接代入成本公式保证最优。

例题 13.5：低阈值和加权概率并非同一件事

漏检成本为 9，误报成本为 1。某样本真实正类概率为 0.2。另用正类权重 4、负类权重 1 训练一个充分灵活的加权交叉熵模型，求其总体最优输出。

解 成本阈值为 $1/(1+9) = 0.1$，该样本应判 1。加权条件损失是 $-4\eta \log q - (1-\eta)\log(1-q)$。令导数为 0，得到 $q = 4\eta/[4\eta + (1-\eta)]$。代入 $\eta = 0.2$ 得 $q = 0.5$。加权模型输出 0.5 对应的原始发生概率仍是 0.2，不能据此声称一半同类样本都会为正。

加权交叉熵与重新采样

类别不平衡指类别样本数量相差较大。若正类占 1%，全判负类就有 99% 准确率，但正类召回率为 0。应先明确正类检测价值、可接受误报和目标人群比例，再选择训练及评价办法。

给每条样本正权重 a_i，本节约定

$$J_a = \frac{1}{A}\sum_i a_i \ell_i + \frac{\lambda}{2}\|w\|^2, \qquad A = \sum_i a_i.$$

权重可以来自类别、抽样设计或业务关注。梯度中的残差变为 $a_i(p_i - y_i)/A$。若实现改为除以 n，不仅数据项尺度变化，正则项的相对强度也变化；库对照必须核对归一化约定。

当正类权重为 α、负类权重为 β 时，加权总体最优概率是

$$q^* = \frac{\alpha\eta}{\alpha\eta + \beta(1-\eta)}, \qquad \eta = \frac{\beta q^*}{\alpha(1-q^*) + \beta q^*}.$$

逆公式只在相应加权模型恰好拟合加权条件概率等假设下成立，有限模型不能依靠它消除全部失准。改变类别采样比例也会改变训练分布；在仅先验类别比例变化、类条件输入分布保持不变时，可在对数几率上加上部署与训练先验几率之比的对数。若类条件分布也变了，这种截距修正一般不足。

过采样是重复或生成少数类训练记录，欠采样是减少多数类记录。重复记录不会凭空增加独立信息。采样操作只能在训练折内完成：若在划分之前复制样本，同一记

录可能同时落入训练和验证，评价将被污染。阈值调整作用于预测阶段，加权和采样作用于训练阶段，三者可以组合，但组合应在验证流程中共同选择，并重新检查概率含义。

13.6 概率校准：让预测值与发生频率相符

概率校准（probability calibration）研究预测概率与实际频率的匹配。理想二分类模型满足 $P(Y = 1 \mid \hat{p} = s) = s$。例如大量预测约为 0.7 的样本中，实际正类比例应接近 0.7。单个样本只有 0 或 1 标签，不能凭一次结果判定它的 0.7 概率“错了”。

可靠性图把样本按预测概率分箱，每箱横轴为平均预测概率，纵轴为正类比例。若一箱 10 条记录平均预测 0.8，却只有 5 条正类，则点为 $(0.8, 0.5)$。小箱的频率波动大，分箱数量和边界会影响外观；应报告每箱数量，并避免用少量点宣称精确校准。

校准与排序不同。将所有得分做严格单调变换可保持排序，却改变概率；ROC AUC 可能完全不变，交叉熵和 Brier 分数却显著变化。常数预测器如果输出总体正类比例，可能整体校准，却无法区分高风险和低风险样本。因而评价需要同时考察区分能力和概率质量。

常见后处理方法包括：对原得分再拟合一个 sigmoid 的 **Platt 缩放**；拟合单调阶梯函数的**保序回归**（isotonic regression）；以及对多类得分除以 $T > 0$ 的**温度缩放**（temperature scaling）。T 增大通常使分布更平坦，减小则更集中；正温度不改变多分类最大得分类别。保序方法更灵活，也更容易在小样本校准集上过拟合。

> **校准数据必须与基础模型拟合数据分开**
>
> 基础模型先在训练集拟合；再用独立校准集上的得分与标签拟合校准映射；最后在从未参与选择的测试集评价。也可用交叉拟合产生折外得分。不能把基础模型在训练集上的过度自信预测直接当作无偏校准输入。若还要用数据选择阈值，需把该选择纳入验证协议，避免在同一小样本上反复调到最优后报告其分数。

没有一种后处理能保证在任意分布变化后仍然校准。若数据来源、时间、标签定义或人群改变，先检查评价分布是否仍对应使用场景，再判断是否需要重新拟合。

13.7 把训练、概率和决策连接成可复现流程

先校准还是先选阈值

假设开发数据分为拟合集、校准集和阈值验证集，最终测试集另留。基础模型及其超参数在拟合部分的内部验证中确定，随后产生校准集得分。校准器只学习得分到概率的映射；固定该映射后，阈值验证集用于确定满足成本或容量要求的决策阈值。测试只评价最终组合。

样本有限时，简单切成许多小块会使每一步估计不稳定，可使用适当交叉拟合。关键要求不是一定要四个固定文件，而是每一步用于评价的预测不应来自已经使用其标签拟合的过程。若在多个校准方法之间选择，也要把选择纳入验证，而不是挑校准集

损失最低者后将同一损失当作最终证据。

若最终把拟合集和校准集合并重训基础模型，其得分分布可能改变，旧校准映射不一定继续匹配。可以保留原基础模型，或使用有明确交叉拟合与重训规则的校准流程。重训不是只把数据拼起来调用一次拟合；它会改变后处理所依赖的输入分布。

例题 13.6：一组可靠性图的手算

四条记录的预测概率为 $(0.2, 0.4, 0.6, 0.8)$，标签为 $(0, 1, 0, 1)$。按低于 0.5 和不低于 0.5 分成两箱，求可靠性图上的点，以及按箱人数加权的绝对频率偏差。

解　两箱各 2 条，平均预测分别为 0.3 与 0.7，实际正例比例都为 0.5，所以点为 $(0.3, 0.5)$、$(0.7, 0.5)$。加权绝对偏差为 $\frac{1}{2}|0.3 - 0.5| + \frac{1}{2}|0.7 - 0.5| = 0.2$。若全部并为一箱，平均预测与正例比例都为 0.5，偏差变为 0。分箱改变了估计结果，不能把这个小样本分箱值当作模型真实校准误差。

上述按箱汇总的统计常被称为期望校准误差的一种经验估计，缩写为 ECE。其值依赖分箱、样本数量和具体定义，不能只报告“ECE 为 0”就声称概率完全可信。Brier 和对数损失无需分箱，但它们也不是只衡量校准，评价应同时说明所回答的问题。

多分类成本决策

最大概率分类隐含所有误分类成本相同。若共有 K 类、可采取 A 种动作，令 $C_{a,c}$ 表示真实类别为 c 时采取动作 a 的成本，则动作的条件期望成本为

$$R(a \mid x) = \sum_{c=1}^{K} C_{a,c} p_c(x), \qquad a^*(x) = \arg\min_a R(a \mid x).$$

成本矩阵形状是 $A \times K$，概率是长度 K 的向量，所以矩阵乘积给出长度 A 的成本向量。动作可以包括“交给人工”，不必与类别一一对应。只有成本矩阵对角为 0、非对角都相同时，最小期望成本才化为最大概率类别。

例如三类概率为 $(0.45, 0.40, 0.15)$，正确分类成本 0，通常错误成本 1，但把第三类错判为第一类成本 10。预测第一类的期望成本为 $0.40 + 10(0.15) = 1.90$；预测第二类成本 $0.45 + 0.15 = 0.60$；预测第三类成本 $0.45 + 0.40 = 0.85$。最小成本动作是第二类，虽然第一类概率最大。若所有人工审核的固定成本为 0.3 且能完全纠正类别，则选择人工更便宜；实际人工也可能有错误和容量限制，需要把这些因素写入模型。

L2 系数、特征缩放与参数解释

逻辑回归的 L2 项与第 11 章岭回归有相同的尺度问题。令 $z_j = (x_j - \mu_j)/s_j$，标准化模型得分为 $\sum_j v_j z_j + a$，则原坐标权重与截距为

$$w_j = \frac{v_j}{s_j}, \qquad b = a - \sum_j \frac{v_j \mu_j}{s_j}.$$

标准化空间的惩罚 $\sum_j v_j^2$ 对应原空间的 $\sum_j s_j^2 w_j^2$。因此标准化不仅影响梯度训练速度，也改变同一数值正则强度所偏好的函数。解释系数前必须知道它处于哪个坐标系。

若训练有 n 条同等权重记录，将每条记录简单复制一次，平均损失形式的数据项不变；保持本章的 λ 也应保持最优预测不变。库参数对应 $C = 1/(n\lambda)$，所以复制后若保持 C 不变，相当于将 λ 减半。这个小实验比只记住“C 越大正则越弱”更能检查接口理解。复制记录不增加独立信息，不能因此缩小统计区间。

从零训练循环与停止诊断

每一步先用当前参数计算损失和梯度，再同时更新全部参数。不能在计算截距梯度之前就改权重，否则同一步的各分量来自不同参数状态。下面的函数调用损失梯度函数，定义见下一节。先运行下一节的导入与函数定义，再调用训练函数；固定步数只为使实验可复现：

```
def train_binary(X, y, lam, steps=12000, rate=.1):
    theta = np.zeros(X.shape[1] + 1)
    history = []
    for step in range(steps):
        loss, grad = loss_grad(theta, X, y, lam)
        if step % 1000 == 0:
            history.append(loss)
        theta = theta - rate * grad
    return theta, np.array(history)
```

实际停止还可参考梯度范数、相邻目标变化和最大迭代数。训练准确率不再变化不代表概率损失已收敛；完全可分无正则问题甚至可能持续降低损失而没有有限极小点。若损失变化很小但梯度仍大，应检查步长是否过小、尺度是否悬殊。梯度检查通过说明局部导数与目标一致，不保证训练数据正确、目标合适或模型泛化可靠。

13.8 实验 13.1：从零实现二分类并对照库

实验数据是六条二维教学样本。其目的是验证似然、梯度、正则化与库接口的对应关系，因此在同一训练数据上比较两种实现，不把训练准确率当作泛化评价。完整入口为 配套实验/ch13_logistic.py；使用 NumPy、SciPy 和 scikit-learn，CPU 运行，无外部数据。

参数数组按 $[w_1, w_2, b]$ 排列。核心计算如下，完整脚本另检查输入形状、标签范围与有限值：

```
import numpy as np
from scipy.special import expit

def loss_grad(theta, X, y, lam):
    w, b = theta[:-1], theta[-1]
    z = X @ w + b
    loss = np.mean(np.logaddexp(0, z) - y*z)
    loss += lam/2 * (w @ w)
    r = expit(z) - y
    grad = np.r_[X.T @ r / len(y) + lam*w,
                 r.mean()]
    return loss, grad
```

`expit`是 SciPy 的稳定 sigmoid 实现。`np.r_`把权重梯度与截距梯度接成一个数组。目标采用平均数据损失，因此 L2 项不再除以样本数。脚本从零初始化，步长 0.1 执行 12000 步，在若干步保存损失，并用中心差分核对三个坐标的解析梯度。

scikit-learn 的 `LogisticRegression` 中，C 是正则化强度的倒数型参数。对本实验的无权重、L2、`lbfgs`设置，对应关系为

$$\lambda = \frac{1}{nC}, \qquad C = \frac{1}{n\lambda}.$$

这里 $n = 6, \lambda = 0.1$，所以 $C = 5/3$。截距不惩罚。不能直接把 $C = 1/\lambda$ 套入平均损失目标；其他求解器或权重约定也要另查。库版本和本批实测结果保存在实验说明及日志中。

在项目根目录运行：

```
python3 配套实验/ch13_logistic.py
```

应出现有限目标值，保存的损失不增，中心差分误差低于 10^{-8} 量级，且从零实现与库预测概率的最大绝对差不超过 2×10^{-6}。浮点最后几位随数值库可能变化。脚本同时用绝对值 1000 的参数检查稳定损失；稳定函数避免指数溢出，并不保证任意更大矩阵乘法都不会溢出。

修改任务：将 λ 改为 0.01，同时调整库中的 C，观察权重和概率变化；再故意只改变库的 C，说明为何差异不代表从零实现错误。把标签改成 $(6, 1)$ 应被完整接口拒绝。将数据项从平均改为求和时，需要将正则系数乘以 n 才能保持同一目标的最优点，学习率也应按梯度尺度重新考虑。

13.9 实验 13.2：多分类梯度与稳定概率

完整入口为 配套实验`/ch13_softmax.py`。固定种子 1302，在二维空间三个中心附近各生成 40 条正态扰动数据，标签为 0、1、2。生成数据只用于数值验证；类别中心不代表真实数据分布。目标为平均多分类交叉熵加 $0.05\|W\|_F^2/2$。

实验先在非零参数处用九个坐标的中心差分核对 2×3 权重和 3 个截距，再用 SciPy 的拟 Newton 求解器最小化自写目标。这样可以把目标与梯度实现的正确性同训练循

环分开检查。与库比较时使用 $C = 1/(120 \times 0.05) = 1/6$，检查概率误差而不强制截距共同平移一致。

```
from scipy.special import logsumexp

Z = np.array([[1000., 1001., 999.]])
logp = Z - logsumexp(Z, axis=1, keepdims=True)
p = np.exp(logp)
loss = -logp[0, 1]
print(p, loss)
```

`axis=1`表示每一行在类别轴上归一化；`keepdims=True`使分母形状为 $(n, 1)$，与 (n, K) 正确广播。若沿样本轴归一化，每一列之和可能为 1，但每个样本不再得到有效类别分布。

运行 `python3` 配套实验`/ch13_softmax.py`，极端得分概率应与例题 13.4 一致，损失约 0.407606；共同平移前后对数概率差在 10^{-12} 内。梯度用绝对容差 10^{-8}、相对容差 10^{-6} 核对，库预测用绝对容差 2×10^{-5}。完整训练输出以日志为准。

修改任务：将所有类别截距加 5，验证损失与概率不变；只给第一类加 5，观察变化。将 `axis=1` 改为 0，检查每行和并解释错误。把每类中心重合，重新运行后不应强求原训练准确率；数据可辨识程度已经改变。增加无关维度时同时记录参数数目和正则系数，后续用第 14 章的独立评价判断效果。

13.10 数值结果的逐项解释与复核

实验 13.1 保存的最终权重约为 $(1.350719, 0.403469)$，截距接近 0。固定输入和概率对应关系如下。数据正负两类关于原点对称，因而最优截距接近 0 符合此处的数据构造；一般任务不能据此省略截距。

x_1	x_2	y	$\hat{p}$	$\hat{p} - y$
-2	0	0	0.062889	0.062889
-1	1	0	0.279438	0.279438
0	-1	0	0.400479	0.400479
0	1	1	0.599521	-0.400479
1	-1	1	0.720562	-0.279438
2	0	1	0.937111	-0.062889

表中默认分类全部正确，但靠近边界的两个概率仍约为 0.4 与 0.6。L2 目标不要求为了训练正确而把每个概率推到 0 或 1；优化平衡了数据损失与权重大小。六个残差成对相消，所以截距梯度接近 0。权重的数据梯度与 λw 抵消，而不是两者分别为 0。

最终总目标约为 0.400795，中心差分最大误差约 1.14×10^{-11}，两种实现的最大概

率差约 1.12×10^{-9}。这些结果验证的是本组数据和目标下的一致性。换成非线性边界数据后，即使两种实现仍完全一致，也可能都无法获得良好泛化。

多分类实验的训练准确率约为 $118/120 = 0.983333$。它不应被读作独立测试准确率；本实验保留训练样本是为了比较目标与梯度。两个实现概率最大差在本环境约为 3.33×10^{-16}，这是该小问题和求解器组合的实测值，核对时仍采用正文给出的较宽容差。

温度改变概率而不改变最大类别

以三类得分 $(2, 1, 0)$ 为例，温度缩放使用 z/T。三个温度下的概率约为

温度 T	第一类	第二类	第三类
0.5	0.866813	0.117310	0.015876
1	0.665241	0.244728	0.090031
2	0.506480	0.307196	0.186324

第一类始终具有最大概率，故最大概率决策的标签不变。若真实标签是第一类，增大温度会增加该样本损失；若真实标签是第三类，增大温度会降低其过度自信的错误损失。校准温度必须综合独立校准集的目标来选择，不能只挑一个样本或凭直觉让所有概率更“温和”。

二分类与多分类实现的共同检查表

首先核对样本轴和类别轴，确保概率行和为 1，二元标签为 0 或 1，多类整数标签落在允许范围。再检查损失归一化、正则系数和截距约定，最后比较梯度、收敛状态和预测。若只看准确率，两种目标可能在同一小数据上都达到 100%，掩盖系数错误。

检查损失时加入极端但有限的得分，检查梯度时选择非零参数，检查预测时既包含边界附近点也包含高置信点。对于多类输出还应验证共同得分平移不变性；对于加权目标应核对所有权重同时乘一个常数后，在规定的归一化约定下会发生什么。每项检查都应对应一个可能的实现错误，而不是重复运行同一条正常输入。

13.11 算法成本、适用范围与知识联系

二分类全批量一次迭代主要需要 Xw 和 $X^{\mathrm{T}}r$，时间为 $O(nd)$；多分类为 $O(ndK)$，概率矩阵存储为 $O(nK)$。小批量可降低每次更新的内存占用；稀疏输入可以利用非零元素减少乘法，但把稀疏特征中心化可能使其变稠密。线性模型没有显式构造所有样本对，常适合作为高维文本的基线。

逻辑回归的主要限制来自表示：原始坐标上的线性边界不能表达任意交互，标准化也不会自动创造非线性。若误差来自缺少信息，增加迭代次数无效；若训练梯度还大，先解决优化问题；若训练好而验证差，应考察样本量、正则、泄漏和分布差异。错误的概率标签顺序同样会毁掉评价：库的概率列对应 `classes_`，必须核对列与真实类

别的映射。

本章将第 8 章的伯努利似然变成具体训练目标，将第 7 章的链式法则变成向量梯度，并把第 12 章的优化步骤用于凸目标。后续神经网络仍可使用相同输出层和交叉熵；改变的是产生得分的函数。自检时应能从概率定义推到损失、从损失推到梯度，再解释阈值为何独立于训练目标。

13.12 分层习题

13.1. 区分得分、概率和预测标签；说明名字中有“回归”为何仍用于分类。

13.2. 若 $p = 0.75$，求几率与对数几率。某特征系数为 $\log 2$，增加一个单位后原概率 0.75 变成多少？

13.3. 对 $z = 3x - 2$ 求阈值 0.5 和 0.9 的决策区域。

13.4. 重做例题 13.3，但初始 $w = 1, b = 0$、学习率 0.1、$\lambda = 0.2$，写出更新参数。

13.5. 从得分形式直接求二元交叉熵的一阶、二阶导数，并解释凸性。

13.6. 证明完全可分数据的无正则交叉熵下确界为 0，解释有限参数为何不能达到它。

13.7. 三类得分为 $(\log 2, 0, \log 3)$，真实类别为第三类，求概率、损失和得分梯度。

13.8. 证明两类 softmax 只依赖得分差。为什么两套参数不必能逐项对应？

13.9. 正、负类权重分别为 3、1。真实概率 0.25 时，加权最优输出是多少？加权输出 0.75 对应原概率多少？

13.10. 漏检成本 4、误报成本 1 时求最优阈值；列出直接套用该阈值所需的假设。

13.11. 用同一数据先训练模型，再拟合校准器，再报告校准后分数，有何问题？给出可实施的数据安排。

13.12. 修改实验 13.1 检查总损失与平均损失的系数对应，并用极端得分验证稳定公式；报告梯度误差与概率误差。

13.13 参考答案与核对步骤

13.1. 得分是任意实数，概率是条件分布的参数，标签是按决策规则离散化的结果。逻辑回归用仿射函数拟合对数几率，二分类只是最终输出用途；不能把三个输出都称为概率。

13.2. 几率为 3，对数几率 $\log 3$。特征增加 1 后几率乘 2 变为 6，所以新概率为 $6/(1+6) = 6/7$，增加约 0.107143，并非增加 $\log 2$。

13.3. 阈值 0.5 要求 $3x-2 \ge 0$，即 $x \ge 2/3$；阈值 0.9 要求 $3x-2 \ge \log 9$，即 $x \ge (2+\log 9)/3$。两边界平移，斜率不变。

13.4. 概率为 $(0.5, \sigma(2)) \approx (0.5, 0.880797)$。权重梯度为 $0.880797 - 1 + 0.2 = 0.080797$；截距梯度为 $(0.5 + 0.880797 - 1)/2 = 0.190399$。故新参数约为 $w = 0.991920, b = -0.019040$。

13.5. 对 $\log(1 + e^z) - yz$ 求导得 $\sigma(z) - y$，再求导为 $\sigma(z)(1 - \sigma(z)) \ge 0$。仿射复合与非负求和保持凸性，但有限最优点存在性仍需另证。

13.6. 令 $s_i = 2y_i - 1$，存在分离参数使 $s_i z_i > 0$。将参数乘 $a > 0$，每条损失为 $\log(1 + e^{-a s_i z_i}) \to 0$。有限 a 下指数严格正，每条损失严格正，所以只能趋近下确界。

13.7. 指数为 $(2, 1, 3)$、总和 6。概率 $(1/3, 1/6, 1/2)$，损失 $\log 2$，梯度 $(1/3, 1/6, -1/2)$。三项和为 0。

13.8. $p_1 = e^{z_1}/(e^{z_1} + e^{z_2}) = 1/(1 + e^{-(z_1 - z_2)})$。共同平移得分不会改变差，因此参数表示有冗余；L2 惩罚还依赖参数化方式。

13.9. $q = 3 \times 0.25/(3 \times 0.25 + 0.75) = 0.5$。反推时 $\eta = q/[3(1 - q) + q]$，代入 0.75 得 0.5。应把加权目标下概率与原始条件概率分开。

13.10. 阈值为 1/5。要求使用目标人群的校准条件概率，错误成本固定且正确成本为 0，决策按逐样本期望成本最小化；存在资源约束或其他动作时需要新决策模型。

13.11. 训练内得分不能代表未见样本的得分分布，且校准集上的最终分数又用于拟合。可划分训练、校准、测试，训练基础模型、拟合映射、最终一次测试；模型和校准器的选择也应在测试之外完成。

13.12. 原目标乘 n 后成为 $\sum \ell_i + n\lambda\|w\|^2/2$，最优点不变，梯度乘 n，使用原迭代轨迹需将学习率除以 n。检查 $z = \pm 1000$ 的正确与错误标签损失，错误标签约 1000、正确标签约 0，均有限。有限差分不能只在零参数点测一次，应选非零参数并检查每个坐标。

14 泛化、模型选择与可靠评价

先修知识、学习目标与本章位置

先修第 8 章的抽样与置信区间、第 9 章的期望风险、第 10 章的数据划分和 Pipeline，以及第 11–13 章的回归、优化与分类。本章说明训练表现为何不能替代泛化证据，建立超参数选择和最终评价的完整流程，推导常见分类指标，并讨论比较中的不确定性。后续算法章节应重复使用本章协议，而不是每出现一种模型就重新选择有利于它的测试方式。

两个分类器在同一测试集上分别得到 90% 和 91% 准确率，不能仅凭这一对数字断言第二个更适合部署。首先要知道样本数、类别比例、错误成本和数据来源；其次要确认测试集是否参与过选择，以及模型错的是不是相同样本。评价的对象也可能不同：有时要评价一个已经固定的模型，有时要评价“给定训练数据后搜索参数并训练”的整个学习流程。

泛化（generalization）指从已有训练数据得到的规则在所关心的新样本分布上的表现。它总是相对于一个任务、人群、时间范围和评价协议而言。随机划分下表现良好，不自动意味着可以推广到新医院、新用户或未来年份；选择划分方式本身就是对泛化问题的定义。

14.1 欠拟合、过拟合和误差来源

从训练与验证的差异出发

欠拟合（underfitting）通常指当前模型或训练流程没有充分表达数据中的可预测规律，例如真实关系呈明显弯曲而模型只能拟合直线。**过拟合**（overfitting）指拟合过度依赖训练样本中的偶然性，使训练误差降低却没有改善相应的新样本表现。过拟合可以来自复杂模型、过多特征、过长训练，也可以来自在验证集上反复试验。

训练误差高并不能单独证明模型容量不足。学习率过小、迭代次数不足、输入标签错位和损失实现错误也可能产生同样现象。训练误差低而验证误差高时，应检查样本量、模型复杂度和分布差异；如果存在时间或群体变化，单纯增强正则未必能解决。

观察	需要检查	可能措施
训练与验证都差	表示缺少信息、优化未收敛、标签错误	核对实现和基线，再改表示或模型
训练好、验证差	方差大、选择过多、划分分布不同	限制复杂度、增加有效数据、重审划分
训练与验证都好、部署差	泄漏、样本选择、输入或标签变化	核对信息可用时点和部署数据
验证优于训练	正则/增强、数据难度、抽样波动	统一评价模式和损失口径

表中的措施是排查方向，不是仅凭两条曲线作出的诊断结论。训练目标可能含正则，验证损失通常不含正则，两者直接作差前应先统一口径。

平方损失的偏差—方差分解

为给出精确含义，固定一个输入 x，设 $Y = f_*(x) + \varepsilon$，其中 $f_*(x) = E[Y \mid x]$，$E[\varepsilon \mid x] = 0$，条件噪声方差为 $\sigma^2(x)$。用随机训练集 D 得到预测 $\hat{f}_D(x)$，测试噪声与训练过程独立。记平均预测 $\bar{f}(x) = E_D[\hat{f}_D(x)]$。则

$$E_{D,Y|x}[(Y - \hat{f}_D(x))^2] = \sigma^2(x) + E_D[(f_*(x) - \hat{f}_D(x))^2] \tag{14.1}$$

$$= \sigma^2(x) + (f_*(x) - \bar{f}(x))^2 + E_D[(\hat{f}_D(x) - \bar{f}(x))^2]. \tag{14.2}$$

第一步的交叉项为 0，是因为噪声条件均值为 0 且与训练集独立。第二步在括号内加减 $\bar{f}(x)$，交叉项包含 $E_D[\hat{f}_D - \bar{f}] = 0$，故消失。

三项分别为不可约条件噪声、偏差平方、预测方差。**偏差**（bias）比较反复训练后的平均预测与真实条件均值；**方差**（variance）衡量更换训练集时预测如何变化。这里的方差不是原始标签方差，也不是一条训练损失曲线的振荡大小。公式严格针对平方损失；不能不加说明地把它逐项搬到准确率或交叉熵。

例题 14.1：计算偏差、方差与噪声

在某固定输入处，真实条件均值为 2，测试噪声方差为 1。两种等可能训练集分别使预测为 1 和 3。求平均平方预测误差。若另一方法总预测为 2.5，结果如何？

解 第一方法平均预测为 2，偏差平方为 0，方差为 $[(1-2)^2 + (3-2)^2]/2 = 1$，总误差为 $1 + 0 + 1 = 2$。第二方法偏差平方 0.25、方差 0，总误差 1.25。预测更稳定的方法在此例更优，即使它带有小的系统偏差。若真实均值改变，比较也可能改变。

正则化常以增加一些偏差来降低估计方差，但这不是对任意模型和任意数据都成立的单调定律。高容量模型的泛化行为还受优化和数据结构影响。实际选择应由正确的验证流程支持，而不能凭“越简单越好”或“参数越多越差”替代实验。

14.2 学习曲线和验证曲线怎样读

学习曲线（learning curve）通常以训练样本量为横轴，分别绘制训练和验证表现。它与第 12 章以训练步数为横轴的优化曲线不同。构造学习曲线时，保持评价集或外层划分规则固定，从训练部分取不同数量样本，每个数量重新拟合全部预处理和模型。

小训练集容易被拟合得很好，训练误差可能偏低；增加样本后训练问题更难，训练误差可能上升，而验证误差可能下降。若两者在较高误差处靠拢，且优化已充分完成，可以尝试更有信息的特征或更合适的模型。若二者差距大且验证误差随样本量仍下降，增加相同分布的有效数据可能有帮助。

每个样本量最好重复多个合法划分或子抽样，显示平均值和波动范围。同一用户的十条相关记录不能简单当作十份独立信息；增加重复数据未必产生预期的学习曲线收益。若子样本中少数类缺失，有些模型无法训练，必须采用与目标相符的分层或分组方案。

验证曲线（validation curve）则以某个超参数为横轴，例如岭惩罚、树深或近邻数 k。其他条件应保持一致。参数轴常跨多个数量级，正则强度适合用对数间隔，例如 0.001、0.01、0.1、1。不要仅在一个很窄的区间试两个值就断言模型对参数不敏感。

当若干配置差异小于评价波动时，可优先考虑运行成本、稳定性和实现复杂度。所谓“一个标准误规则”是在接近最佳值的候选中倾向较简单方案的启发式；交叉验证各折相互依赖，其标准误估计应谨慎，不能把规则当作严格的性能保证。

14.3 交叉验证与超参数搜索

每一折都重新拟合完整流程

交叉验证（cross-validation，CV）在开发数据上轮换训练与验证角色。K 折交叉验证把开发集分成 K 个互不相交的验证折。第 j 轮在其余 $K-1$ 折拟合模型，并只在第 j 折评价。若每折规模相等，可取折分数平均；规模不等时应明确采用等折权重还是等样本权重。

对于可逐样本相加的损失，按折大小加权的平均等于合并全部折外损失的平均；对于 F1、AUC 等非线性指标，平均折分数通常不等于把折外预测合在一起计算一次的分数。两种汇总回答的问题不同，应预先指定。

折外预测（out-of-fold prediction，OOF）是某样本由没有用它训练的那一折模型产生的预测。一次完整 K 折流程可为每条开发记录产生一个折外预测，但这些预测来自不同模型。不能把它们说成某个最终固定模型在一个独立测试集上的预测。



每一轮的均值填补、标准化、特征选择、过采样和降维都只能在本轮训练折拟合。先

在整个开发集标准化再交叉验证，会让验证折信息参与训练。即使未使用标签，严格的归纳评价也应把预处理放进 Pipeline。

随机独立样本分类可以采用分层折，尽量保持类别比例；同一用户多条记录需采用分组折；预测未来需采用时间顺序划分。分层不能消除用户泄漏，也不能把时间反转变成合法预测。某一折没有正类时，ROC AUC 无定义；不能擅自填成 0.5，必须调整设计或如实报告无法计算。

网格、随机搜索和选择偏差

超参数是在训练规则外指定的配置，如 λ、学习率、k、特征数和停止轮数。**网格搜索**枚举预先给定的组合；**随机搜索**从指定分布抽样组合。若三个参数各有 5 个值，网格有 $5^3 = 125$ 个候选，配合 5 折需要 625 次拟合，最后通常还要用最佳配置重训一次。嵌套预处理与校准也会增加拟合成本。

搜索应提前固定主要指标、候选范围、随机种子策略和资源预算。若根据验证结果增加候选、改标签或删样本，这些都是选择的一部分，需要体现在评价协议里。选择分数最好的候选相当于同时选择了其真实能力和有利的抽样噪声；试验越多，报告最高验证分数的乐观偏差可能越大。

例题 14.2：相同真实能力也能选出“最优模型”

两个候选的真实准确率相同。假设各自验证估计误差独立且以相同概率为 +0.02 或 −0.02。每次选验证分数较高者，其验证误差期望是多少?

解 四种等可能误差组合为 $(+.02, +.02)$、$(+.02, -.02)$、$(-.02, +.02)$、$(-.02, -.02)$。被选中的误差分别为 $+.02, +.02, +.02, -.02$，平均为 0.01。每个估计单独无偏，选择最大值后却平均高估一个百分点。真实交叉验证误差通常相关，但这个简单例子已揭示选择偏差的来源。

14.4 嵌套验证与最终测试集

若已有一次性独立测试集，可在开发集内部用 CV 选择配置，然后在整个开发集重训并最终测试。若没有足够大的独立测试集，或需要比较完整选择流程，使用**嵌套交叉验证**（nested CV）：外层验证性能，内层选择超参数。

每个外层轮次先留出外层验证折。在外层训练部分内部执行完整内层搜索，再按选中配置用全部外层训练数据重训，最后只评价一次外层验证折。不同外层轮次可以选中不同超参数，这是训练样本变化导致的正常现象。外层平均评估的是“给定一定规模训练数据，执行既定搜索”的过程，不是某个事先固定超参数的单一模型。

一个完整、可执行的评价顺序

先确定任务、人群、划分单位与主要指标；保留最终测试数据。仅在开发数据内探索、拟合预处理、选择模型、正则、阈值与校准方式。必要时以外层 CV 评价整套选择流程。冻结配置和报告模板后，用全部开发数据按预定规则训练，最后评价测试集，并同时报告基线、样本量和不确定性。

外层分数不能随后被无限用于挑选搜索空间，再被称为未参与选择的评价。如果对外层结果反复作决策，外层也变成了开发反馈。只有当数据隔离与实际操作一致时，“外层”“测试”等名称才有意义。

测试集使用一次并不是说程序只能读取文件一次。排版、指标复算和已声明分组报告可以使用同一固定预测；关键是不要依据测试反馈继续选择模型后仍把同一分数当作独立证据。若测试揭示严重缺陷，应诚实修复并把这批测试数据降为开发资料，另找新的验证机会。

14.5 混淆矩阵与阈值指标

四种计数和分母含义

规定类别 1 为正类，0 为负类。**混淆矩阵**（confusion matrix）记录真实类别与预测类别的交叉计数。采用“行是真实、列是预测”的约定：

	预测 0	预测 1
真实 0	TN：真负	FP：假正
真实 1	FN：假负	TP：真正

某些资料轴顺序相反，使用时应先看行列说明。假正是误报，假负是漏检；正类指人为指定的关注类别，不代表价值判断。

常见指标为

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + TN + FN}, \tag{14.3}$$

$$\text{Precision} = \frac{TP}{TP + FP}, \qquad \text{Recall} = \text{TPR} = \frac{TP}{TP + FN}, \tag{14.4}$$

$$\text{Specificity} = \frac{TN}{TN + FP}, \qquad \text{FPR} = \frac{FP}{FP + TN}, \tag{14.5}$$

$$F_1 = \frac{2PR}{P + R} = \frac{2TP}{2TP + FP + FN}. \tag{14.6}$$

精确率回答“预测为正的记录中多少是真的”，召回率回答“实际正类中找到了多少”。两个分母对应不同人群。特异度衡量实际负类被正确排除的比例，假正率与它互补。

F1 是精确率和召回率的调和平均。若二者为 0.9 与 0.1，F1 为 0.18，低于算术平均 0.5；它会限制“一项高、一项很低”带来的表面平均优势。但 F1 忽略 TN，也没有显式表达错误成本，所以并非所有不平衡任务都必须使用 F1。

没有预测正例时，精确率的分母为 0；没有真实正例时，召回率无定义。库可能按选项返回 0、NaN 或警告。报告必须写清约定，不应把没有正例的群体自动描述为“检测能力为 0”。多类宏平均也会受到这些约定影响。

例题 14.3：手算两个阈值的混淆矩阵

真实标签为 $(1,0,1,0,0,1)$，概率为 $(0.9,0.8,0.7,0.4,0.3,0.2)$。用 $p \ge t$ 判正，比较阈值 0.5 与 0.75。

解 在 0.5 下，前 3 条判正，$TP=2, FP=1, TN=2, FN=1$，准确率、精确率、召回率、F1 均为 $2/3$。在 0.75 下，前 2 条判正，$TP=1, FP=1, TN=2, FN=2$，准确率 $1/2$，精确率 $1/2$，召回率 $1/3$，F1 为 $2/(2+1+2)=0.4$。阈值上升使预测正例集合缩小，但精确率不保证逐步上升，本例反而下降。

多类别指标怎样汇总

对每个类别分别看作正类，其余类别合并为负类，可以计算各类精确率、召回率与 F1。**宏平均**（macro average）对各类指标等权平均，关注每一类；**加权平均**（weighted average）按真实类别数量加权，容易受大类主导；**微平均**（micro average）先汇总计数，再计算指标。

对于每条样本恰有一个真实类别和一个预测类别、且统计全部类别的普通多分类任务，微精确率、微召回率和微 F1 都等于准确率，因为每次分类错误同时贡献一个 FP 和一个 FN。多标签或只统计部分类别时，这个等式不再普遍成立。宏 F1 是各类 F1 的平均，通常不等于宏精确率与宏召回率的调和平均。

平衡准确率（balanced accuracy）在二分类中为 $(\mathrm{TPR}+\mathrm{TNR})/2$，在多分类中通常为各类召回率的平均。它减轻大类数量对普通准确率的主导，但仍需考虑每类样本数和置信区间。

14.6 ROC、PR 与排序指标

ROC 曲线与成对比较

逐渐降低阈值，预测正例从空集合扩展到全部样本。以假正率 FPR 为横轴、真正率 TPR 为纵轴得到 **ROC 曲线**（receiver operating characteristic curve，受试者工作特征曲线）。每个点对应一个阈值；相同得分应作为一组同时跨越阈值，不能任意拆开制造更漂亮的曲线。

ROC 曲线下面积（ROC AUC）可解释为：随机取一个正例和一个负例，正例得分高于负例的概率，加上同分概率的一半。对 n_+ 个正例和 n_- 个负例，经验形式为

$$\mathrm{AUC}=\frac{1}{n_+n_-}\sum_{i:y_i=1}\sum_{j:y_j=0}\left(\mathbf{1}[s_i>s_j]+\frac{1}{2}\mathbf{1}[s_i=s_j]\right).$$

得分 s 可以是概率或未归一化决策值。严格单调递增变换保持排序，所以不改变 AUC。AUC 高不代表 0.5 阈值好，也不代表概率校准；部署可能只关心极低误报区间，整体 AUC 又可能掩盖这个局部区间的不足。

PR 曲线与平均精确率

PR 曲线（precision-recall curve）以召回率为横轴、精确率为纵轴。它直接关注预测正例中的质量，在稀少正类场景中常更容易看出大量误报的后果。若不依赖得分随机选记录，期望精确率约等于正类比例；因此不同正类比例数据集的 PR 水平不能无条件横比。

平均精确率（average precision，AP）常按召回增量加权：

$$\mathrm{AP} = \sum_j (R_j - R_{j-1}) P_j.$$

按得分从高到低处理不同得分组，P_j, R_j 为纳入该组后的精确率与召回率。无同分时，每遇到一个正例召回增加 $1/n_+$，AP 就是各正例所在排名处精确率的平均。AP 采用阶梯式加权；把 PR 点用直线连起来再用梯形积分，通常得到不同的“PR AUC”，报告时应写明具体定义。

> **例题 14.4：排序指标为什么给出不同信息**
>
> 继续使用例题 14.3 的数据。正例得分为 0.9、0.7、0.2，负例得分为 0.8、0.4、0.3。求 ROC AUC 与 AP。
>
> **解** 最高正例战胜 3 个负例，0.7 战胜 2 个，0.2 战胜 0 个，共 5 次成功，无同分，故 AUC 为 $5/9 \approx 0.555556$。正例排名为 1、3、6，对应精确率 $1, 2/3, 3/6$，故 AP 为 $(1 + 2/3 + 1/2)/3 = 13/18 \approx 0.722222$。AP 较高并非计算矛盾；它对排序前端的正确正例和正类比例更敏感，两种指标没有相同的数值标尺。

类别比例改变后的误报规模

令目标正类比例为 π。在给定阈值下若类条件得分分布不变，TPR 与 FPR 不变，则

$$\mathrm{Precision} = \frac{\pi\,\mathrm{TPR}}{\pi\,\mathrm{TPR} + (1-\pi)\,\mathrm{FPR}}.$$

这是贝叶斯公式在预测结果中的应用。在 10000 条样本中，正类比例 1%、TPR 为 0.9、FPR 为 0.05，则 TP 约 90、FP 约 495，精确率只有 $90/585 \approx 0.153846$。95% 特异度看似很高，在低发生率场景中仍可产生大量误报。该公式以类条件分布保持不变为条件，现实人群改变时 TPR、FPR 也可能一起改变。

多分类 ROC AUC 通常需明确一对其余或一对一，以及宏平均或按类别频数加权。单个总分不替代各类错误分析，尤其应查看少数类是否被某一个相邻类别系统性吞并。

14.7 概率指标、任务成本与基线

交叉熵和 Brier 分数

第 13 章的平均交叉熵评价模型赋给真实类别的概率。错误且极其自信的预测会受到较大惩罚。**Brier 分数**在二分类下定义为

$$\mathrm{Brier} = \frac{1}{n}\sum_i (p_i - y_i)^2.$$

它位于 0 与 1 之间，数值越小越好。固定输入处，若真实正类概率为 η，则

$$E[(p-Y)^2 \mid x] = (p-\eta)^2 + \eta(1-\eta).$$

因此期望在 $p=\eta$ 达到最小。交叉熵和 Brier 都是鼓励报告真实概率的适当评分规则；它们综合概率区分与校准信息，不能简单把 Brier 直接称作“校准误差”。

在多分类时，一种定义是 $n^{-1}\sum_{i,k}(P_{ik}-Y_{ik})^2$，取值可到 2；有的接口又除以 2。比较不同软件数值前要核对归一化。本章实验采用二分类标量定义，避免混用量纲。

第 13 章已说明概率为 0 时对真实正例的数学交叉熵为无穷。库计算可能用机器精度裁剪概率以返回有限数；报告极端结果时需说明实现约定。训练损失若含正则项，与测试的纯交叉熵也不是同一量。

指标应对应实际用途

若每个误报成本 1、漏检成本 9，可直接报告总成本 $FP+9FN$ 或每样本平均成本。若每天只能审核 100 条，可报告前 100 条的精确率与召回数，并说明容量和每天样本量。若目标是给用户可靠风险概率，应同时关注对数损失、Brier 和可靠性图，单独优化准确率无法保证这一用途。

基线（baseline）是预先声明的简单比较方案。分类可用训练集多数类或训练正类比例，回归可用训练均值、训练中位数或合理的业务规则。用测试集正类比例设置常数概率，相当于使用了测试标签，不能再作为纯训练得到的基线。基线必须采用相同的数据划分和指标。

例题 14.5：正确率相同，概率质量不同

两个样本标签为 $(1,0)$。模型 A 输出 $(0.6,0.4)$，模型 B 输出 $(0.9,0.1)$。计算默认准确率、交叉熵和 Brier。再把标签交换。

解 原标签下两者准确率均为 1。A 的交叉熵为 $-\log 0.6 \approx 0.510826$，B 为 $-\log 0.9 \approx 0.105361$；Brier 分别 0.16、0.01。交换标签后准确率都为 0，A 交叉熵为 $-\log 0.4 \approx 0.916291$，B 为 $-\log 0.1 \approx 2.302585$，Brier 分别 0.36、0.81。更自信的模型在正确时更好，在错误时损失也更大。

14.8 不确定性：样本波动与训练波动

固定模型的测试抽样不确定性

对已固定模型，若测试样本近似独立同分布，准确率可视为正确指示变量的样本均值。若准确率为 $\hat{p}$，大样本标准误近似为 $\sqrt{\hat{p}(1-\hat{p})/n}$。样本少或接近 0、1 时，应考虑第 8 章的 Wilson 区间，而非直接使用可能越界的正态区间。

例如 100 条独立样本中 90 条正确，标准误约 0.03；误差一两个百分点可能不足以支持稳定排序。10000 条高度相关的同一用户记录，不等价于 10000 个独立用户。区间必须按照独立抽样单位设计，用户内相关可按用户重采样，时间依赖需用适合时间结构的方法。

比较两个模型要保留配对

同一测试样本上比较 A 和 B 时，应先构造逐样本损失差 $d_i = \ell_{A,i} - \ell_{B,i}$。其均值为平均性能差。独立记录条件下，差均值标准误约为 $s_d/\sqrt{n}$，其中 s_d 是差值的样本标准差。不要把两个模型分数的标准误独立相加，因为两者经常在同一难例上一起犯错。

配对 bootstrap 用同一索引同时重采样标签和两组预测。每次计算差值，再取分位数形成区间。对 F1、AUC 等非线性指标，应在每次抽样中重算整个指标，而非平均所谓逐样本 F1；若抽样后缺失某类，AUC 可能无定义，需预先选用合法方案并报告。分层 bootstrap 会固定类别数，它估计的不确定性条件与普通抽样不同。

区间究竟覆盖什么变化

固定测试预测的 bootstrap 只反映测试样本组成变化，不包含重新训练、重新搜索和分布变化。若要研究训练随机性，可重复种子；若要研究训练样本变化，应重新划分或重采样后重新拟合整个流程。重复种子均值和标准差不能代替未来人群的置信区间。

交叉验证折之间共享大量训练数据，因此各折分数不是独立重复实验。简单使用“折标准差除以 $\sqrt{K}$”作为严格置信区间可能低估不确定性。可将折分数离散程度作为描述，但应把更严格的推断建立在相应设计与假设上。

若比较很多模型、指标和子群体，总会有一些差异因偶然波动看起来突出。提前声明主比较和主要指标，完整报告试验范围；探索性发现应以新的数据验证。置信区间不含 0 也不自动说明差异有实际价值，还要看改善规模是否值得额外推理时间、内存和维护成本。

14.9 错误分析与消融实验

错误分析按预先有意义的维度检查失败，例如类别、输入长度、设备、时间和缺失程度。先保存每条记录的标识、真实标签、概率和预测，再计算分组计数与指标。小群体分数波动很大，不能只列比例不列样本量。检查最自信的错误常能发现标签错误、重复记录、分布变化或预处理失效。

错误分析应主要在开发集或折外预测上进行。对最终测试错误作事后解释可以帮助认识限制，但若据此改模型，就要承认测试已提供开发反馈。删除“模型不擅长”的测试样本会改变目标人群，不能仅为了提升分数。

消融实验（ablation study）移除或替换一个组件，以研究其作用。例如比较有无标准化、有无某组特征，或不同正则。应固定同一划分、指标和随机策略，避免同时改动多个因素使结果无法归因。若移除组件后仍使用原先仅为完整系统选择的超参数，结果回答的是“固定配置下移除会怎样”；若允许重新调参，则回答“移除后能达到怎样的最佳流程表现”。两者都可研究，但必须注明。

实验记录至少保存数据版本、划分方式与种子、标签映射、候选配置、主要指标、每折分数、最终重训规则和软件版本。保存一个最高分无法重建选择过程，也无法知道是否存在大量未报告失败。模型比较表应同时给出基线、评价样本数和必要的资源成本。

14.10 实验 14.1：从固定概率计算评价指标

入口为 配套实验/ch14_metrics.py，使用 NumPy 和 scikit-learn。数据就是例题 14.3 的六条固定记录，目的是手算对照，不是用六条样本建立可靠业务证据。

```
import numpy as np
from sklearn.metrics import confusion_matrix

y = np.array([1, 0, 1, 0, 0, 1])
p = np.array([.9, .8, .7, .4, .3, .2])
pred = p >= .5
cm = confusion_matrix(y, pred, labels=[0, 1])
tn, fp, fn, tp = cm.ravel()
print(cm)
print(2*tp / (2*tp + fp + fn))
```

显式传 `labels=[0,1]` 固定行列顺序。实验计算两个阈值、ROC AUC、AP、二分类交叉熵和 Brier，再比较另一组固定概率。两组 Brier 的逐样本差按同一索引有放回抽 10000 次，交换模型时每个抽样差应精确变号。

运行 `python3` 配套实验/ch14_metrics.py。ROC AUC 为 5/9，AP 为 13/18，交叉熵约 0.758069，Brier 约 0.271667。第二组概率为 $(0.8, 0.7, 0.8, 0.3, 0.2, 0.4)$，A 减 B 的 Brier 差为 0.095。本环境固定种子 1401 的百分位区间约为 $[0.026667, 0.181667]$；因原样本极少，这个区间仅展示计算机制，不用它宣称可靠改进。浮点指标允许 10^{-9} 绝对误差，随机分位数随版本和随机流可能变化。

修改任务：对概率作严格单调变换 $p \mapsto p^2$，观察 AUC 与 AP 保持不变，而 Brier、交叉熵和 0.5 阈值下的标签可以改变。把所有标签改为 0，检查哪些指标仍有定义，并记录库的警告；不应让脚本静默返回一组看似正常的完整分数。

14.11 实验 14.2：把完整搜索放进外层验证

入口为 配套实验/ch14_selection.py。用固定种子 1402 生成 600 条、12 个特征的二分类模拟样本，正类比例约 30%，标签带少量噪声；其中 120 条最终测试、480 条开发。开发部分采用 5 折外层、4 折内层，比较 $C \in \{0.01, 0.1, 1, 10\}$。每次拟合均包含训练折标准化和逻辑回归，主要指标预先设为对数损失。

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import GridSearchCV

pipe = make_pipeline(StandardScaler(),
                     LogisticRegression(max_iter=2000))
search = GridSearchCV(
    pipe, {"logisticregression__C": [.01, .1, 1., 10.]},
    scoring="neg_log_loss", cv=4)
```

嵌套参数名称使用双下划线，把模型名与参数名连接。scikit-learn 的搜索接口统一按“分数越大越好”处理，因此最小化损失时使用负损失；展示时要再取负，不能把 −0.4 误读为比 −0.3 更好。

完整脚本显式建立打乱且固定种子的分层内外折，通过 `cross_val_score` 在每个外层训练部分重新拟合整个搜索对象。外层评价结束后，在全部开发数据上重新搜索和重训，最后只评价一次测试；同时报告只使用开发标签比例的常数基线。外层共约 $5(4 \times 4 + 1) = 85$ 次基础模型拟合，最终开发搜索另需 17 次。

运行入口为 `ch14_selection.py`。本环境外层五个损失约为 0.451716、0.470414、0.330199、0.329541、0.401137，平均 0.396601；全开发搜索选 $C = 1$，测试损失约 0.369281，基线约 0.624372，测试准确率约 0.808333。数值记录用于复现本次模拟，不作为逻辑回归在其他任务上的性能结论。

修改任务应从不查看测试的开发阶段开始：将主要指标改为平衡准确率，或减少可用训练样本，重新运行内外验证并记录配置是否变化。若比较两个协议，应先把比较方案固定，不能在看完两种测试结果后继续增加第三种并只报告最高者。对于已有最终测试反馈的当前模拟，反复修改属于教学探索，不能继续把原测试称为新的独立证据。

14.12 评价设计中的几个容易混淆的边界

合并折外预测和平均折分数

假设两个验证折的混淆计数不同。第一折 $TP = 9, FP = 1, FN = 0$，F1 为 $18/19$；第二折 $TP = 1, FP = 9, FN = 0$，F1 为 $2/11$。等权平均 F1 约为 0.564593。合并计数后 $TP = 10, FP = 10, FN = 0$，F1 为 $20/30 = 2/3$。即使两个折样本数相同，结果仍不同，因为 F1 是计数比值的非线性函数。

对于 AUC，合并来自不同模型的折外得分，还会引入跨折正负样本比较。若某折模型得分整体偏高，跨折排序可能与每折内部排序不一致。折外预测适合许多诊断和后续训练任务，但合并指标需说明不同模型分数是否处于可比尺度。

对数损失则可按每条记录直接相加。若两折分别有 20 条和 80 条，平均损失为 0.2 和 0.5，那么按样本汇总为 $(20 \times 0.2 + 80 \times 0.5)/100 = 0.44$，等折平均为 0.35。前者给每条样本相同权重，后者给每折相同权重；如果每折代表不同机构，哪种问题更有意义取决于目标是随机患者还是随机机构。

重复验证不制造新的独立数据

重复打乱 5 折交叉验证可以查看结果对划分的敏感性。若做 10 次重复，总共有 50 个折分数，但原始记录还是同一批，不能宣称得到 50 份独立数据集。重复通常降低特定划分带来的偶然性，却不会消除有限样本、标签偏差或人群选择偏差。

固定随机种子便于复现一次随机过程，不是统计可靠性的证明。先试许多种子，再只保留最好的一次，相当于把种子也当成超参数搜索。若部署训练本来会使用随机初始化，应预先决定报告多个种子的均值、范围或固定规则下的模型，而不是事后选择。

同理，同一个测试集上两个模型的置信区间有重叠，不等于二者差异没有证据；不重叠也不是所有设计下唯一的判定标准。应直接研究配对差值的分布和实际重要性。相关性越强，直接配对比较可能越能消除共同样本难度引起的波动。

从错误计数到实际决策规模

若部署每天有 100000 条记录，FPR 为 0.001 可能意味着接近 100 次误报，而不是“只有 0.1%，可以忽略”。评价应同时报告比例与预期数量，尤其是人工处理能力有限时。数量推算要求测试条件近似代表部署，否则只是一种情景估计。

以正类比例 0.002、TPR 为 0.8、FPR 为 0.001 为例，每天期望 TP 为 160，FP 约 99.8，共需审核约 259.8 条，精确率约 0.616。若审核容量每天只有 200 条，原阈值的成本公式还不足以满足资源约束。可在开发数据上研究按得分排序取前 200 条的政策，并报告容量固定时的命中数；不能先用测试标签挑出最有价值的 200 条。

不同业务时间段的输入数量也可能变化。固定阈值使每日审核量变化，固定前 k 使每日阈值变化。两种政策应分别模拟和评价，不能把一个政策的离线分数套给另一个政策。

一个可审计的结果表应包含什么

一份最小完整记录可以分成任务协议、选择过程和最终结果三部分。任务协议写明预测时点、目标定义、可用特征、划分单位和主要指标；选择过程列出所有候选、预处理状态如何拟合、随机规则和停止条件；最终结果保存模型版本、测试样本数、基线、主要指标、配对差值或合适区间，以及预先声明的重要子群体。

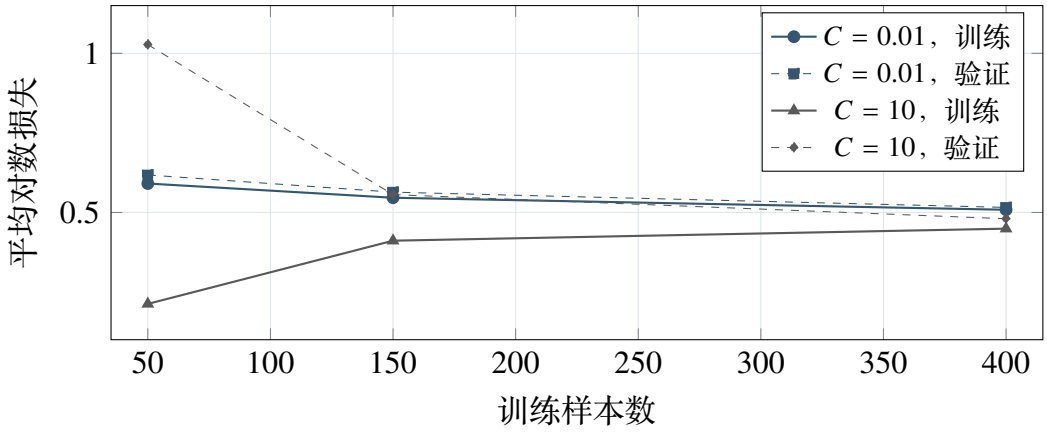
若某一模型未收敛、某一折缺少类别或某项指标无法计算，应保留失败记录并说明处理规则。静默删掉失败折可能选择性提高平均分。调参时也应限制不合法组合，例如某训练折样本数少于近邻数、类别计数不足以分层，或预处理生成空特征集。

对运行成本，可以报告相同硬件上的训练耗时、单条或批量推理延迟、模型与索引大小。高准确率但推理成本超出场景的方案可能没有实际可用性；成本指标必须在与部署相近的批量、预热和并发条件下解释。

学习曲线的可运行补充

配套入口 `ch14_learning_curves.py` 使用固定模拟训练数据与独立验证部分，比较两个正则配置。在每种配置下，采用三个分层子抽样种子和三个训练规模，每次重新拟合标准化与逻辑回归，输出训练、验证对数损失的均值和离散程度。它不另设一个被反复查看的最终测试集，所有输出明确用于开发诊断。

检查重点是每次标准化仅使用当前子训练集，训练规模增加时标签仍包含两类，图表横轴是样本数量而非迭代步数。曲线不必严格单调：每个规模使用不同子样本，估计误差和数据难度都会改变。解释时看平均趋势与重复间差异，不对单个拐点编造机制。完整脚本保存数值表和图，便于把可视化判断与具体数值核对。



图为上述补充实验的实测均值，训练和验证各用独立标记，虚线表示验证损失。每个点来自三个固定种子；为使主图清楚，这里只画均值，完整标准差保存在数值表和配套图中。连接线便于观察，不表示中间样本量已经实际测量。

当只有 50 条训练样本时，$C = 10$ 的训练损失约 0.213，验证损失却约 1.028；较弱正则使小样本拟合更充分，却在这次模拟中产生较大验证误差。$C = 0.01$ 的训练和验证损失都约 0.6，间隔较小，但不等于它已经达到最优任务性能。

当训练增至 400 条，两个配置的训练验证差距都缩小，$C = 10$ 的验证损失约 0.480，低于 $C = 0.01$ 的 0.516。于是“正则越强越好”不成立：合适的约束与有效样本量有关。三个种子不足以给出严格统计结论，图仅用于诊断并形成下一步开发假设。

14.13 知识联系与自检

第 9 章区分了模型、优化和统计误差，本章提供诊断和评价这些差异的操作方法。第 10 章的 Pipeline 保护折间信息边界；第 13 章的概率输出支持阈值、排序和概率三类评价；第 8 章的不确定性帮助避免把有限样本小差异夸大为稳定优势。

完整评价报告应使读者能够回答：预测对象是什么，未来样本怎样产生，选择过程用了哪些数据，主要指标为什么符合用途，结果有多大波动，失败集中在哪里。一个总分即使保留十位小数，也不能回答这些问题。

14.14 分层习题

14.1. 训练和验证误差都高时，列出四个可能原因，并给出排查顺序。

14.2. 固定输入处真实均值为 4，噪声方差 2，训练后预测等可能为 2、4、6。求偏差平方、方差与总平方误差。

14.3. 有 1000 条样本，5 折 CV 比较 12 个配置，选中后在全部开发集重训一次，需要多少次拟合？若外层再设 4 折且最终仍做一次完整开发搜索呢？

14.4. 为什么先对全部开发数据做特征选择，再进行交叉验证会泄漏？无监督标准化是否可以无条件例外？

14.5. 某分类器 $TP = 30, FP = 10, FN = 20, TN = 940$，求准确率、精确率、召回率、F1 和平衡准确率。

14.6. 正类得分为 $(0.8, 0.5)$，负类为 $(0.5, 0.2)$，求含同分修正的 ROC AUC。

14.7. 按得分降序的标签为 $(0, 1, 1, 0, 1)$ 且无同分，求 AP；解释它为何不同于准确率。

14.8. 发生率 0.02、TPR 为 0.8、FPR 为 0.1 时，求精确率；若发生率变为 0.2 且类条件表现不变呢？

14.9. 在二分类平方概率损失下推导总体最优预测为真实条件概率，解释为什么 Brier 不能只代表校准。

14.10. 同一测试集上 A、B 各错 10 条，是否足以判断性能差异的波动？还需要哪些信息？

14.11. 设计一个有无标准化的消融实验，区分固定超参数与允许重调参两种问题。

14.12. 运行两个实验并做单调概率变换；记录排序指标、阈值指标和概率指标分别怎样变化。

14.15 参考答案与核对步骤

14.1. 可能是标签对齐错误、优化未收敛、特征缺少信息、模型表达不足。先用小样本和手算检查数据与实现，再看损失和梯度是否正常，比较合理基线，最后研究新表示和更复杂模型。直接增加模型规模会掩盖实现错误。

14.2. 平均预测 4，偏差平方 0；方差为 $(4+0+4)/3 = 8/3$；总误差为 $2 + 8/3 = 14/3$。若只计算预测离散程度而漏掉测试噪声，就会低估期望误差。

14.3. 普通搜索为 $5 \times 12 + 1 = 61$ 次。4 折外层各自运行内层搜索并重训，共 $4 \times 61 = 244$ 次；最终全开发搜索再 61 次，总 305 次。不含预处理内部额外拟合和失败重试。

14.4. 特征选择看到验证标签后，会把验证中的偶然相关编码进特征集合，随后模型已间接利用验证信息。标准化即使不使用标签，也利用验证分布；严格的归纳协议应在每个训练折重新拟合。若研究明确允许无标签测试输入的传导设置，应单独声明这种任务。

14.5. 总数 1000，准确率 0.97；精确率 $30/40 = 0.75$；召回率 $30/50 = 0.6$；F1 为 $60/(60+10+20) = 2/3$；特异度 $940/950 = 94/95$，平衡准确率为 $(0.6+94/95)/2 \approx 0.794737$。

14.6. 四对比较中，0.8 胜两次，0.5 对 0.5 平局计 0.5、对 0.2 胜一次。因此 AUC 为 $3.5/4 = 0.875$。

14.7. 正例排名 2、3、5，AP 为 $(1/2 + 2/3 + 3/5)/3 = 53/90 \approx 0.588889$。准确率需要指定阈值，而 AP 整合排序过程中召回增加时的精确率，二者评价对象不同。

14.8. 第一种精确率为 $0.016/(0.016 + 0.098) = 8/57 \approx 0.140351$。第二种为 $0.16/(0.16 + 0.08) = 2/3$。保持相同 TPR/FPR 的前提是类条件得分分布不变。

14.9. $E[(p-Y)^2] = p^2 - 2p\eta + \eta = (p-\eta)^2 + \eta(1-\eta)$，后项不依赖预测，故最小点为 $p = \eta$。不同输入的真实概率分布影响可分辨程度和不可约项，Brier 综合这些信息，不能脱离数据分布只解释为校准距离。

14.10. 还需知道两个模型在每条样本上的成败配对以及抽样单位。若错误完全重合，逐样本 0–1 损失差恒为 0；若错误完全不重合，差值有正负波动。边际错误总数相同不能确定差值方差。

14.11. 固定合法划分，使用相同候选模型和主要指标。方案一固定原超参数，只去掉标准化，研究组件移除的直接影响；方案二对两个流程分别在各训练折内部重调参，研究各自能达到的流程表现。两者都应把测试排除在选择之外。

14.12. 严格单调变换保持无同分得分顺序，所以 ROC AUC 和 AP 不变。0.5 阈值对应的原概率位置改变，因此混淆矩阵可能变化；交叉熵和 Brier 直接使用概率值，一般变化。应同时核对标签列映射和概率范围，保存修改前后完整结果。

15 k 近邻与距离学习

先修知识、学习目标与本章位置

先修第 4 章的数组广播、第 6 章的范数和正定矩阵、第 10 章的标准化与无泄漏 Pipeline，以及第 14 章的模型选择。本章进入第三篇经典机器学习算法，完整建立 k 近邻分类与回归，解释距离如何受表示和尺度影响，分析高维数据与检索成本，并介绍监督距离学习。第 1、4 章使用过近邻作为流程示例，本章补齐其统计含义、实现细节和适用边界。

已知若干房屋的面积、房龄和成交价，预测一套新房屋的价格，可以先寻找特征最相似的成交记录，再平均其价格。若任务改为识别一种植物，可以查找测量值最接近的已标注植物，再按类别投票。这一共同思想称为 **k 近邻**（k-nearest neighbors，kNN）：用查询点附近的训练样本估计局部输出。

近邻法将主要计算留到预测阶段。训练通常包括保存样本、拟合预处理和建立索引，而不一定求一个固定长度的权重向量。因此它常被称为**惰性学习**（lazy learning）或基于实例的学习。惰性不表示计算总量小；样本多时，检索开销可能远大于线性模型的一次矩阵乘法。

15.1 相近的输入为什么可能有相近的输出

近邻方法依赖一个与任务相关的局部规律：在所用表示和距离下，足够接近的输入，其条件输出分布应相似。回归中，条件均值 $m(x) = E[Y \mid X = x]$ 在邻域内变化不大；分类中，各类别后验概率 $\eta_c(x) = P(Y = c \mid X = x)$ 在邻域内变化不大。模型不是预先知道这些函数，而是用附近记录作局部估计。

这个假设不由距离公式自动保证。两个用户编号相邻不表示兴趣相近；两张图片像素欧氏距离小不一定语义相同；一个重要的少数类样本可能被大量多数类邻居包围。因此近邻算法的行为同时取决于表示、距离、邻域大小、聚合方式和训练数据覆盖。

设训练输入 $X \in \mathbb{R}^{n \times d}$，标签为 $y_1, \dots, y_n$。对查询 x，计算 $d_i = d(x, x_i)$，将样本按距离排序。令 $N_k(x)$ 为距离最小的 k 个训练下标，$1 \le k \le n$。遇到相同距离时，集合可能不唯一，程序必须规定选择方式。以下手算默认按原始下标稳定排序；类别票数相同则选择预先声明的较小类别编号。

15.2 距离、相似度与数据表示

欧氏、曼哈顿和 Minkowski 距离

距离度量通常要求非负、对称、同一点距离 0 且不同点距离正，并满足三角不等式。欧氏距离为

$$d_2(x, q) = \left[\sum_{j=1}^{d} (x_j - q_j)^2 \right]^{1/2} = \|x - q\|_2.$$

它度量直线长度，球形邻域由同一半径限定。**曼哈顿距离**（Manhattan distance）为 $d_1(x,q)=\sum_j |x_j-q_j|$，对应坐标轴方向差异之和。一般的 **Minkowski 距离**为

$$d_p(x,q)=\left[\sum_j |x_j-q_j|^p\right]^{1/p}, \qquad p\ge 1.$$

当 $p\to\infty$，得到最大坐标差 $d_\infty=\max_j |x_j-q_j|$。$0<p<1$ 的同类表达通常不满足三角不等式，不应无条件使用依赖度量性质的检索剪枝。

欧氏距离和平方欧氏距离具有相同的升序排名，所以只为选邻居时可以不求平方根。但平方距离一般不满足三角不等式；若距离进入 $1/d$ 权重、半径阈值或度量树的下界，就不能把 d 与 d^2 随意互换。

例题 15.1：距离的选择会改变最近邻

查询点为 $(0,0)$，候选 A 为 $(3,0)$，B 为 $(2,2)$。分别按欧氏、曼哈顿和最大坐标距离选最近邻。

解 欧氏距离为 3 与 $\sqrt{8}\approx 2.828$，选 B；曼哈顿距离为 3 与 4，选 A；最大坐标距离为 3 与 2，选 B。距离选择表达了“多个中等偏差”和“单个较大偏差”如何比较，不能在未说明任务的情况下认定某一种恒优。

余弦相似度与归一化

对于非零向量，**余弦相似度**为

$$\cos(x,q)=\frac{x^{\mathrm{T}}q}{\|x\|_2\|q\|_2}.$$

它主要比较方向，忽略正比例缩放产生的长度变化。某些文本词频和嵌入表示中，向量长度可能受文本长度影响，方向更接近所需语义；但是否适合仍需评价。若长度本身承载强度信息，归一化会丢失这种信息。

令 $u=x/\|x\|_2, v=q/\|q\|_2$，则

$$\|u-v\|_2^2=\|u\|^2+\|v\|^2-2u^{\mathrm{T}}v=2[1-\cos(x,q)].$$

因此单位归一化后，最大余弦相似度与最小欧氏距离给出相同排序。常用的 $1-\cos$ 被称为余弦距离，但不总满足三角不等式。零向量的方向无定义，需明确拒绝、特殊标记或采用约定，不能静默除以 0。

类别、缺失和混合特征

无序类别不能随意编码为 1、2、3 后计算欧氏距离，否则程序会认为类别 1 比类别 3 更接近类别 2，并强加人为顺序。独热编码使不同类别两点的平方距离为 2，可作为一种对称不匹配度量，但维度和该字段权重都会改变。多个分类字段与数值字段混合时，应明确每组贡献，避免高维字段仅因列数多就主导距离。

Hamming 距离计算同维离散向量中不相同坐标的数量或比例，适合特定二元或类别表示。混合类型也可采用按字段归一的差异再聚合；每项如何处理缺失、取值范围与权重都构成模型假设。

缺失值填补后可能把两个原本信息不足的样本人为拉近。加入缺失指示会让模型区分这种情况，但其权重还需选择。逐对只比较共同观测坐标会使不同样本对使用不同信息，甚至破坏原度量性质。不能直接把 NaN 交给普通欧氏距离，希望排序自动合理。

15.3 尺度如何改变邻域

标准化等于选择一种加权几何

面积以平方米、总价以元表示时，数值范围可能相差几个数量级。直接计算欧氏距离会把单位的选择当成重要性的选择。用训练均值 μ_j 和正尺度 s_j 标准化，$z_j = (x_j - \mu_j)/s_j$，两个点的平方距离变为

$$\|z(x) - z(q)\|^2 = \sum_j \frac{(x_j - q_j)^2}{s_j^2}.$$

共同中心 μ_j 在相减时抵消；改变距离的是缩放。标准化相当于给原坐标平方差赋权 $1/s_j^2$。这个权重由数据离散程度决定，不等于监督意义上的预测重要性。

常数列训练标准差为 0，可按第 4 章约定用尺度 1，或直接删除。训练中常数不代表未来永远常数；新批次发生变化时也应检查输入范围。极端值会影响均值和标准差，可以考虑稳健尺度或业务变换，但仍在训练部分拟合。

> **例题 15.2：仅仅换单位就改变邻居**
>
> 查询为 $(0,0)$，训练点 A 为 $(1,100)$，B 为 $(3,0)$。原尺度和训练预处理规定的尺度 $(1,100)$ 下，最近邻分别是谁？
>
> 解　原距离分别为 $\sqrt{1+10000} \approx 100.005$ 与 3，选 B。按给定尺度缩放后，A 为 $(1,1)$、B 为 $(3,0)$，距离为 $\sqrt{2}$ 与 3，选 A。这个例子使用预先指定尺度展示几何变化，不声称两条样本足以稳定估计真实尺度。若只改变计量单位而相应尺度同步换算，标准化距离应不变。

分类与回归目标都依赖邻域，所以输入缩放可显著改变预测。回归标签是否缩放是另一问题：均匀近邻平均对标签仿射变换具有相应等变性，但标签不能参加输入距离计算，否则预测时尚未知的目标会泄漏进特征。

Mahalanobis 距离与白化

令 $M \in \mathbb{R}^{d\times d}$ 为对称正定矩阵，**Mahalanobis 距离**定义为

$$d_M(x,q) = \sqrt{(x-q)^{\mathrm{T}} M (x-q)}.$$

若 M 为对角阵，它只调整各坐标权重；非对角项允许旋转并处理特征相关性。取 $M = \Sigma^{-1}$，其中 Σ 为正定协方差矩阵，相当于在白化后的坐标中计算欧氏距离。沿高方差方向的差异被缩小，沿低方差方向的差异被放大。

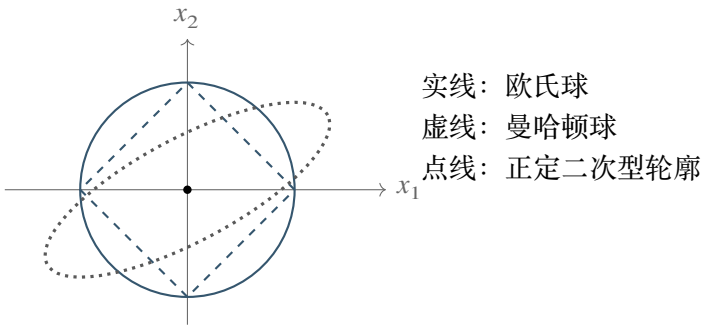
由第 6 章的分解，若 $M = L^{\mathrm{T}}L$，则

$$d_M(x,q) = \|Lx - Lq\|_2.$$

所以学习距离可以转化为学习一个线性表示。若 $L \in \mathbb{R}^{r\times d}$ 且 $r < d$，M 只有半正定，不同点可能投影到同一位置，得到的是**伪度量**；仍可用于检索，但不再满足不同点距离必须大于 0 的要求。

样本少或特征相关时，样本协方差可能奇异或病态。使用 $(\widehat{\Sigma} + \gamma I)^{-1}$ 可改善数值条件，但 γ 的取值也会改变距离，应在训练验证流程中选择。实际可用分解求解，不显式构造逆矩阵。无监督白化强调总体变异方向，未必强调最有助于分类的方向，这正是监督距离学习的动机。

等距离轮廓的几何解释



图中的三条闭曲线表示各自度量下到原点的固定距离，而不是三个可以直接比较的概率等高线。欧氏球在各方向同样伸展；曼哈顿球沿坐标轴形成菱形；含相关方向的正定二次型可形成旋转椭圆。某一点在哪条轮廓内部，取决于采用的距离和半径。

距离学习改变的是这些局部邻域的形状。如果所有相关特征都被重复编码，多次计算同一方向的差异会放大该方向权重；非对角结构或合适的表示可以减少这种冗余。但图形中的椭圆是否适合标签，不能只靠几何美观判断，仍需训练与验证。

15.4 k 近邻分类：局部频率与多数投票

对 K 个类别，均匀近邻概率估计为

$$\hat{p}_c(x) = \frac{1}{k}\sum_{i\in N_k(x)} \mathbf{1}[y_i = c], \qquad \hat{y}(x) = \arg\max_c \hat{p}_c(x).$$

这里用大写 K 表示类别数，小写 k 表示邻居数。票数除以 k 得到局部比例，和为 1。它只有 $0, 1/k, \dots, 1$ 等离散取值，不应把小邻域中的 1 解释为目标事件绝对确定。

二分类常取奇数 k 减少纯票数平局，但不能消除距离平局，也不能消除多分类票数平局。若类别编号只用于打破平局，则编号改变可能影响少量边界预测；实验应声明这一行为。类别不平衡时，大类可能占据更多邻居，可考虑距离权重、不同评价指标和训练采样，但必须遵守第 13、14 章的概率与泄漏约定。

例题 15.3：分类概率与平局

一维训练点为 $0,1,2,4,5$，标签依次为 A、A、B、B、B，查询点为 1.8。求 $k=1,3,5$ 的类别与 B 类概率。

解 各距离为 1.8、0.8、0.2、2.2、3.2，最近顺序为下标 3、2、1、4、5。$k=1$ 时预测 B、概率 1；$k=3$ 时邻居标签 B、A、A，预测 A、B 概率 $1/3$；$k=5$ 时预测 B、概率 $3/5$。增加 k 不保证类别只变化一次，也不保证概率单调。若 $k=2$，A、B 各一票，需要预定平局规则。

$k=1$、欧氏距离且没有重复点时，每个训练点附近的区域由离它最近决定，形成 **Voronoi 划分**。两个训练点等距的位置是它们连线的垂直平分超平面；许多这样的边界拼成分段区域。近邻可以产生非线性分类边界，却不意味着对高维小样本必然泛化良好。

训练集自测时，若查询包含自身，$k=1$ 通常能直接取到自身标签，训练准确率接近 100%。这只是记忆性质。评估时必须用未参与邻居库的样本，或明确采用排除自身的留一规则；相同输入有冲突标签时，即使训练内也可能因同分选择产生错误。

15.5 k 近邻回归：局部最小二乘

为什么取平均而不是随意聚合

固定查询 x 及其邻居集合，假设邻域内用一个常数 a 近似目标。考虑局部平方误差

$$Q(a)=\sum_{i\in N_k(x)}(y_i-a)^2.$$

求导 $Q'(a)=2ka-2\sum_i y_i$，令其为 0，二阶导数 $2k>0$，得到

$$\hat{y}(x)=\frac{1}{k}\sum_{i\in N_k(x)}y_i.$$

若局部目标改为绝对误差，最优常数改为邻居标签的中位数。因此聚合规则应与目标损失联系，而不只是程序习惯。

均匀或非负加权平均都在所选标签的最小值与最大值之间。这使近邻对局部异常有一定平均作用，也限制了外推：即使真实价格随面积持续增加，远离训练区域的查询仍只能输出某些已见价格的平均。线性回归可以沿斜率外推，但外推是否可靠仍依赖模型假设。

距离加权与零距离

令 $a_i\ge 0$ 且 $\sum_i a_i>0$，最小化加权平方误差可得到 $\hat{y}=\sum_i a_i y_i/\sum_i a_i$。常见距离权重为 $a_i=1/d_i$ 或某个随距离减小而增大的核函数。分类同样可以把计数换成类别加权和。

若存在 $d_i=0$，直接求倒数会除以 0。本章实验约定：所选邻居中若有零距离点，只平均这些零距离点，其余权重设为 0；若零距离点标签冲突，保留它们的平均或类别

频率。另一种 $1/(d_i+\varepsilon)$ 会依赖人为选择的 ε，它不是完全相同的规则。

例题 15.4：加权回归与重复样本

训练坐标为 $(0,0,2,4)$，回归标签为 $(1,3,8,10)$，$k=3$。查询 0、1、3，按距离稳定排序，用 $1/d$ 加权并采用上述零距离规则。

解 查询 0 选两条 0 和点 2，两个零距离标签平均为 2。查询 1 最近三点为 0、0、2，距离均为 1，预测 $(1+3+8)/3=4$。查询 3 选点 2、4，再选第一条 0，距离为 1、1、3，预测

$$\frac{8+10+1/3}{1+1+1/3}=\frac{55}{7}\approx 7.857143.$$

若检索器在第三名同距时选了第二条 0，预测变为 $57/7\approx 8.142857$。两者差异来自边界同分规则，不能仅凭数值不等就断定距离公式错误。

相同输入不必总对应相同标签，可能存在测量噪声、未观测因素或标注冲突。去重时不应随意保留第一条并声称已消除噪声；重复记录也可能导致某类权重被人为放大。应结合数据来源判断它们是独立观测还是重复采集。

15.6 选择 k：局部偏差、方差和一致性

较小 k 使用更局部的邻域，能跟随细节，但容易被噪声或单个异常标签影响。较大 k 平均更多记录，通常降低随机波动，却混合更远位置，可能跨过分类边界或平滑掉回归弯曲。在 $k=n$ 时，均匀回归退化为训练标签均值，分类退化为全局类别频率。

在简单回归近似中，邻域内条件均值几乎不变，且标签噪声独立、方差 σ^2，均匀平均噪声的方差为 σ^2/k。若权重已归一化为 α_i，噪声方差为 $\sigma^2\sum_i \alpha_i^2$，可定义有效邻居数 $k_{\mathrm{eff}}=1/\sum_i \alpha_i^2$。极端集中权重可能使名义上 $k=20$ 的模型实际接近 1 近邻。

另一方面，若 $m(x)$ 满足 Lipschitz 条件 $|m(x_i)-m(x)|\le L\|x_i-x\|$，且邻居都位于半径 r_k 内，则条件均值偏差的绝对值至多为 Lr_k，平方偏差至多 $L^2r_k^2$。于是可用

$$\text{局部均方误差}\ \lesssim\ L^2r_k^2+\frac{\sigma^2}{k}$$

理解邻域扩大与平均噪声之间的取舍。这个表达省略了随机邻域等细节，是在明确平滑与独立噪声条件下的解释性上界，不是任意数据上的精确学习曲线。

在有限维欧氏空间、独立同分布样本及适当可积性等标准条件下，让 $k=k_n$ 随样本量增长，同时满足 $k_n\to\infty$、$k_n/n\to 0$，是 k 近邻一致性结果中的关键条件：前者使局部平均的噪声下降，后者使邻域在有数据的区域逐渐局部化。它是渐近结论，不给出有限样本的最佳 k，也不能保证固定 $k=1$ 一致。

实际将 k、距离类型、距离权重和表示作为整个 Pipeline 的超参数，用第 14 章的合法验证选择。可从对数或稀疏网格开始，再在开发范围细化。不能因为 $\sqrt{n}$ 是常见经验值就跳过验证；最优邻域取决于噪声、维数、类别边界和样本密度。

15.7 维度灾难：邻域为何越来越难局部化

覆盖相同局部范围需要多少样本

维度灾难（curse of dimensionality）描述维数增加时空间覆盖、估计和计算所面临的困难。考虑在单位超立方体上均匀分布，边长为 h 的轴对齐小立方体体积为 h^d。若要其中平均包含 k 条样本，需要近似满足

$$nh^d \approx k, \qquad h \approx (k/n)^{1/d}.$$

固定 $k/n = 0.01$，一维边长 0.01，二维 0.1，十维约 0.631；高维中要包含同样比例的点，邻域需要沿每个坐标扩展很大范围。这里使用体积与均匀分布作示意，不把立方体直接等同于真实欧氏球。

例题 15.5：局部覆盖的指数代价

每一维都希望邻域边长不超过 0.2，且邻域期望包含 10 条样本。在单位均匀立方体模型下，二维与十维分别约需多少样本？

解　由 $n(0.2)^d = 10$，得到 $n = 10 \times 5^d$。二维需 250 条，十维需 97656250 条。增加的样本量不是维数的五倍，而随维数指数增长。该数值只用于说明指定分辨率下的覆盖代价，不是实际项目的样本量公式。

距离集中与无关维度

设 x, q 独立来自 $N(0, I_d)$。各维差为独立 $N(0, 2)$，故平方距离 $S = \|x - q\|^2$ 满足

$$E[S] = 2d, \quad \mathrm{Var}(S) = 8d, \quad \frac{\mathrm{SD}(S)}{E[S]} = \sqrt{\frac{2}{d}}.$$

平均距离平方随维数增加，但相对波动缩小。这称为一种**距离集中**现象。距离都大不一定有害，问题是有用近邻与无关样本在距离上的相对差异可能变弱。该计算针对独立高斯样本对；它不直接证明任意数据集的最近和最远距离比都收敛到 1。

增加与标签无关的独立噪声特征，会向距离叠加随机贡献，可能淹没少数有用维度。标准化只统一尺度，不识别哪些维度与标签相关，因而不能自动解决这个问题。特征选择、监督表示学习或合适的先验距离可以减少干扰，但这些步骤本身也要在训练折内学习。

高维数据可能集中在低维结构附近，实际难度与**内在维度**有关，而不只取决于表格列数。PCA 等降维在第 21 章展开；保留最大方差方向未必保留分类信息，小方差方向也可能区分类别，所以降维仍需针对任务验证。

15.8 精确检索的计算成本与实现

暴力搜索和分块

对一个查询计算 n 个 d 维距离，时间为 $O(nd)$；对 m 个查询为 $O(mnd)$。全部排序需要每个查询 $O(n \log n)$，用局部选择可降低选前 k 的开销。训练样本与标签至少占 $O(nd + n)$ 存储，查询结果为 $O(mk)$。

广播表达 `Q[:, None, :] - X[None, :, :]` 会产生形状 (m, n, d) 的中间数组，不只是 (m, n) 距离矩阵。按查询批大小 B 分块，可将该中间内存降为 $O(Bnd)$；如果训练库仍太大，可再分训练块并维护每个查询当前最优的 k 项。分块改变内存，不改变精确算法所需的全部距离计算量。

平方距离也可写成 $\|q\|^2 + \|x\|^2 - 2q^{\mathrm{T}}x$，避免三维差数组并利用矩阵乘法。但相近的大数相减可能因舍入出现负的微小平方距离；把微小负值裁为 0 是数值修正，若出现明显负数或溢出则应检查数据和算法。直接差分对教学更清楚，但也需防止大数平方溢出。

`argsort(kind="stable")`完整排序并保留原下标同分顺序；`argpartition`可更快找候选，但边界同分的选择与内部顺序不稳定。若要求严格的“距离优先、下标次序”规则，需额外处理边界同分，不能仅对任意选出的 k 个下标再排序就保证一致。

KD 树和球树

KD 树（k-dimensional tree）递归按坐标划分空间，查询时利用查询点到区域的距离下界剪去不可能更近的分支。**球树**（ball tree）用包含点集的球组织节点，通过球心距离和半径形成下界。它们预先建立**索引**，即有利于检索的数据结构。

若一个球的中心为 c、半径 r，球内点 x 满足 $d(c, x) \le r$。由三角不等式 $d(q, x) \ge d(q, c) - r$。若此下界已大于当前第 k 小距离，整个节点都可跳过。这解释了为什么依赖此类剪枝的算法需要适当的度量条件。

低维且空间结构有利时，索引可显著减少查询工作；高维或大量节点都与查询邻域相交时，剪枝可能失效，最坏仍需接近全库扫描。不能把树查询一概写成 $O(\log n)$ 并忽略维数、分布和返回邻居数。是否快应在实际数据、相同精度与批量设置下测量，还需计入建索引和更新成本。

近似最近邻与检索评价

近似最近邻（approximate nearest neighbor，ANN）允许返回集合与精确前 k 不完全一致，以换取更低时间或内存。常见思路包括分区、图遍历和压缩表示；具体大规模索引将在第 35 章检索系统中继续讨论。

检索本身可用 Recall@$k = |A_k \cap E_k|/k$ 衡量，其中 A_k 是近似返回集合，E_k 是按固定同分规则确定的精确集合。这个召回率比较的是邻居集合，与第 14 章分类正例召回率不是同一量。若存在大量边界同分，集合重合指标还应说明等距替代项怎样处理。

近似检索误差不一定等于最终分类误差：换掉一个同类邻居可能不改变投票，换掉少量关键异类却可能改变结果。应同时报告检索召回、最终任务指标、延迟和内存。在相同硬件、查询批量和预热条件下测量；仅比较一次运行时间不足以判断稳定优势。

15.9 距离学习：用标签改变表示

从固定缩放到可学习的线性映射

距离学习（metric learning）利用监督信息学习怎样比较样本。设 $L \in \mathbb{R}^{r\times d}$，先做 $u = Lx$，再在 r 维中计算欧氏距离。它可以调整尺度、旋转坐标和减少维数，相应原空间矩阵为 $M = L^{\mathrm{T}}L$，自动半正定。

若只要求同类点靠近，一个退化解是 $L = 0$，此时所有距离为 0；还需同时约束不同类的区分，或使用直接关联近邻分类的目标。只凭“让相似点更近”不能构成完整可学习算法。标签本身有噪声时，距离学习也可能把错误关系放大。

邻域成分分析的软近邻目标

邻域成分分析（Neighborhood Components Analysis，NCA）以可微的随机近邻选择代替硬排序。对训练样本 i，排除自身，令

$$D_{ij} = \|L(x_i - x_j)\|^2, \qquad p_{ij} = \frac{e^{-D_{ij}}}{\sum_{l\neq i} e^{-D_{il}}}\ (j \neq i), \quad p_{ii} = 0.$$

这里 p_{ij} 表示把样本 j 随机选为 i 邻居的概率，不是类别概率。负平方距离越大即距离越小，被选中的概率越高。给定这种随机选择，分类正确的概率为

$$p_i = \sum_{j:y_j=y_i} p_{ij}, \qquad F(L) = \sum_i p_i.$$

最大化 F 就是提高训练样本留一随机 1 近邻的期望正确数。NCA 训练目标与最后用确定性 k 近邻预测不完全相同，k 仍需验证选择。

为说明目标如何可微，记 $\Delta_{ij} = x_i - x_j$、$C_{ij} = \Delta_{ij}\Delta_{ij}^{\mathrm{T}}$。由 $D_{ij} = \mathrm{tr}(LC_{ij}L^{\mathrm{T}})$ 得 $\partial D_{ij}/\partial L = 2LC_{ij}$。对归一化指数求导，

$$\frac{\partial p_{ij}}{\partial L} = -2p_{ij}L\left(C_{ij} - \sum_{l\neq i} p_{il}C_{il}\right).$$

再对同类 j 求和得到

$$\nabla_L F = 2L\sum_i \left[p_i \sum_{l\neq i} p_{il}C_{il} - \sum_{j:y_j=y_i} p_{ij}C_{ij}\right].$$

右侧括号是 $d\times d$ 矩阵，左乘 $r\times d$ 的 L 得到正确梯度维度。最小化负目标时需取负号。目标通常非凸，初始化、停止条件和局部最优都会影响结果；不能套用逻辑回归的凸性结论。

例题 15.6：软邻居正确概率

对某训练样本，另有一个同类点、一个异类点，变换后平方距离分别为 0、$\log 3$。求正确选择概率。若两类点距离都变为 0 呢？

解 指数权重分别为 1、1/3，同类选择概率为 $1/(1+1/3) = 3/4$。若全部距离为 0，两点各有 1/2 概率被选中，正确概率降为 1/2。这说明把所有点压到一起并不会自动得到最优分类目标。实际多样本情况下目标还取决于同类数量和其他点的位置。

NCA 直接使用标签，必须放入训练折内部，与标准化、近邻数共同验证。对整个数据集先学距离再 CV，会把验证标签泄漏到表示中。全批量目标涉及 n^2 样本对，时间与内存可能成为瓶颈；本章用小规模模拟展示机制，不声称它适合直接处理任意大规模检索库。

15.10 实验 15.1：可核对的分块精确近邻

入口为 配套实验/ch15_neighbors.py，使用 NumPy 及 scikit-learn。实验复现例题 15.4，并检查不同查询批大小给出相同下标、零距离权重和非法邻居数拒绝。为便于阅读，采用直接差分、完整稳定排序；这是正确性清楚的教学实现，不追求大型数据的最优速度。

核心距离和排序计算如下，其中 Q 为当前查询块：

```
import numpy as np
X = np.array([[0.], [0.], [2.], [4.]])
Q = np.array([[0.], [1.], [3.]])
k = 3
D2 = np.sum((Q[:, None, :] - X[None, :, :])**2,
            axis=2)
ix = np.argsort(D2, axis=1, kind="stable")[:, :k]
d = np.sqrt(np.take_along_axis(D2, ix, axis=1))
print(ix)
```

take_along_axis按每一行已选下标取对应距离，避免把一行下标应用到所有行。完整函数检查训练矩阵非空、查询维度一致、有限值，以及 k 和批大小必须为合法整数；布尔值虽然在 Python 中可视作整数子类，仍被拒绝。

距离非零时，程序使用每行最小距离除以各距离作为权重，再归一化。它与 $1/d$ 的归一化权重完全相同，却避免对极小距离取倒数引起上溢。存在零距离时另走明确定义的分支。分类投票使用 bincount，它要求类别先映射为非负整数；完整业务系统需保存原类别与整数的映射。

运行 python3 配套实验/ch15_neighbors.py，稳定下标为 $[0,1,2]$、$[0,1,2]$、$[2,3,0]$，加权回归为 $(2,4,55/7)$，均匀分类为 $(1,1,0)$。库对第三个查询可能选择另一个同距离点，脚本展示其结果但不强求与稳定实现相同；前两个查询的预测应一致。再将 k 改为 4、包含全部同分点，库与从零实现预测应一致。绝对和相对容差采用 NumPy 常规双精度核对；固定手算主要值应在 10^{-12} 级别一致。

修改任务：把第一条标签从 1 改为 5，检查查询 0 预测应改为 4；把批大小改为 1、2、10，邻居顺序应不变；把 k 改为 0、5、1.5 或 True，应被拒绝。若改用 argpartition，必须另外写出并核对边界同分规则，不能仅凭随机数据测试没有失败就宣称完全等价。

15.11 实验 15.2：距离集中与监督表示

入口为 配套实验/ch15_geometry.py。第一部分分别在 2、20、200 维生成 10000 对独立标准正态向量，计算平方距离的变异系数，即标准差除以均值，比较理论值 $\sqrt{2/d}$。固定种子 1502，本环境实测约为 1.012791、0.314886、0.099974，对应理论 1、0.316228、0.1。每项允许 0.05 绝对误差，这是有限模拟的粗核对，不要求随机末位永久固定。

第二部分生成 260 条、8 维、其中 2 维提供分类信息的模拟数据，把一列放大 100 倍。保留 65 条最终测试，其余 195 条用于 3 折 CV，选择 $k \in \{3, 7, 15\}$。预先比较两个完整流程：标准化后直接近邻；标准化后用 NCA 映射到 2 维，再近邻。NCA 固定随机种子和最大迭代数，不读取验证标签。

```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import (
    KNeighborsClassifier, NeighborhoodComponentsAnalysis)

pipe = Pipeline([
    ("scale", StandardScaler()),
    ("metric", NeighborhoodComponentsAnalysis(
        n_components=2, max_iter=60, random_state=15)),
    ("knn", KNeighborsClassifier(n_neighbors=3))])
```

完整脚本用搜索对象把整个 Pipeline 放进每个训练折重新拟合。NCA 与标准化都属于模型的一部分；如果为了加快运行先在全部 195 条开发数据上学习 NCA 再交叉验证，内层分数会看到验证标签，已不再是相同协议。

运行 python3 配套实验/ch15_geometry.py。本环境直接缩放流程选 $k = 15$，CV 准确率约 0.887179，测试约 0.923077；NCA 流程选 $k = 3$，CV 约 0.933333，测试约 0.984615。两种流程是预先声明的对照，不能在看过结果后继续扩展候选并仍将这个测试集视为新证据。这里只说明该固定模拟中的现象，不得推出 NCA 通常一定更好。若换数据、初始化或版本，非凸优化结果可能变化。

修改任务：移除 NCA、增加无关维度或改用距离加权，均在开发范围重新选择 k。把同一用户的多条样本加入模拟后，替换为分组验证。额外比较未缩放距离时，应明确其受计量单位支配；若有业务上合理尺度，则与自动标准化并列验证，而不是先假定单位方差最佳。

15.12 进一步理解局部估计与实现边界

局部密度决定同一个 k 看多远

固定邻居数意味着每个查询使用相同数量的记录，却不意味着使用相同空间范围。在训练点密集的区域，第 k 个邻居可能很近；在稀疏区域，它可能很远。对后者，模型仍会输出一个类别或数值，但局部平滑假设更难成立。

在 d 维、查询附近密度约为 $f(x) > 0$ 的简化条件下，半径 r 的球内期望样本数约

为 $nf(x)V_d r^d$，V_d 是单位球体积。因此

$$r_k \approx \left[\frac{k}{nf(x)V_d}\right]^{1/d}.$$

这比只讨论维数多说明了密度的作用。同样的 n, k, d，局部密度越低，邻域越大。记录第 k 邻居距离有助于识别覆盖不足，但该距离不是自动校准的错误概率；阈值也应通过开发数据和业务范围确定。

结合局部平滑平方偏差约随 r_k^2 增大、噪声方差约为 $1/k$ 的近似，在固定密度和维数下得到

$$\mathrm{MSE}(k) \approx A(k/n)^{2/d} + B/k,$$

其中 $A, B > 0$ 汇总平滑度、密度和噪声。对 k 暂按连续变量求导：

$$\frac{2A}{d} n^{-2/d} k^{2/d-1} - Bk^{-2} = 0,$$

所以 $k^{1+2/d} \propto n^{2/d}$，即 $k \propto n^{2/(d+2)}$，对应误差量级约为 $n^{-2/(d+2)}$。这只是特定平滑和密度条件下的尺度分析，不是直接选整数 k 的通用公式，但能说明维数增大为何使改善随样本量变慢。

训练内查询、留一和重复记录

若把训练矩阵本身传入预测接口，通常会把每条记录自己作为距离 0 的候选。排除自身不能简单删除所有零距离点，因为另一个独立样本也可能有相同特征。应通过记录下标或标识排除当前记录，再保留其他同坐标观测。

若希望每条记录留一后仍用 k 个邻居，训练库必须至少有 $k+1$ 条。可以先取 $k+1$ 个候选，再按身份删除自己；当库与查询存在不同顺序、重复标识或过滤时，需要显式映射，不能默认对角线就是自身。

留一验证的每一轮仍需考虑预处理是否重拟合。只排除邻居库中的目标记录，但标准差、特征选择或监督距离映射已在全部记录上拟合，严格说不是整个流程的留一评价。对大样本可能有人采用近似以节省计算，但应说明近似范围，不能把结果与完整无泄漏验证混称。

内存预算也应手算

若查询 $m = 1000$、训练库 $n = 100000$、特征数 $d = 100$，float64 广播差数组含 10^{10} 个元素，仅这个数组约需 80 GB 十进制字节；距离矩阵另需约 0.8 GB，尚未计入临时平方结果。一次矩阵表达虽然代码短，内存并不因此少。

若查询块大小为 10，差数组降到约 0.8 GB；进一步按训练块 10000 分块，差数组约 80 MB。维护前 k 候选时每块都与已有候选合并，再按相同距离和下标规则筛选。分块的正确性来自：被某块内至少 k 个更优点压过的候选，不可能进入全局前 k；同分次序必须也纳入“更优”的定义。

实际峰值内存还包括 NumPy 表达式临时数组和库缓冲。应实测而不只用最终数组形状估算。float32 可减半存储，但距离接近时的舍入可能改变排名，应在允许精度下比较预测与检索质量。

NCA 梯度怎样独立核对

配套 `ch15_solutions.py` 用四条固定二维样本构造排除自身的软邻居目标，按正文公式计算 $\nabla_L F$，再对 2×2 映射的每一元素作中心差分。核对时选择非零且非对角的 L，避免 $L = 0$ 恰好使梯度为 0 而掩盖错误。

稳定实现先把自选得分设为负无穷，再按每行进行 log-sum-exp 归一化，使对角概率为 0、每行和为 1。每行必须至少有一个其他样本；若某类只有一个样本，它没有同类可选，其该项正确概率为 0。这个边界并不意味着程序崩溃，但提醒当前目标在该类上缺少同类关系。

差分通过只核对这个小输入的目标和公式一致，不能证明非凸优化找到了全局最优。还应分别检查行概率和、对角概率、同类掩码、标签置换不变性，以及共同平移所有输入后距离和目标不变。若把标签类别名作一一重命名，同类关系不变，目标也应不变。

15.13 近邻法与其他模型的比较

逻辑回归在给定表示中学习全局线性边界，预测成本主要由特征数和类别数决定；k 近邻保存样本、利用局部结构，预测成本随训练库增大。前者在边界大致线性时可能用较少样本获得稳定估计，后者在低维且局部规律明确时可形成灵活边界。没有一种方法仅凭“无需训练”或“非参数”就保证更强。

非参数方法通常指模型复杂度不被预先固定的有限维参数族完全限制。k 近邻仍有 k、距离、权重、预处理和索引等配置；非参数不等于无超参数，也不等于无需验证。随着样本库增大，保存的实例和可表达的局部结构一起变化。

半径近邻固定距离范围而不是固定数量，在稠密处可用更多样本、稀疏处更少。它需要处理“没有邻居”的情况，例如拒绝预测或使用基线；不能把空平均当成 0。固定 k 总会返回邻居，即使所有训练样本都很远，因此距离阈值、覆盖检查和拒绝机制也值得关注。

近邻检索将贯穿后续内容：聚类按距离形成分组，降维改变表示，推荐检索相似用户或物品，检索增强生成查找文档向量。相同的“找最近”计算并不说明任务相同；距离表示、标签含义、评估单位和最终用途仍需分别定义。

方式	主要代价	核对重点
全库暴力距离	每查询 $O(nd)$，还需选前 k	内存中间量、距离精度、同分规则
查询分块	总距离次数不变，降低峰值内存	块大小改变不能改变精确结果
空间树索引	建库与遍历，效率依赖维数和分布	剪枝条件、最坏退化、更新成本
近似索引	以检索误差换取速度或内存	Recall@k、任务分数、延迟和容量
学习距离后检索	增加表示拟合与转换成本	训练折隔离、目标梯度、映射版本

选择检索方式前，应先有正确的精确基线。否则近似返回与预期不一致时，难以分清表示变了、索引误差、同分规则还是基础距离实现错误。索引必须与用于建立它的预处理和距离映射一起保存；更新映射后，旧索引坐标通常也需要重建。

15.14 分层习题

15.1. 为什么 k 近邻可以没有梯度训练过程，却仍然需要训练集和模型选择？说明它的非参数含义。

15.2. 查询原点，A 为 $(4,0)$、B 为 $(3,2)$，比较曼哈顿和欧氏最近邻。

15.3. 证明单位向量的平方欧氏距离等于 $2(1-\cos)$，并指出零向量问题。

15.4. 给定尺度 $(2,5)$，两点差为 $(4,10)$，求标准化欧氏距离，写出对应矩阵 M。

15.5. 对例题 15.3 求 $k=2$ 的距离加权 B 类概率，采用 $1/d$ 权重。

15.6. 最小化加权局部平方误差，推导加权平均；证明非负归一权重下预测不会超过邻居标签范围。

15.7. 对例题 15.4 的查询 3，若 $k=4$，求距离加权回归预测；解释为什么此时边界同分不会造成集合差异。

15.8. 归一权重为 $(0.8,0.1,0.1)$，求有效邻居数，并与均匀 3 近邻的噪声方差比较。

15.9. 在单位均匀立方体模型中，$n=10000, k=10$，求二维和六维的邻域边长近似。

15.10. 独立标准高斯样本对在 $d=50$ 时，平方距离均值、方差和变异系数分别是多少？

15.11. 构造一个半正定但非正定的 M，给出不同点距离 0 的例子。解释这种映射为什么仍可用于分类。

15.12. 说明为何在全数据上先拟合 NCA 再交叉验证会泄漏；若只拟合无标签 PCA，严格归纳协议又应如何处理？

15.13. 设计精确和近似检索对照，至少包含检索质量、任务质量、时间和内存四方面。

15.14. 修改实验 15.1，加入零查询行、非法维度和极大有限值；说明应返回空结果还是主动拒绝，并验证分块一致性。

15.15 参考答案与核对步骤

15.1. 保存样本库、拟合缩放或距离映射都使用训练数据，k 和距离还需通过验证选取。非参数表示其复杂度可随样本量增长，不是没有配置。预测依赖训练记录，因此不能把测试样本加入邻居库。

15.2. 曼哈顿距离 A 为 4、B 为 5，选 A；欧氏距离 A 为 4、B 为 $\sqrt{13} \approx 3.606$，选 B。不同距离对各坐标偏差的聚合不同。

15.3. 展开 $\|u-v\|^2 = u^{\mathrm{T}}u + v^{\mathrm{T}}v - 2u^{\mathrm{T}}v = 2 - 2\cos$。对非零原向量先单位归一化；零向量无法除以范数，需预定处理策略。

15.4. 缩放后差为 $(2,2)$，距离 $\sqrt{8}$；$M = \mathrm{diag}(1/4, 1/25)$。平方距离为 $16/4 + 100/25 = 8$。

15.5. 两个最近点为坐标 2 的 B 和坐标 1 的 A，距离 0.2 和 0.8，权重 5 和 1.25。B 概率为 $5/6.25 = 0.8$，与均匀投票的 0.5 不同。

15.6. 令 $Q(a) = \sum_i w_i (y_i - a)^2$，导数为 $2a\sum_i w_i - 2\sum_i w_i y_i$，设为 0 即得平均。若 $y_{\min} \le y_i \le y_{\max}$，乘非负归一权重再求和，得到 $y_{\min} \le \hat{y} \le y_{\max}$。

15.7. 四个距离为 3、3、1、1，分子 $1/3 + 3/3 + 8 + 10 = 58/3$，分母 $1/3 + 1/3 + 1 + 1 = 8/3$，预测 $58/8 = 7.25$。全部点都被选入，同距离点顺序不影响求和。

15.8. 权重平方和为 0.66，有效邻居数 $1/0.66 = 50/33 \approx 1.515152$；噪声方差 $0.66\sigma^2$，均匀 3 近邻为 $\sigma^2/3$。名义邻居数相同，但权重集中使平均降噪较弱。

15.9. $k/n = 0.001$。二维 $h = 0.001^{1/2} \approx 0.031623$；六维 $h = 0.001^{1/6} \approx 0.316228$。每一维扩展范围增加约 10 倍，体现高维覆盖困难。

15.10. 均值 $2d = 100$，方差 $8d = 400$，标准差 20，变异系数 0.2。注意这里研究平方距离，不能把其方差直接当作距离本身的方差。

15.11. 取 $M = \mathrm{diag}(1, 0)$，点 $(0,0)$ 与 $(0,1)$ 距离 0，相当于只保留第一坐标。若第二维是无关噪声，该压缩可能改善分类；若第二维含标签信息，则可能损害分类，需验证。

15.12. NCA 目标直接使用所有标签，验证标签已经影响距离，发生监督泄漏。无标签 PCA 仍利用全数据的输入分布，严格归纳评价也应放进 Pipeline 并在训练折拟合；明确允许无标签测试输入的传导问题则属于另一协议。

15.13. 先固定查询、库、距离和同分约定，以精确结果作参考。报告 Recall@k、最终分类或检索任务指标、多批次延迟统计、峰值内存和索引大小，并计入建库与更新成本。使用相同硬件和批量，不能只报最快的一次。

15.14. 空查询可返回形状 $(0, k)$ 的下标和距离，因为没有待预测样本；空训练库、维度不匹配和非法 k 应拒绝。极大值即使输入有限，平方差仍可能溢出，完整函数在数值错误上下文中抛出异常。分块大小 1、2、大于查询数时，稳定下标应完全一致。